



دانشگاه اصفهان  
دانشکده مهندسی کامپیوتر

# توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی

پایان نامه برای دریافت درجه کارشناسی ارشد در رشته هوش مصنوعی و رباتیک

مهرداد قصابی

استاد راهنما

دکتر حمیدرضا برادران کاشانی

آذر ۱۴۰۴



齊人





دانشگاه اصفهان  
دانشکده مهندسی کامپیوتر

# توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی

پایان نامه برای دریافت درجه کارشناسی ارشد در رشته هوش مصنوعی و رباتیک

مهرداد قصابی

استاد راهنما

دکتر حمیدرضا برادران کاشانی

آذر ۱۴۰۴





## گواهی دفاع از پایان نامه کارشناسی ارشد

هیات داوران پایان نامه کارشناسی ارشد آقای مهرداد قصابی به شماره دانشجویی ۴۰۲۳۶۱۴۰۲۹ در رشته هوش

مصنوعی را در تاریخ ..... با عنوان « توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی »

به عدد به حروف

--	--

با نمره نهایی

ارزیابی کرد.

--

و درجه

ردیف	مشخصات هیات داوران	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا موسسه	امضا
۱	استاد راهنما	دکتر حمیدرضا برادران کاشانی	استاد	دانشگاه اصفهان	
۲	استاد داور داخلی	دکتر داور داخلی	دانشیار	دانشگاه اصفهان	
۳	استاد مدعو	دکتر داور خارجی	دانشیار	دانشگاه اصفهان	
۴	نماینده تحصیلات تکمیلی دانشکده	دکتر نماینده	دانشیار	دانشگاه اصفهان	

نام و نام خانوادگی معاون آموزشی و تحصیلات

تکمیلی پردیس دانشکده های فنی:

تاریخ و امضا:

نام و نام خانوادگی معاون تحصیلات تکمیلی و

پژوهشی دانشکده / گروه:

تاریخ و امضا:





## تعهدنامه اصالت اثر

به نام خدا

اینجانب مهرداد قصابی تأیید می‌کنم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آن‌ها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتری ارائه نشده است.

نام و نام خانوادگی دانشجو: مهرداد قصابی

تاریخ و امضای دانشجو:



کلیه حقوق مادی و معنوی این اثر  
متعلق به دانشگاه اصفهان است.



تقديم به:

پدرم كه در طول تحصيل پشـتـيـبانـم بوده است



## قدردانی

دستان پدر و مادر نازنینم را به پاس مهر بیکرانیشان به گرمی میفشارم و از استاد راهنما خود جناب آقای دکتر حمیدرضا برادران بابت راهنمایی هایشان در طول انجام این پایان نامه سپاس گزاری میکنم.

مهرداد قصابی

آذر ۱۴۰۴





## چکیده

استفاده از هوش مصنوعی در پاسخگویی به سوالات پزشکی به عنوان یکی از حوزه‌های نوظهور و مهم در فناوری و بهداشت شناخته می‌شود که در سال‌های اخیر مورد توجه گسترده‌ای قرار گرفته است. این فناوری پیشرفته، با قابلیت‌های ویژه خود، می‌تواند کیفیت خدمات پزشکی ارائه شده به بیماران را به شکل چشمگیری ارتقا دهد. همچنین، با سرعت بخشیدن به فرآیند ارائه اطلاعات پزشکی و ارائه پاسخ‌های سریع و دقیق به سوالات پزشکان و بیماران، نقش مهمی در کاهش فشار کاری پزشکان ایفا می‌کند. به این ترتیب، هوش مصنوعی نه تنها موجب افزایش کارایی در سیستم‌های بهداشتی می‌شود، بلکه تجربه کلی بیماران را بهبود می‌بخشد و زمینه ارائه درمان‌های بهتر و مؤثرتر را فراهم می‌کند.

از طرف دیگر از آنجا که پزشکی مبتنی بر استدلال و تحلیل‌های منطقی است، توسعه یک مدل پزشکی که بر پایه زنجیره‌ای از افکار و استدلال‌های منطقی طراحی شده باشد، می‌تواند دقت و کارایی این مدل را به طور قابل توجهی افزایش دهد. چنین رویکردی امکان انجام فرآیندهای پیچیده تشخیصی و درمانی را به صورت ساختاریافته‌تر و هدفمندتر فراهم می‌کند. در این زمینه، هر مرحله از تشخیص و درمان باید مبتنی بر شواهد علمی و داده‌های معتبر باشد. به عنوان مثال، پزشکان در فرآیند تشخیص بیماری‌ها معمولاً از تاریخچه پزشکی، علائم بالینی و نتایج آزمایش‌ها بهره می‌گیرند. با طراحی یک مدل منطقی، این داده‌ها می‌توانند در قالب یک زنجیره منطقی به یکدیگر متصل شوند که به شناسایی الگوها و روابط میان علائم و بیماری‌ها کمک می‌کند.

**واژگان کلیدی**    هوش مصنوعی در پزشکی، مدل‌های زبانی فارسی، مدل‌های زبانی پزشکی، پردازش زبان‌های طبیعی، توانایی استدلال هوش مصنوعی



# فهرست مطالب

ج	فهرست تصاویر
چ	فهرست جداول
ح	فهرست الگوریتم‌ها
د	فهرست برنامه‌ها
۱	فصل ۱: دیباچه
۱	۱.۱ هدف پژوهش . . . . .
۱	۲.۱ کاربرد پژوهش . . . . .
۱	۱.۲.۱ کاربرد مدل های زبانی پزشکی . . . . .
۲	۲.۲.۱ کاربرد مدل های زبانی پزشکی دارای قابلیت استدلال . . . . .
۲	۳.۲.۱ کاربرد مدل های زبانی پزشکی فارسی . . . . .
۳	۳.۱ مراحل انجام پایان نامه . . . . .
۴	۴.۱ ساختار پایان نامه . . . . .
۵	فصل ۲: ادبیات موضوع
۵	۱.۲ مقدمه . . . . .
۵	۲.۲ مدل های زبانی . . . . .
۶	۱.۲.۲ مدل های زبانی آماری . . . . .
۶	۲.۲.۲ مدل های زبانی بازگشتی . . . . .

۳.۲.۲	مدل های زبانی مبتنی بر ترنسفورمر	۷
۱.۳.۲.۲	مدل های زبانی فقط رمزگذار	۷
۲.۳.۲.۲	مدل های زبانی فقط رمزگشا	۸
۳.۳.۲.۲	مدل های زبانی رمزگذار-رمزگشا	۸
۳.۲	سیستم های پرسش و پاسخ	۸
۱.۳.۲	سیستم های پرسش و پاسخ استخراجی	۹
۲.۳.۲	سیستم های پرسش و پاسخ تولیدی	۹
۴.۲	شیوه های سنجش مدل های زبانی	۹
۱.۴.۲	سنجش بر اساس میزان پاسخگویی به پرسش و پاسخ های چند گزینه ای	۱۰
۲.۴.۲	سنجش بر اساس نظر مدل داور	۱۰
۳.۴.۲	سنجش بر اساس استنتاج زبان طبیعی	۱۱
۴.۴.۲	سنجش بر اساس امتیاز bert	۱۱
۵.۲	یادگیری تقویتی در مدل های زبانی	۱۲
۱.۵.۲	یادگیری تقویتی با بازخورد انسان یا هوش مصنوعی	۱۲
۲.۵.۲	الگوریتم های بهینه سازی مدل زبانی	۱۳
فصل ۳:	بررسی کارهای پیشین	۱۷
۱.۳	مقدمه	۱۷
۲.۳	کارهای پیشین در حوزه زبان انگلیسی	۱۷
۱.۲.۳	مدل های MedPaLM	۱۷
۲.۲.۳	مدل ChatDoctor	۱۸
۳.۲.۳	مدل های Meerkat	۱۸
۴.۲.۳	مدل MedMobile	۱۹
۳.۳	کارهای پیشین در حوزه زبان فارسی	۱۹
۱.۳.۳	مدل Sina-bert	۲۰
۲.۳.۳	سیستم پرسش و پاسخ پزشکی دکتر ویسی و همکاران	۲۰

۳۰	پایان نامه کارشناسی ارشد خانم لیلا دارابی	۳.۳.۳
۲۱	بهبود قابلیت دلیل آوری در حوزه پزشکی	۴.۳
۲۱	مدل MedSSS	۱.۴.۳
۲۲	مدل MedReason	۲.۴.۳
۲۳	مدل HuatuoGPT-o1	۳.۴.۳
۲۳	بهبود قابلیت دلیل آوری در حوزه های دیگر	۵.۳
۲۳	مدل Deepseek	۱.۵.۳
۲۴	چهارچوب Thought Preference Optimization	۲.۵.۳
۲۵	آموزش استدلال مدل های بزرگ به مدل های کوچک	۳.۵.۳
۲۷	جمع آوری دادگان	فصل ۴:
۲۷	مقدمه	۱.۴
۲۷	معرفی پیکره پزشکی فارسی	۲.۴
۲۸	معرفی مجموعه داده MF3QA	۳.۴
۲۹	منابع مجموعه داده MF3QA	۱.۳.۴
۲۹	فیلتر کردن رکورد های مجموعه داده MF3QA	۲.۳.۴
۳۱	خزش از تالار گفتگو دکترهست	۱.۲.۳.۴
۳۱	ترجمه قسمت پزشکی مجموعه داده MMLU	۴.۴
۳۲	گردآوری سوالات کنکور علوم پایه پزشکی ایران	۵.۴
۳۳	ترجمه ماشینی مجموعه داده MedMCQA	۶.۴
۳۳	مجموعه دادگان PersianMedQA و PerMedCQA	۷.۴
۳۵	معرفی مدل زبانی گائوکرنا-V	فصل ۵:
۳۵	مقدمه	۱.۵
۳۵	مدل پایه	۲.۵
۳۶	ویژگی های مدل aya-expanse	۱.۲.۵
۳۷	تنظیم دقیق روی پیکره پزشکی	۳.۵

۴.۵	تنظیم دستورالعملی روی مجموعه داده MF3QA	۳۸
۵.۵	رد پای کربن مدل گائوکرنا-V	۳۸
۶.۵	نتایج	۳۹
۱.۶.۵	مقایسه با مدل های زبانی فارسی همه منظوره	۴۰
۲.۶.۵	مقایسه با جایگزین های خط لوله ای	۴۱
فصل ۶:	استدلال در مدل های زبانی	۴۵
۱.۶	ناتوانی معماری ترنسفورمر در تفکر سیستم دو	۴۵
۲.۶	طراحی یک معماری دارای قابلیت تفکر سیستم دو	۴۶
۳.۶	بهبود توانایی دلیل آوری مدل های زبانی مبتنی بر ترنسفورمر	۴۷
۱.۳.۶	روش های مبتنی بر هوش مصنوعی عصبی-نمادین	۴۷
۲.۳.۶	روش های مبتنی بر راهنمایی مدل زبانی توسط یک مدل پاداش	۴۹
۳.۳.۶	روش های مبتنی بر تمرین روی داده های دلیل آوری	۴۹
فصل ۷:	معرفی مدل زبانی گائوکرنا-R	۵۱
۱.۷	مقدمه	۵۱
۲.۷	مدل پایه	۵۱
۳.۷	متد های معرفی شده	۵۲
۱.۳.۷	روش نخست	۵۲
۲.۳.۷	روش دوم	۵۳
۴.۷	رد پای کربن	۵۴
۵.۷	نتایج	۵۵
۱.۵.۷	سنجش استدلال پزشکی	۵۶
۱.۱.۵.۷	دقت	۵۷
۲.۱.۵.۷	Pass@k	۵۷
۲.۵.۷	سنجش دانش پزشکی	۵۸
۳.۵.۷	سنجش پایانی	۵۹

۶۵	نتیجه گیری	فصل ۸:
۶۶	تحقیقات آینده	۱.۸
۶۷		کتابنامه
۷۵	اجرای مدل های زبانی	فصل آ:
۷۵	اجرای مدل ها	۱.آ

## فهرست تصاویر

۱۵	معماری ترنسفورمر	۱.۲
۱۵	مقایسه الگوریتم بهینه‌سازی سیاست مجاورتی و بهینه‌سازی مستقیم ترجیحات	۲.۲
۲۲	بلوک دیاگرام مدل medsss	۱.۳
۲۵	بلوک دیاگرام Thought Preference Optimization	۲.۳
۲۶	بلوک دیاگرام آموزش دلیل آوری توسط مدل بزرگتر به مدل کوچکتر	۳.۳
۳۰	سهم هر مجله در پیکره پزشکی فارسی گردآوری شده	۱.۴
۳۱	سهم هر تالار گفتگو در مجموعه داده MF3QA	۲.۴
۳۶	مکانیسم آریتاژ داده	۱.۵
۳۸	نمودار کاهش خطا تنظیم دقیق روی پیکره پزشکی	۲.۵
۳۹	نمودار کاهش خطا تنظیم دقیق روی مجموعه داده MF3QA	۳.۵
۴۰	مکانیسم جایگزین خط لوله ای	۴.۵
۴۰	نرخ پیروزی گائوکرنا-V در رقابت با بقیه مدل های زبانی فارسی همه منظوره	۵.۵
۴۲	نرخ پیروزی گائوکرنا-V در رقابت با جایگزین های خط لوله ای	۶.۵
۵۳	بلوک دیاگرام شیوه نخست	۱.۷
۵۵	بلوک دیاگرام شیوه دوم	۲.۷
۵۷	نمودار کاهش خطا بهینه سازی مستقیم ترجیحات	۳.۷
۵۹	نتایج Pass@k روی مجموعه داده ترجمه قسمت پزشکی MMLU	۴.۷
۶۰	نتایج Pass@k روی مجموعه داده کنکور علوم پایه پزشکی شهرپور 1401	۵.۷



## فهرست جداول

۱.۱	اطلاعات دو فاز پایان نامه	۳
۱.۴	مقایسه پیکره گردآوری شده با پیکره های گردآوری شده توسط I. Garcia Ferrero et al.	۲۸
۲.۴	مقایسه مجموعه داده های پرسش و پاسخ آزاد پزشکی با مجموعه داده گردآوری شده	۲۹
۱.۵	مقایسه مدل گائوکرنا-V با بقیه مدل های زبانی فارسی همه منظوره	۴۳
۲.۵	مقایسه مدل گائوکرنا-V با جایگزین های خط لوله ای	۴۴
۱.۷	دقت با درخواست زنجیره افکار بدون نمره منفی	۶۱
۲.۷	دقت با درخواست زنجیره افکار با نمره منفی	۶۲
۳.۷	دقت با درخواست مستقیم	۶۳
۴.۷	ارزیابی دو پیکربندی	۶۴



## فهرست الگوریتم‌ها

۱.۴	الگوریتم جستجو اول عرض برای استخراج رکورد های پرسش و پاسخ پزشکی	۳۲
۱.۷	شیوه دوم پیشنهاد شده برای بهبود دلیل آوری	۵۴
۲.۷	شیوه دوم پیشنهاد شده برای بهبود دلیل آوری	۵۶

## فهرست برنامه‌ها

۱.آ	اجرای مدل های زبانی ورودی فقط متن	۷۶
۲.آ	اجرای مدل های زبانی ورودی متن و تصویر	۷۷



# فصل ۱

## دیباچه

### ۱.۱ هدف پژوهش

هدف از این پژوهش، توسعه یک مدل زبانی پزشکی فارسی بر پایه استدلال<sup>۱</sup> است که قابلیت اجرا روی دستگاه‌های محلی را داشته باشد. اجرا روی دستگاه‌های محلی از آن جهت حائز اهمیت است که داده‌های پزشکی اغلب حساس و خصوصی هستند و ارسال آنها به سرورهای خارجی ممکن است خطرات جدی برای حریم خصوصی بیماران ایجاد کند. [۱]

### ۲.۱ کاربرد پژوهش

#### ۱.۲.۱ کاربرد مدل های زبانی پزشکی

مدل های زبانی در سال های اخیر با استفاده از داده های بسیار گسترده تر و معماری های پیشرفته تر به پیشرفت های چشمگیری دست یافته اند. این مدل ها توانایی درک بهتر مفاهیم، تولید متن های طبیعی تر و پاسخ دهی دقیق تر به سوالات را پیدا کرده اند.

این پیشرفت ها منجر به افزایش چشمگیر کاربرد هوش مصنوعی<sup>۲</sup> در حوزه های مختلف، به ویژه در زمینه

---

<sup>۱</sup> reasoning  
<sup>۲</sup> artificial intelligence

پزشکی، شده است. امروزه در حوزه پزشکی، مدل‌های زبانی مبتنی بر یادگیری ژرف<sup>۳</sup> نقش مهمی در تحلیل داده‌های پزشکی، بهبود دقت تشخیص بیماری‌ها، ارائه پیشنهادها، درمانی دقیق‌تر و افزایش کیفیت مراقبت از بیماران ایفا می‌کنند. علاوه بر این، این فناوری، به بهینه‌سازی سیستم‌های اداری و کاهش بار کاری کادر درمانی کمک شایانی کرده است. به عنوان مثال، مدل‌های هوش مصنوعی قادرند با تحلیل داده‌های حاصل از پرونده‌های پزشکی، الگوهای مرتبط با بیماری‌ها را شناسایی کنند و اطلاعات ارزشمندی را برای تصمیم‌گیری سریع‌تر و دقیق‌تر در اختیار پزشکان قرار دهند. این مدل‌ها همچنین می‌توانند نقش مهمی در تکمیل مشاوره‌های پزشکی ایفا کرده و به پزشکان در ارائه اطلاعات دقیق‌تر و سریع‌تر کمک کنند. و حتی شاید در آینده ای نه چندان دور بتوانند جای پزشکان را در مشاوره‌های پزشکی بگیرند.

این تحول نه تنها به افزایش کارایی و بهره‌وری در سیستم‌های درمانی منجر شده است، بلکه تجربه کلی بیماران را نیز بهبود بخشیده و امکان ارائه خدمات درمانی بهتر و مؤثرتر را فراهم کرده است. به همین دلیل، توسعه و استفاده از مدل‌های زبانی پزشکی<sup>۴</sup>، همچنان مورد توجه پژوهشگران و متخصصان قرار دارد.

## ۲.۲.۱ کاربرد مدل‌های زبانی پزشکی دارای قابلیت استدلال

پزشکی به عنوان یک علم تجربی و کاربردی، بیش از هر چیز به استدلال دقیق وابسته است. تشخیص بیماری، انتخاب درمان، پیش‌بینی پیامد و حتی آموزش پزشکی، همگی بر پایه زنجیره‌های منطقی، تحلیل داده‌های بالینی و استنتاج از شواهد بنا شده‌اند. از آن روی که پزشکی علم وابسته به استدلال است، توسعه یک مدل زبانی که دارای قابلیت‌های استدلال برتری باشد می‌تواند بسیار تحول‌آفرین باشد. این مدل‌ها نه تنها می‌توانند اطلاعات را بازیابی کنند، بلکه می‌توانند دلیل بیاورند، احتمالات را مقایسه کنند، تناقضات را شناسایی کنند و تصمیمات را توجیه‌پذیر سازند. بنابراین توسعه این نوع از مدل‌های زبانی در حوزه پزشکی بسیار مفید است.

## ۳.۲.۱ کاربرد مدل‌های زبانی پزشکی فارسی

علیرغم پیشرفت‌های چشمگیر در توسعه مدل‌های زبانی پزشکی به زبان انگلیسی، در حوزه زبان فارسی هنوز کار چندانی صورت نگرفته است. این در حالی است که در سرتاسر جهان میلیون‌ها نفر تنها قادر به استفاده از این زبان هستند؛ بنابراین تلاش برای توسعه یک مدل زبانی پزشکی در زبان فارسی می‌تواند گامی رو به جلو در ارتباطات و خدمات درمانی کشور های فارسی زبان باشد.

<sup>۳</sup> deep learning  
<sup>۴</sup> medical language models

## ۳.۱ مراحل انجام پایان نامه

همانطور که در جدول ۱.۱ این پایان نامه در دو فاز اصلی طراحی و اجرا شده است. فاز نخست به جمع‌آوری دادگان پزشکی فارسی و توسعه مدلی با نام گائوکرنا-V اختصاص دارد که فاقد توانایی استدلال بوده و بیشتر بر درک سیستم یک<sup>۵</sup> زبان تمرکز دارد. از این فاز، مقاله‌ای با عنوان ”اهرم قرار دادن داده‌های آنلاین برای بهبود دانش پزشکی یک مدل زبانی کوچک پزشکی فارسی“<sup>۶</sup> استخراج شده است که به تشریح فرآیند جمع‌آوری داده‌ها و نحوه بهینه‌سازی دانش پزشکی مدل می‌پردازد. در فاز دوم این پژوهش ابتدا تکنیک‌های جدیدی برای ارتقای توانایی استدلال و درک سیستم دو مدل معرفی شده و سپس مدل گائوکرنا-R در این فاز توسعه داده شده است. از این فاز نیز، مقاله‌ای با عنوان ”بهبود مهارت‌های استدلال در مدل‌های زبانی پزشکی فارسی کوچک می‌تواند از آموزش داده‌های بزرگ‌مقیاس پیشی بگیرد“<sup>۷</sup> استخراج شده است.

مقاله نخست در سی و دومین کنفرانس ملی و دهمین کنفرانس بین‌المللی مهندسی پزشکی ایران و مقاله دوم در یازدهمین کنفرانس بین‌المللی پردازش سیگنال و سیستم‌های هوشمند منتشر شده است.

	<b>gaokerena-V</b>	<b>gaokerena-R</b>
مخزن گیت هاب	mehrdadghassabi/gaokerena-V	mehrdadghassabi/gaokerena-R
مخزن پارامترها	gaokerena/gaokerena-v1.0	gaokerena/gaokerena-r1.0
پیوند مقاله	arxiv.org/pdf/2505.16000	arxiv.org/pdf/2510.20059
هزینه	۳۰۰ دلار	۷۰ دلار
توانایی استدلال	خیر	بله
منتشر شده در	سی و دومین کنفرانس ملی و دهمین کنفرانس بین‌المللی مهندسی پزشکی ایران	یازدهمین کنفرانس بین‌المللی پردازش سیگنال و سیستم‌های هوشمند

جدول ۱.۱: اطلاعات دو فاز پایان نامه

<sup>۵</sup> در علم رفتارشناسی به درک سریع، شهودی و بدون نیاز به تفکر ژرف درک سیستم یک و به درک آهسته، غیر شهودی و نیازمند استدلال درک سیستم دو می‌گویند.

Leveraging Online Data to Enhance Medical Knowledge in a Small Persian Language Model<sup>۶</sup>  
Enhancing Reasoning Skills in Small Persian Medical Language Models Can Outperform Large-Scale<sup>۷</sup>  
Data Training



## ۴.۱ ساختار پایان نامه

در این پایان نامه، ساختار فصل ها به گونه ای طراحی شده است که مراحل مختلف پژوهش به صورت منظم و هدفمند ارائه شوند. فصل دوم به بررسی کارهای پیشین اختصاص دارد که در آن مطالعات انجام شده در زمینه های مرتبط مرور خواهند شد. در فصل سوم، به دلیل عدم وجود دادگان پزشکی در حوزه زبان فارسی، فرآیند گردآوری و آماده سازی این دادگان به طور دقیق تشریح خواهد شد. سپس در فصل چهارم، با استفاده از دادگان معرفی شده در فصل سوم، مدل اولیه با نام گائوکرنا-<sup>۱</sup> V معرفی و تحلیل می شود. در فصل پنجم، توانایی های استدلال در مدل های هوش مصنوعی مورد بررسی قرار گرفته و چالش ها و راهکارهای مرتبط با استدلال ارائه خواهند شد. در ادامه، در فصل ششم، با معرفی تکنیک هایی برای بهبود توانایی استدلال یک مدل زبانی مدل پیشرفته تری به نام گائوکرنا-<sup>۱</sup> R معرفی و ویژگی های آن به تفصیل شرح داده می شود. در نهایت، فصل پایانی به جمع بندی نتایج پژوهش و پیشنهاداتی برای تحقیقات آینده اختصاص دارد.

<sup>۱</sup> نام گائوکرنا از درختی افسانه ای الهام گرفته شده است که در روایات اساطیری زرتشتی به عنوان نماد شفادهی و جاودانگی شناخته می شود.

## فصل ۲

# ادبیات موضوع

### ۱.۲ مقدمه

در این فصل به بررسی مفاهیم مدل‌های زبانی<sup>۱</sup> انواع آن و چگونگی سنجش آن‌ها خواهیم پرداخت. همچنین، انواع سیستم‌های پرسش و پاسخ<sup>۲</sup> را مورد تحلیل قرار خواهیم داد تا درک بهتری از عملکرد و کاربردهای مختلف این سیستم‌ها به دست آوریم.

### ۲.۲ مدل‌های زبانی

مدل‌های زبانی ابزارهای پیشرفته‌ای هستند که برای پردازش و تولید زبان طبیعی طراحی شده‌اند. این مدل‌ها با استفاده از یادگیری ماشین<sup>۳</sup> و به ویژه یادگیری عمیق<sup>۴</sup>، توانایی درک و تولید متن را دارند. در حقیقت، وظیفه مدل‌های زبانی پیش‌بینی توکن بعدی<sup>۵</sup> بر اساس متنی است که تاکنون تولید شده است. این مدل‌ها دارای انواع مختلفی است که در ادامه آن‌ها را بررسی می‌کنیم.

---

language models<sup>۱</sup>  
question answering systems<sup>۲</sup>  
machine learning<sup>۳</sup>  
deep learning<sup>۴</sup>  
next token prediction<sup>۵</sup>

## ۱.۲.۲ مدل های زبانی آماری

مدل های زبانی n-gram ابتدایی ترین مدل های زبانی هستند که در دهه نود میلادی به عنوان جایگزینی برای ترجمه ماشینی مبتنی بر قانون<sup>۶</sup> معرفی شدند [۲] همانطور که در فرمول ۱.۲.۲ مشاهده میکنید این مدل ها برای پیش بینی توکن بعدی از فراوانی n-gram ها در پیکره<sup>۷</sup> موجود استفاده میکنند. به عنوان مثال در مدل زبانی 2-gram، احتمال وقوع یک کلمه تنها بر اساس کلمه قبلی محاسبه می شود.

$$P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-n+1}, w_{i-n+2}, \dots, w_{i-1})$$

## ۲.۲.۲ مدل های زبانی بازگشتی

شبکه های عصبی بازگشتی نوعی از شبکه های عصبی مصنوعی<sup>۸</sup> هستند که به طور خاص برای پردازش توالی ها<sup>۹</sup> طراحی شده اند. [۳] از آنجا که زبان را نیز می توان به صورت یک توالی از توکن ها تعریف کرد، بنابراین می توان از شبکه های عصبی بازگشتی به عنوان مدل های زبانی استفاده کرد.

همانطور که در فرمول ۲.۲.۲ که فرمول پایه شبکه های عصبی است می بینید ویژگی اصلی شبکه های عصبی بازگشتی این است که دارای حلقه های بازگشتی است که به آن اجازه می دهد اطلاعات را از مراحل قبلی به مراحل بعدی منتقل کند. این ساختار باعث می شود شبکه های عصبی بازگشتی بتواند وابستگی های زمانی و ترتیبی داده ها را مدل سازی کند.

شبکه های عصبی بازگشتی مانند نوع ساده آن<sup>۱۰</sup> معمولاً در مدل کردن وابستگی های بلند مدت<sup>۱۱</sup> با مشکل مواجه میشوند، این وابستگی ها که در زبان های طبیعی به وفور یافت میشوند باعث شده اند که مدل های زبانی مبتنی بر شبکه های عصبی بازگشتی مدل های چندان خوبی نباشند. هر چند در انواع دیگر این شبکه ها مانند LSTM [۴] برای حل این مشکل تلاش شده است اما این مشکل هنوز در این نوع از شبکه های عصبی وجود دارد.

$$h_t = f(W_h h_{t-1} + W_x x_t + b)$$

<sup>۶</sup> rule-based machine translation  
<sup>۷</sup> corpus  
<sup>۸</sup> artificial neural networks  
<sup>۹</sup> sequences  
<sup>۱۰</sup> vanilla recurrent neural networks  
<sup>۱۱</sup> long term dependencies

## ۳.۲.۲ مدل های زبانی مبتنی بر ترنسفورمر

همان طور که در قسمت پیشین اشاره شد، مدل های زبانی بازگشتی در مدل سازی وابستگی های بلندمدت با مشکل مواجه هستند و به دلیل ماهیت توالی گونه خود، سرعت پردازش آنها نیز بسیار پایین است.

مقاله Attention is All You Need [۵] با معماری نوآورانه خود توانست هر دوی این مشکلات را حل کند. این معماری از مکانیزم توجه<sup>۱۲</sup> استفاده می کند که به مدل اجازه می دهد تا به طور همزمان به تمامی ورودی ها توجه کند و وابستگی های بلندمدت را به راحتی شناسایی کند. به این ترتیب، سرعت پردازش به طور قابل توجهی افزایش می یابد.

علاوه بر این، معماری ترنسفورمر<sup>۱۳</sup> که در شکل ۱.۲ می توانید آن را ببینید، قابلیت پردازش موازی را دارد، زیرا معماری آن ماهیت توالی گونه ندارد. به همین دلیل، با استفاده از پردازنده های گرافیکی<sup>۱۴</sup> می توان پردازش های موازی را انجام داد که سرعت پردازش را به طور چشمگیری بهبود می بخشد.

مدل های مبتنی بر معماری ترنسفورمر سه دسته هستند که در ادامه به بررسی این سه دسته خواهیم پرداخت.

## ۱.۳.۲.۲ مدل های زبانی فقط رمزگذار

مدل های زبانی فقط رمزگذار<sup>۱۵</sup>، تنها از بخش رمزگذار معماری ترنسفورمر که در سمت چپ شکل ۱.۲ قابل مشاهده است، استفاده می کنند. این مدل ها به طور ویژه برای پردازش و درک متن طراحی شده اند و ورودی ها را به یک نمایش داخلی تبدیل می کنند که شامل اطلاعات معنایی و ساختاری متن است.

این نوع مدل ها عمدتاً در وظایفی مانند تحلیل احساسات<sup>۱۶</sup>، دسته بندی متن<sup>۱۷</sup> و استخراج ویژگی ها<sup>۱۸</sup> کاربرد دارند. آن ها به خوبی می توانند الگوهای زبانی و معنایی را شناسایی کرده و اطلاعات مفیدی از داده های متنی استخراج کنند، اما به تنهایی توانایی تولید متن جدید را ندارند.

به عنوان مثال، می توان از BERT [۶] [۷]، که یکی از معروف ترین مدل های زبانی فقط رمزگذار است، یاد کرد.

<sup>۱۲</sup> Attention Mechanism<sup>۱۳</sup> transformer<sup>۱۴</sup> graphical processing unit<sup>۱۵</sup> encoder only language models<sup>۱۶</sup> sentiment analysis<sup>۱۷</sup> text classification<sup>۱۸</sup> feature extraction

### ۲.۳.۲.۲ مدل‌های زبانی فقط رمزگشا

مدل‌های زبانی فقط رمزگشا<sup>۱۹</sup> نوعی از مدل‌های زبانی هستند که به طور خاص برای تولید متن و پیش‌بینی توکن‌های بعدی در یک توالی طراحی شده‌اند. این مدل‌ها تنها از ساختار رمزگشای معماری ترنسفورمر که در سمت راست شکل ۱.۲ قابل مشاهده است، استفاده می‌کنند و به صورت تک‌جهته عمل می‌کنند، به این معنا که برای تولید هر توکن، تنها به توکن‌های قبلی خود در توالی دسترسی دارند.

در این مدل‌ها، هدف اصلی پیش‌بینی توکن بعدی بر اساس توکن‌های قبلی است. به عنوان مثال، اگر ورودی مدل یک جمله باشد، مدل سعی می‌کند کلمه بعدی را پیش‌بینی کند. این نوع از مدل‌ها در کاربردهایی مانند تولید متن، چت‌بات‌ها و ترجمه ماشینی بسیار موثر هستند.

مدل‌های رمزگشا معمولاً با استفاده از داده‌های متنی بزرگ آموزش دیده و توانایی بالایی در تولید متن‌های معنادار و مرتبط دارند. یکی از معروف‌ترین نمونه‌های این دسته از مدل‌ها، مدل GPT<sup>۲۰</sup> [۸] است که توسط OpenAI توسعه یافته است.

### ۳.۳.۲.۲ مدل‌های زبانی رمزگذار-رمزگشا

دل‌های زبانی رمزگذار-رمزگشا<sup>۲۱</sup> نوعی از مدل‌های زبانی هستند که هر دو قسمت معماری ترنسفورمر که در شکل ۱.۲ مشاهده می‌کنید استفاده می‌کند.

این معماری که در مدل‌هایی مانند T5 [۹] به کار گرفته شده در وظایف پیچیده‌ای مانند ترجمه ماشینی، خلاصه‌سازی متن و تولید گفتار کاربرد دارد. به عنوان مثال، در ترجمه ماشینی، بخش رمزگذار جمله‌ای را به زبان مبدا تحلیل کرده و آن را به یک نمایش معنایی تبدیل می‌کند، سپس بخش رمزگشا این نمایش را به زبان مقصد ترجمه می‌کند.

## ۳.۲ سیستم‌های پرسش و پاسخ

سیستم‌های پرسش و پاسخ<sup>۲۲</sup> فناوری‌های هوشمندی هستند که با استفاده از تکنیک‌های پردازش زبان طبیعی<sup>۲۳</sup>، به کاربران این امکان را می‌دهند تا سوالات خود را مطرح کرده و پاسخ‌های دقیق و مرتبط دریافت کنند. این

<sup>۱۹</sup> Decoder-Only Language Models

<sup>۲۰</sup> Generative Pre-trained Transformer

<sup>۲۱</sup> Encoder-Decoder Language Models

<sup>۲۲</sup> Question Answering Systems

<sup>۲۳</sup> Natural Language Processing

سیستم‌ها بر دو نوع هستند استخراجی<sup>۲۴</sup> و تولیدی<sup>۲۵</sup> که در ادامه به بررسی آنها خواهیم پرداخت. [۱۰]

### ۱.۳.۲ سیستم‌های پرسش و پاسخ استخراجی

سیستم‌های پرسش و پاسخ استخراجی به منظور پاسخ‌گویی به سوالات کاربران، به جستجوی اطلاعات در پایگاه‌های داده یا مستندات می‌پردازند و پاسخ‌ها را از متن استخراج می‌کنند. این سیستم‌ها معمولاً از یک مدل زبانی فقط رمزگذار مانند bert استفاده می‌کنند.

### ۲.۳.۲ سیستم‌های پرسش و پاسخ تولیدی

با توسعه و گسترش هوش مصنوعی تولیدکننده<sup>۲۶</sup> سیستم‌های پرسش و پاسخ‌هایی پدید آمدند که در آن برای پاسخ دادن به پرسش کاربر به دانش مدل زبانی تکیه می‌شود. یعنی مدل زبانی با توجه به دانشی که در زمینه پرسش مطرح شده دارد بایستی پاسخ را تولید کند. از آنجایی که در این سیستم‌ها بایستی چیزی تولید شود بنابراین در آن‌ها از مدل‌های زبانی فقط رمزگشا یا مدل‌های زبانی رمزگذار-رمزگشا استفاده می‌گردد. با بهبود دانش پزشکی و توانایی استدلال یک مدل پایه ما نیز در پایان نامه حاضر اقدام به طراحی یک سیستم پرسش و پاسخ تولیدی کرده ایم.

## ۴.۲ شیوه‌های سنجش مدل‌های زبانی

سنجش دانش یک مدل زبانی به ویژه در زمینه پزشکی از اهمیت بالایی برخوردار است، زیرا این فرآیند به شناخت ما از میزان دانش یک مدل زبانی، کمک شایانی می‌کند. در ادامه چندین روش سنجش کیفیت پاسخ‌های مدل‌های زبانی را مطرح خواهیم کرد، ضمناً ما از روش اول و دوم برای سنجش دانش مدل‌های خود استفاده کرده ایم.

<sup>۲۴</sup>extractive  
<sup>۲۵</sup>generative  
<sup>۲۶</sup>intelligence artificial generative

## ۱.۴.۲ سنجش بر اساس میزان پاسخگویی به پرسش و پاسخ های چند گزینه ای

یکی از معیارهای مهم برای سنجش عملکرد مدل های زبانی، ارزیابی توانایی آن ها در پاسخگویی به پرسش های چهار گزینه ای است که از پیش آماده شده اند. این نوع ارزیابی به دلیل ساختار مشخص و استاندارد پرسش ها، امکان مقایسه دقیق تری بین مدل های مختلف را فراهم می آورد. یکی از مجموعه های داده ای که به طور گسترده در این زمینه مورد استفاده قرار می گیرد، مجموعه داده MMLU<sup>۲۷</sup> [۱۱] است. این مجموعه شامل پرسش های متنوعی است که درباره موضوعات مختلفی مانند علوم، پزشکی، ریاضیات، تاریخ، و ادبیات طراحی شده اند.

مجموعه داده MMLU به عنوان یک استاندارد در ارزیابی مدل های زبانی، به محققان و توسعه دهندگان این امکان را می دهد که عملکرد مدل های زبانی خود را در زمینه های مختلف بسنجند و نقاط قوت و ضعف آن ها را شناسایی کنند. پرسش های چهار گزینه ای در MMLU به گونه ای طراحی شده اند که نیاز به درک عمیق و تحلیل دقیق متن دارند. این ویژگی، مدل ها را به چالش می کشد تا نه تنها اطلاعات را بازیابی کنند، بلکه توانایی استدلال و تحلیل خود را نیز به نمایش بگذارند. با استفاده از این معیار، می توان به راحتی مقایسه هایی بین مدل های مختلف انجام داد و پیشرفت های حاصل شده در زمینه هوش مصنوعی و پردازش زبان طبیعی را ارزیابی کرد.

## ۲.۴.۲ سنجش بر اساس نظر مدل داور

یک روش دیگر برای سنجش عملکرد یک مدل زبانی، استفاده از یک مدل زبانی دیگر به عنوان داور است. در این رویکرد، یک مدل زبانی مستقل به عنوان مرجع برای ارزیابی کیفیت پاسخ های تولید شده توسط مدل اصلی مورد استفاده قرار می گیرد. این روش به دلیل قابلیت های بالای مدل های زبانی در پردازش و درک زبان طبیعی، می تواند به طور موثری به ارزیابی دقت و کیفیت پاسخ ها کمک کند.

در این فرآیند، پاسخ های تولید شده توسط مدل اصلی به مدل قاضی ارائه می شود. مدل قاضی می تواند با استفاده از معیارهای مختلفی مانند شباهت معنایی با پاسخ اصلی<sup>۲۸</sup>، صحت اطلاعات، و سازگاری با زمینه، کیفیت پاسخ ها را ارزیابی کند. به عنوان مثال، مدل قاضی می تواند با بررسی تطابق پاسخ ها با اطلاعات موجود در متون معتبر یا داده های آموزشی، نمره ای برای هر پاسخ تولید کرده [۱۲] یا پاسخی را بر پاسخ دیگر ترجیح دهد.

<sup>۲۷</sup> Massive Multitask Language Understanding  
<sup>۲۸</sup> ground truth

### ۳.۴.۲ سنجش بر اساس استنتاج زبان طبیعی

با داشتن یک مجموعه داده مانند K-QA [۱۳]، شامل پاسخ‌های تولید شده توسط انسان که به همراه توضیحات دقیقی دسته‌بندی شده‌اند، این پاسخ‌ها به عنوان "الزامی" <sup>۲۹</sup> یا "مفید" <sup>۳۰</sup> مشخص گشته‌اند. این دسته‌بندی نشان می‌دهد که آیا توضیحات باید به طور ضروری در پاسخ گنجانده شوند یا اینکه اضافی و مفید هستند.

این حقایق اتمی می‌توانند برای به کارگیری یک روش ارزیابی مبتنی بر استنتاج زبان طبیعی <sup>۳۱</sup> استفاده شوند. در این روش، پاسخ مدل به عنوان "مقدمه" <sup>۳۲</sup> و هر یک از توضیحات انسانی به عنوان "فرضیه" <sup>۳۳</sup> در نظر گرفته می‌شود. سپس یک مدل زبانی توانا در حوزه استنتاج زبان طبیعی تعیین خواهد کرد که آیا مقدمه مستلزم <sup>۳۴</sup>، متناقض <sup>۳۵</sup> یا خنثی <sup>۳۶</sup> با فرضیه است.

با انجام این کار روی همه رکوردهای مجموعه داده، دو امتیاز کامل بودن <sup>۳۷</sup> و حقیقت داشتن <sup>۳۸</sup> به صورت زیر به دست می‌آید.

$$S_{comp}(r_i, A'_i) = \frac{\mathbb{1}[r_i \text{ entails } a]}{|A'_i|}$$

$$S_{fact}(r_i, A'_i) = \begin{cases} 0 & \text{if } \exists a \in A_i \text{ s.t. } r_i \text{ contradicts } a \\ 1 & \text{if otherwise} \end{cases}$$

### ۴.۴.۲ سنجش بر اساس امتیاز bert

در این معیار، کیفیت پاسخ‌های تولید شده توسط یک مدل زبانی فقط رمزگذار مانند bert ارزیابی می‌شود. [۱۴] در این فرآیند، پاسخ داده شده با پاسخ صحیح <sup>۳۹</sup> موجود در مجموعه داده مقایسه می‌گردد.

must have<sup>۲۹</sup>  
 nice to have<sup>۳۰</sup>  
 natural language inference<sup>۳۱</sup>  
 premise<sup>۳۲</sup>  
 hypothesis<sup>۳۳</sup>  
 entailment<sup>۳۴</sup>  
 contradiction<sup>۳۵</sup>  
 neutral<sup>۳۶</sup>  
 completeness<sup>۳۷</sup>  
 factuality<sup>۳۸</sup>  
 ground truth<sup>۳۹</sup>



مدل زبانی پاسخ فقط رمزگذار را به دو بردار تبدیل می‌کند: یکی برای پاسخ داده شده و دیگری برای پاسخ صحیح. سپس برای محاسبه امتیاز bert، کافی است میزان شباهت این دو بردار را با یک روش شباهت‌سنجی مانند شباهت کسینوسی<sup>۴۰</sup> محاسبه کنیم.

پس از محاسبه امتیازها برای تمامی پاسخ‌ها در مجموعه داده، این امتیازات جمع‌آوری و میانگین‌گیری می‌شوند. میانگین امتیازها نمای کلی از عملکرد مدل را ارائه می‌دهد و به شناسایی نقاط قوت و ضعف آن کمک می‌کند.

## ۵.۲ یادگیری تقویتی در مدل‌های زبانی

با داشتن یک مدل زبانی اولیه که بتواند برای هر پرسشی پاسخ خود را تولید کند، می‌توانیم یک مدل یا تابع پاداش<sup>۴۱</sup> در نظر بگیریم و آن مدل زبانی را به گونه‌ای به‌روزرسانی کنیم که این تابع پاداش بیشینه گردد. به این صورت که ابتدا داده‌های ترجیحات انسانی (مانند مقایسه دو پاسخ و انتخاب بهتر) جمع‌آوری شده و با آن‌ها یک مدل پاداش آموزش داده می‌شود. سپس، با استفاده از الگوریتم‌های بهینه‌سازی که در ادامه به آن‌ها خواهیم پرداخت، سیاست تولید پاسخ مدل زبانی به تدریج اصلاح می‌گردد تا امتیاز پاداش بالاتری کسب کند. این شیوه باعث می‌شود که مدل زبانی نه تنها با ترجیحات انسانی هم‌راستا شود، بلکه پاسخ‌های مخرب، نادرست، جانبدارانه یا نامناسب کاهش یابد، ایمنی و قابلیت اطمینان افزایش یابد و کیفیت کلی مکالمه از نظر روانی بودن، مفید بودن و جذابیت به طور چشمگیری بهبود یابد. در نهایت، این روش به مدل‌های زبانی کمک می‌کند تا خروجی‌هایی تولید کنند که نه تنها دقیق و مرتبط باشند، بلکه با ارزش‌ها، فرهنگ و انتظارات کاربران انسانی نیز هماهنگ گردند.

### ۱.۵.۲ یادگیری تقویتی با بازخورد انسان یا هوش مصنوعی

برای مشخص کردن ترجیحات انسانی یاد شده علاوه بر انسان<sup>۴۲</sup> [۱۵] می‌توان از بازخورد هوش مصنوعی نیز استفاده کرد؛ بدین صورت که از یک مدل هوش مصنوعی پیشرفته‌تر یا تخصصی (مانند یک مدل زبانی بزرگ‌تر یا یک سیستم ارزیابی خودکار) خواسته می‌شود که به پاسخی که یک مدل زبانی تولید کرده نمره‌ای عددی (مثلاً از ۱ تا ۱۰ بر اساس معیارهایی نظیر صحت، مفید بودن، روانی و ایمنی) بدهد یا آن را در قیاس با پاسخ‌های دیگر تولیدشده توسط همان مدل یا مدل‌های متفاوت رتبه‌بندی کند. این روش که از آن با عنوان یادگیری تقویتی با

<sup>۴۰</sup> cosine similarity

<sup>۴۱</sup> reward model or function

<sup>۴۲</sup> reinforcement learning with human feedback

بازخورد هوش مصنوعی [۱۶] <sup>۴۳</sup> یاد میشود، هزینه‌های جمع‌آوری داده‌های انسانی را به شدت کاهش می‌دهد، سرعت فرآیند را افزایش می‌دهد و امکان مقیاس‌پذیری گسترده‌تری فراهم می‌آورد، هرچند ممکن است به دلیل محدودیت‌های مدل ارزیابی‌کننده، برخی جنبه‌های ظریف فرهنگی، اخلاقی یا زمینه‌ای انسانی را به‌طور کامل پوشش ندهد؛ بنابراین اغلب ترکیبی از بازخورد انسانی و هوش مصنوعی برای دستیابی به بهترین نتایج به کار گرفته می‌شود.

## ۲.۵.۲ الگوریتم‌های بهینه‌سازی مدل زبانی

الگوریتم‌های متعددی برای بهبود عملکرد مدل‌های زبانی بزرگ پیشنهاد شده‌اند که هر یک از رویکردهای متفاوتی در چارچوب یادگیری تقویتی <sup>۴۴</sup> بهره می‌برند. از میان این روش‌ها، می‌توان به الگوریتم بهینه‌سازی سیاست مجاورتی <sup>۴۵</sup> [۱۷] به‌عنوان یکی از پرکاربردترین و پایدارترین روش‌ها اشاره کرد. این الگوریتم با محدود کردن میزان تغییر در سیاست، موجب پایداری در فرآیند آموزش می‌شود. در این رویکرد، ابتدا یک مدل پاداش آموزش داده می‌شود و سپس مدل زبانی تلاش می‌کند تا با بهینه‌سازی مقدار خروجی این مدل پاداش، عملکرد خود را بهبود دهد.

یکی دیگر از این الگوریتم‌ها، بهینه‌سازی سیاست بر پایه پاداش گروهی <sup>۴۶</sup> [۱۸] است. این الگوریتم با معرفی پاداش‌های نسبی درون‌گروهی، تلاش می‌کند مشکلات نوسان و ناپایداری موجود در الگوریتم بهینه‌سازی سیاست مجاورتی را کاهش دهد و از طریق ارزیابی نسبی پاسخ‌ها در یک گروه، بازخورد دقیق‌تر و پایدارتری برای آموزش فراهم کند.

در ادامه، الگوریتم بهینه‌سازی مستقیم ترجیحات <sup>۴۷</sup> [۱۹] به جای تکیه بر یک مدل پاداش بیرونی، سعی دارد تابع هدف درونی <sup>۴۸</sup> را در مدل زبانی بهینه کند. همان‌طور که در تصویر ۲.۲ می‌بینید در این روش، مدل به‌صورت مستقیم از جفت پاسخ‌های ترجیحی (پاسخ تاییدشده و پاسخ ردشده) <sup>۴۹</sup> یاد می‌گیرد و نیازی به تخمین یا آموزش مدل پاداش مجزا ندارد. این ویژگی باعث سادگی و پایداری بیشتر در فرآیند هم‌ترازسازی مدل با ترجیحات انسانی می‌شود. تابع هزینه این الگوریتم به‌صورت زیر تعریف می‌شود

<sup>۴۳</sup> reinforcement learning with AI feedback

<sup>۴۴</sup> Reinforcement Learning

<sup>۴۵</sup> Proximal Policy Optimization (PPO)

<sup>۴۶</sup> Group Reward Policy Optimization (GRPO)

<sup>۴۷</sup> Direct Preference Optimization (DPO)

<sup>۴۸</sup> Intrinsic Objective Function

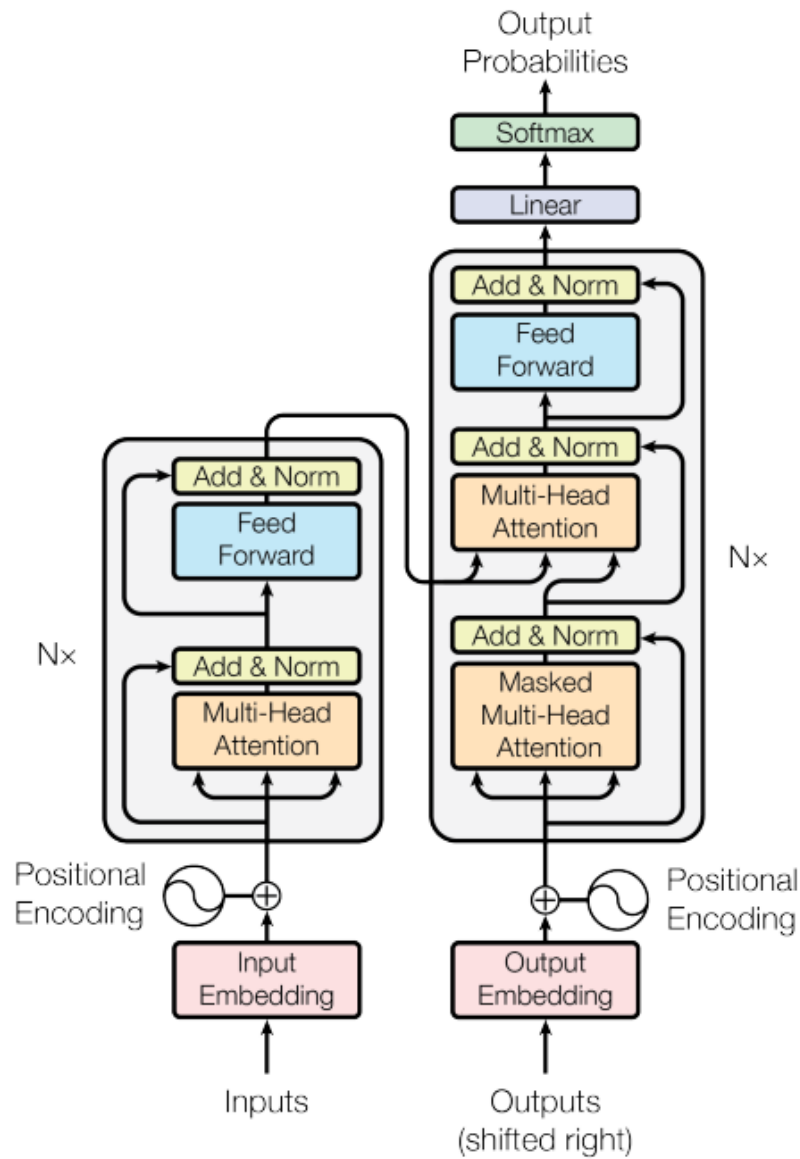
<sup>۴۹</sup> Rejected-Preferred Answer Pairs

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y^+, y^-)} \left[ \log \sigma \left( \beta \left( \log \frac{\pi_{\theta}(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi_{\theta}(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right) \right) \right] \quad (۱.۲)$$


در نهایت، روش بهینه‌سازی مستقیم تابع کیو<sup>۵۰</sup> [۲۰] فرآیند تولید پاسخ را به صورت یک فرآیند تصمیم مارکوف<sup>۵۱</sup> مدل می‌کند و با بهره‌گیری از چارچوب بازیگر-منتقد نرم<sup>۵۲</sup> [۲۱] به طور مستقیم تابع Q را که به وسیله مدل زبانی پارامترگذاری شده است، بهینه می‌سازد. این مدل‌سازی بر پایه‌ی زنجیره تصمیم‌گیری مارکف، نسبت به روش‌های مبتنی بر Bandit از ساختار قوی‌تری برخوردار است و امکان نظارت فرایندی مؤثرتر را فراهم می‌کند. به طور کلی، هر یک از این الگوریتم‌ها با هدف افزایش کارایی، پایداری و هم‌خوانی رفتاری مدل‌های زبانی با ترجیحات انسانی توسعه یافته‌اند و بخش مهمی از پیشرفت‌های اخیر در حوزه‌ی آموزش و هم‌ترازسازی مدل‌های زبانی را تشکیل می‌دهند.

---

Direct Q-function Optimization (DQO)<sup>۵۰</sup>  
 Markov Decision Process (MDP)<sup>۵۱</sup>  
 Soft Actor-Critic (SAC)<sup>۵۲</sup>



شکل ۱.۲: معماری ترنسفورمر



شکل ۲.۲: مقایسه الگوریتم بهینه‌سازی سیاست مجاورتی و بهینه‌سازی مستقیم ترجیحات



## فصل ۳

# بررسی کارهای پیشین

### ۱.۳ مقدمه

همان‌طور که پیش‌تر اشاره شد، علیرغم پیشرفت‌های چشمگیر در توسعه مدل‌های زبانی پزشکی به زبان انگلیسی، مانند توسعه و معرفی مدل‌های MedPalm [۲۲] [۲۳] یا مدل Med-Gemini [۲۴]، متأسفانه در حوزه زبان فارسی هنوز کار چندانی در این زمینه انجام نشده است. این مسئله بدین معناست که ما در حوزه زبان فارسی تقریباً با یک کاغذ سفید روبه‌رو هستیم. در این پایان‌نامه تلاش شده است تا قدمی رو به جلو در جهت توسعه مدل‌های زبانی پزشکی برای زبان فارسی برداشته شود. در ادامه، به بررسی کارهای پیشین انجام‌شده در حوزه زبان انگلیسی، حوزه زبان فارسی و مدل‌های دارای قابلیت دلیل‌آوری خواهیم پرداخت.

### ۲.۳ کارهای پیشین در حوزه زبان انگلیسی

#### ۱.۲.۳ مدل‌های MedPaLM

مدل‌های MedPaLM یکی از مدل‌های زبانی پزشکی بزرگ<sup>۱</sup> است که توسط تیم تحقیقاتی گوگل برای کاربرد های پزشکی توسعه داده شده است. این مدل با استفاده از داده‌های تخصصی پزشکی و بالینی آموزش

---

<sup>۱</sup>large medical language models

دیده است. هدف اصلی این خانواده از مدل های زبانی پزشکی پاسخ گویی به پرسش های پزشکی با دقت بالا، کمک به پزشکان در تصمیم گیری های بالینی، و تسهیل دسترسی به اطلاعات پزشکی برای کاربران است. نسخه های مختلف این مدل، مانند MedPaLM و MedPaLM2، توانایی های قابل توجهی در درک و تحلیل زبان تخصصی پزشکی نشان داده اند و به عنوان یک ابزار نوین در حوزه هوش مصنوعی پزشکی شناخته می شوند. این مدل ها با استفاده از آزمون های استاندارد پزشکی (مانند USMLE) ارزیابی شده و توانسته اند عملکردی نزدیک به سطح متخصصین پزشکی ارائه دهند. مدل MedPaLM2 به عنوان یک گام مهم در جهت توسعه مدل های زبان تخصصی در حوزه سلامت و پزشکی شناخته می شود.

### ۲.۲.۳ مدل ChatDoctor

مدل ChatDoctor [۲۵] یکی از برجسته ترین تلاش ها در حوزه توسعه مدل های زبانی پزشکی است که شباهت قابل توجهی به فاز نخست پایان نامه حاضر دارد. تیم توسعه دهنده این مدل، داده های آموزشی خود را از دو پلتفرم آنلاین پرسش و پاسخ پزشکی به نام های HealthcareMagic و iCliniq جمع آوری کرده اند. این تیم ابتدا بیش از دویست هزار جفت پرسش و پاسخ پزشکی از این منابع گردآوری کرده و سپس با اعمال فیلترهایی بر اساس طول و کیفیت پاسخ ها، مجموعه ای با کیفیت بالا شامل صد هزار جفت پرسش و پاسخ نهایی ایجاد کرده اند. داده های مذکور به عنوان پایه ای برای آموزش و تنظیم دقیق<sup>۲</sup> مدل LLaMa [۲۶] مورد استفاده قرار گرفته اند تا مدلی توانمند در تولید اطلاعات پزشکی دقیق و مرتبط ایجاد شود.

علاوه بر این، این مدل از رویکرد تولید مبتنی بر بازبازی اطلاعات<sup>۳</sup> بهره برده است. این رویکرد به مدل امکان می دهد تا به اطلاعات جدید و خارجی دسترسی پیدا کرده و آن ها را به طور مؤثر در پاسخ های خود ادغام کند. چنین رویکردی موجب ارتقای عملکرد کلی سیستم شده و توانایی مدل در تولید پاسخ هایی دقیق تر و مرتبط تر را به طور چشمگیری بهبود بخشیده است.

### ۳.۲.۳ مدل های Meerkat

مدل های Meerkat [۲۷] یکی دیگر از تلاش های برجسته در حوزه توسعه مدل های زبانی پزشکی است. این پروژه با استخراج زنجیره های تفکر<sup>۴</sup> از کتاب های درسی پزشکی و تنظیم دقیق یک مدل زبانی پایه با استفاده از این داده ها، همراه با مجموعه داده های مکمل دیگر، به وجود است. همانند فاز دوم پایان نامه حاضر هدف

<sup>۲</sup> fine-tuning

<sup>۳</sup> Retrieval-Augmented Generation (RAG)

<sup>۴</sup> chain of thought

اصلی Meerkat تمرکز بر فرآیندهای استدلالی است که در تصمیم‌گیری‌های پزشکی نقش دارند. این مدل تلاش کرده است تا نه تنها اطلاعات پزشکی دقیق ارائه دهد، بلکه فرآیندهای شناختی و تصمیم‌گیری متخصصان حوزه سلامت را شبیه‌سازی کند. به همین دلیل، Meerkat به عنوان مدلی برای تعاملات پیچیده‌تر و آگاهانه‌تر در حوزه پزشکی معرفی شده است.

### ۴.۲.۳ مدل MedMobile

MedMobile [۲۸] تلاشی دیگر در حوزه مدل‌های زبانی کوچک پزشکی است. برای توسعه این مدل زبانی کوچک، مدل Phi-3-mini [۲۹] به عنوان مدل پایه<sup>۵</sup> استفاده از ترکیبی از داده‌های مصنوعی و تولیدشده توسط انسان تنظیم دقیق<sup>۶</sup> شده است تا عملکردی بهینه و مناسب برای اجرا روی دستگاه‌های همراه مانند موبایل ارائه دهد. با تمرکز بر نیازهای خاص کاربران دستگاه‌های همراه، MedMobile تلاش کرده است مدلی کارآمد و مؤثر فراهم کند که دسترسی به اطلاعات پزشکی باکیفیت را در هر زمان و مکان به صورت محلی<sup>۷</sup> ممکن می‌سازد.

## ۳.۳ کارهای پیشین در حوزه زبان فارسی

همان‌طور که پیش‌تر اشاره شد، تحقیقات محدودی بر روی مدل‌های زبانی پزشکی فارسی تمرکز داشته‌اند که این امر نشان‌دهنده شکاف قابل توجهی در منابع موجود برای جامعه پزشکی فارسی‌زبان است. علاوه بر این، پژوهش‌های بسیار اندک موجود در این زمینه، به طور کامل در مورد مجموعه داده‌ها، مدل‌ها و کدهای خود متن بسته<sup>۸</sup> هستند.

از سوی دیگر، تمامی این تلاش‌ها عمدتاً بر روی راهکارهای استخراجی<sup>۹</sup> متمرکز بوده‌اند که هدفشان بازیابی اطلاعات مرتبط از منابع از پیش تعریف شده است، به جای استفاده از رویکردهای تولیدی<sup>۱۰</sup> که قادر به تولید پاسخ‌های آگاه از زمینه باشند.

baseline model<sup>۵</sup>

fine tune<sup>۶</sup>

local<sup>۷</sup>

closed-source<sup>۸</sup>

extractive<sup>۹</sup>

generative<sup>۱۰</sup>



### ۱.۳.۳ مدل Sina-bert

شاید اولین و برجسته ترین مدل زبانی پزشکی فارسی، Sina-BERT [۳۰] باشد که شامل آموزش یک مدل BERT [۳۱] با استفاده از یک پیکره خزش شده<sup>۱۱</sup> همراه با مجموعه داده پرسش و پاسخ پزشکی فارسی است که به طور خاص برای کاربردهای مختلف از جمله پاسخ به سوالات پزشکی، تحلیل احساسات پزشکی و بازیابی سوالات پزشکی توسعه یافته اند.

Sina-BERT در میان تلاش های متمرکز بر زبان فارسی، بیشترین شباهت را به فاز نخست پایان نامه حاضر دارد؛ با این تفاوت که از مدل برت<sup>۱۲</sup> یک مدل زبانی مبتنی بر رمزگذار<sup>۱۳</sup> به عنوان مدل پایه استفاده می کند. این انتخاب تولید پاسخ توسط این مدل را عملاً ناممکن می سازد، چرا که برت عمدتاً برای درک و استخراج اطلاعات طراحی شده است نه برای تولید پاسخ.

### ۲.۳.۳ سیستم پرسش و پاسخ پزشکی دکتر ویسی و همکاران

یکی از آثار برجسته در حوزه پردازش زبان طبیعی، سیستم پرسش و پاسخ پزشکی فارسی است که توسط دکتر ویسی و همکارانش [۳۲] طراحی و توسعه داده شده است. این سیستم به طور کلی شامل سه ماژول اصلی است: پردازش پرسش، بازیابی سند و استخراج پاسخ. ماژول پردازش پرسش وظیفه تحلیل و اصلاح پرسش های کاربران را برعهده دارد تا پرسش ها به شکل بهینه برای مراحل بعدی آماده شوند. سپس، ماژول بازیابی سند با استفاده از الگوریتم های پیشرفته، اسناد پزشکی مرتبط را از میان داده های از پیش تعیین شده پیدا می کند. در نهایت، ماژول استخراج پاسخ با شناسایی دقیق اطلاعات موجود در اسناد بازیابی شده، مناسب ترین پاسخ ها را استخراج کرده و به کاربران ارائه می دهد. این سیستم نه تنها به طور مؤثر به پرسش های پزشکی پاسخ می دهد، بلکه ساختار ماژولار آن امکان بهبود و توسعه در آینده را نیز فراهم می سازد.

### ۳.۳.۳ پایان نامه کارشناسی ارشد خانم لیلا دارابی

مشابه به این دو اثر، پیشین لیلا دارابی در پایان نامه ارشد خود [۳۳] از مدل هایی مانند Pars-BERT [۳۴] برای بازیابی پاسخ های مرتبط استفاده کرده است. رویکرد او شامل یافتن سوالات مشابه برای مدیریت پرسش های تکراری و به کارگیری استراتژی های ارزیابی دقیق و سهل گیرانه برای پاسخ های دقیق یا تقریبی می شود. علاوه بر

<sup>۱۱</sup>crawled  
<sup>۱۲</sup>BERT  
<sup>۱۳</sup>encoder-based

این، روش‌های طبقه‌بندی و شناسایی موجودیت‌های نامدار<sup>۱۴</sup> برای بهبود ارتباط پاسخ‌ها از طریق دسته‌بندی سوالات و شناسایی موجودیت‌های پزشکی مانند نام داروها و بیماری‌ها به کار گرفته می‌شوند.

## ۴.۳ بهبود قابلیت دلیل آوری در حوزه پزشکی

### ۱.۴.۳ مدل MedSSS

یکی از تلاش‌های برجسته در این حوزه، مدل زبانی MedSSS است. [۳۵] هدف اصلی این چارچوب، ارتقای توانایی استدلال مدل‌های پزشکی از طریق دقت‌بخشی و ریزسازی مراحل میانی استدلال بین پرسش و پاسخ نهایی است. همانطوری که در تصویر ۱.۳ برای دستیابی به این هدف، پژوهشگران از الگوریتم جست‌وجوی درختی مونت‌کارلو<sup>۱۵</sup> [۳۶] استفاده کردند. این الگوریتم بر روی مجموعه داده‌هایی از پرسش‌های چندگزینه‌ای پزشکی به کار گرفته شد تا مسیرهای استدلالی ساختارمند و مرحله به مرحله تولید شود؛ مسیرهایی که نشان می‌دهند مدل چگونه از پرسش به پاسخ درست می‌رسد. بر اساس این رویکرد، نویسندگان به صورت مصنوعی سه مجموعه داده مجزا ساختند که هر یک در مرحله‌ای خاص از آموزش مدل نقش دارد:

۱. مجموعه داده تنظیم دقیق نظارت شده: برای آموزش مدل سیاستی<sup>۱۶</sup> از طریق نمونه‌های استدلال با کیفیت.
۲. مجموعه داده پاسخ‌های ترجیح داده شده و رد شده: برای آموزش مبتنی بر بهینه‌سازی مستقیم ترجیحات<sup>۱۷</sup> تا مدل بتواند میان پاسخ‌های بهتر و ضعیف‌تر تمایز قائل شود.
۳. مجموعه داده برچسب‌های نرم دوسویه: جهت تنظیم دقیق مدل پاداش فرآیند<sup>۱۸</sup> که به جای تمرکز صرف بر پاسخ نهایی، کیفیت فرآیند استدلال مدل را ارزیابی می‌کند.

در نهایت، مدل سیاستی آموزش دیده به عنوان موتور اصلی استدلال در فرآیند تولید پاسخ عمل می‌کند، در حالی که مدل پاداش فرآیند آموزش دیده نقش راهنما و ارزیاب را در هنگام تولید ایفا می‌نماید. این مدل دوم کمک می‌کند تا فرآیند استدلال مدل به صورت پیوسته اصلاح شده و از نظر منطق، انسجام و درستی پزشکی ارزیابی گردد.

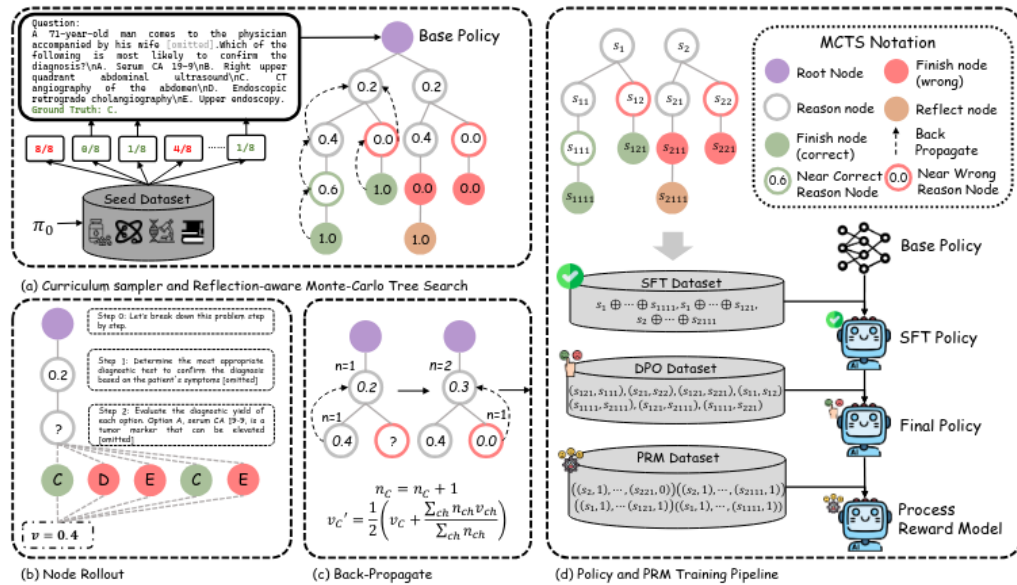
<sup>۱۴</sup> Named Entity Recognition (NER)

<sup>۱۵</sup> monte carlo tree search

<sup>۱۶</sup> policy model

<sup>۱۷</sup> direct preference optimization

<sup>۱۸</sup> process reward model



شکل ۱.۳: بلوک دیاگرام مدل medsss

### ۲.۴.۳ مدل MedReason

یکی دیگر از دستاوردهای مهم در زمینه توسعه مدل‌های زبانی استدلال‌محور در حوزه پزشکی، مدل زبانی MedReason است. [۳۷] در این پژوهش، نویسندگان از یک گراف دانش ساختاریافته پزشکی<sup>۱۹</sup> بهره گرفتند تا جفت‌های متداول پرسش و پاسخ را به مسیرهای استدلالی دقیق و گام‌به‌گام تبدیل کنند. هر مسیر استدلالی، زنجیره‌ای منطقی از گام‌های مرتبط را نشان می‌داد که یک پرسش بالینی را به پاسخ صحیح آن متصل می‌کرد و این ارتباط بر پایه روابط دانش پزشکی مانند علائم، تشخیص‌ها، درمان‌ها و سازوکارهای فیزیولوژیکی بنا شده بود. پژوهشگران با ساخت چنین مجموعه داده‌ای غنی شده از استدلال، توانستند یک مدل زبانی پایه را بر اساس این نمونه‌های ساختاریافته تنظیم دقیق کنند. این رویکرد سبب شد تا توانایی مدل در انجام وظایف پیچیده و استدلال‌محور در حوزه پزشکی به طور قابل توجهی بهبود یابد. نتایج حاصل نشان داد که نظارت مبتنی بر استدلال استخراج شده از گراف‌های دانش<sup>۲۰</sup>، می‌تواند نقش مؤثری در ارتقای دقت و قابلیت تحلیل مدل‌های زبانی پزشکی ایفا کند.

یافته‌های حاصل از پژوهش MedReason همچنین بر اهمیت نمایش‌های ساختاریافته استدلال در بهبود تفسیرپذیری<sup>۲۱</sup> و عمق تحلیلی مدل‌های زبانی پزشکی تأکید می‌کنند. این چارچوب نشان می‌دهد که ترکیب دانش ساختاریافته با فرآیند یادگیری زبانی، می‌تواند پلی میان درک داده‌محور و استدلال مبتنی بر دانش در سامانه‌های

<sup>۱۹</sup> Medical Knowledge Graph<sup>۲۰</sup> Knowledge Graph-based Reasoning Supervision<sup>۲۱</sup> Interpretability

هوش مصنوعی پزشکی ایجاد کند.

### ۳.۴.۳ مدل HuatuoGPT-o1

یکی از پیشرفت‌های مهم دیگر در توسعه مدل‌های زبانی استدلال‌محور پزشکی، چارچوبی با نام HuatuoGPT-o1 است. [۳۸] در این پژوهش، نویسندگان یک چارچوب استدلال با هدایت اعتبارسنجی<sup>۲۲</sup> را معرفی کردند که هدف آن بهبود انسجام منطقی و دقت مسیرهای استدلالی تولیدشده توسط مدل است. در این رویکرد، یک مدل اعتبارسنج<sup>۲۳</sup> به عنوان جز کنترلی و ارزیاب به کار گرفته شد تا در حین فرآیند تولید استدلال، عملکرد مدل سیاستی را ارزیابی و هدایت کند. این مکانیزم اطمینان حاصل می‌کند که هر مسیر استدلالی تولیدشده با واقعیت‌های علمی و اصول پذیرفته‌شده پزشکی سازگار باشد. با استفاده از فرآیند فیلترسازی و پالایش مسیرهای استدلال از طریق این مدل اعتبارسنج، پژوهشگران موفق به تولید یک مجموعه داده با کیفیت متشکل از دنباله‌های استدلالی تأییدشده شدند.

در گام بعد، نویسندگان از ترکیب دو رویکرد آموزش، شامل تنظیم دقیق نظارت‌شده و یادگیری تقویتی، برای آموزش مدل زبانی پایه با استفاده از داده‌های اعتبارسنجی‌شده بهره بردند. این رویکرد دوگانه باعث شد مدل نه تنها رفتارهای استدلالی صحیح را تقلید کند، بلکه اصول استدلال منطقی را از طریق بهینه‌سازی مبتنی بر پاداش درونی‌سازی نماید. نتایج حاصل از این پژوهش نشان داد که مدل HuatuoGPT-o1 در طیف وسیعی از وظایف پزشکی، از جمله پاسخ‌گویی به پرسش‌های بالینی و استدلال تشخیصی، بهبود چشمگیری در دقت و قابلیت اعتماد از خود نشان می‌دهد. این دستاورد اهمیت چارچوب‌های یادگیری هدایت‌شده با اعتبارسنج را در ارتقای مدل‌های زبانی استدلالی در حوزه پزشکی برجسته می‌سازد و مسیر توسعه سامانه‌های هوش مصنوعی با استدلال قابل اعتماد را هموار می‌کند.

## ۵.۳ بهبود قابلیت دلیل آوری در حوزه‌های دیگر

### ۱.۵.۳ مدل Deepseek

یکی از تاثیرگذارترین پژوهش‌های اخیر در حوزه گسترده استدلال در هوش مصنوعی، مدل DeepSeek-R است. [۳۹] این مدل بر پایه نسخه پایه DeepSeek-V3-Base توسعه یافته و با هدف ارتقای صریح قابلیت‌های

Verification-Guided Reasoning Framework<sup>۲۲</sup>  
Verifier Model<sup>۲۳</sup>

استدلالی، چارچوبی مبتنی بر یادگیری تقویتی را به کار می‌گیرد. در این چارچوب، نویسندگان از الگوریتم بهینه سازی سیاست بر پایه پاداش گروهی<sup>۲۴</sup> استفاده کردند تا فرآیند یادگیری تقویتی را به گونه‌ای هدایت کنند که عملکرد استدلالی مدل به صورت هدفمند بهبود یابد.

در این رویکرد، تابع پاداش به طور ویژه طراحی شد تا کیفیت استدلال مدل را ارزیابی کرده و آن را به حداکثر برساند. نتایج نشان داد که مدل DeepSeek-R از طریق این الگوی آموزشی، پیشرفت چشمگیری در منطق استدلالی و دقت حل مسئله در مجموعه‌ای از معیارهای استاندارد<sup>۲۵</sup> به دست آورده است. با این حال، استفاده از یادگیری تقویتی بدون کنترل کامل، پیامدهایی جانبی نیز به همراه داشت؛ از جمله کاهش روانی زبان، افت انسجام جمله‌ای، و افزایش بروز پدیده اختلاط زبانی<sup>۲۶</sup> در خروجی مدل.

برای رفع این چالش‌ها، پژوهشگران مرحله‌ای تکمیلی به فرآیند آموزش افزودند. در این مرحله، مقدار اندکی داده نظارت شده اولیه<sup>۲۷</sup> مورد استفاده قرار گرفت و یک زنجیره آموزشی چندمرحله‌ای<sup>۲۸</sup> طراحی شد. این فاز تنظیم دقیق کمک کرد تا ضمن حفظ توانمندی‌های استدلالی کسب شده از یادگیری تقویتی، روانی و خوانایی زبان طبیعی نیز بازگردانده شود.

در نتیجه، مدل DeepSeek-R به عنوان گامی اساسی در مسیر توسعه هوش مصنوعی استدلال محور مطرح شد؛ مدلی که نشان می‌دهد یادگیری تقویتی می‌تواند به طور قابل توجهی توانایی استدلال را ارتقا دهد، مشروط بر آنکه با تنظیم دقیق و نظارت زبانی هدفمند ترکیب شود تا تعادل میان کیفیت زبانی و عمق استدلالی حفظ گردد.

### ۲.۵.۳ چهارچوب Thought Preference Optimization

یکی از دستاوردهای قابل توجه در زمینه بهبود توانایی استدلال در مدل‌های زبانی، روش بهینه سازی ترجیحات فکری<sup>۲۹</sup> است. [۴۰] در این پژوهش، نویسندگان چارچوبی مبتنی بر ترجیحات را برای ارتقای کیفیت استدلال در مدل‌های زبانی پیشنهاد کردند.

همانطور که در تصویر ۲.۳ می‌بینید در این رویکرد، هنگامی که یک پرسش به مدل ارائه می‌شود، ابتدا مدل چندین مسیر استدلالی متفاوت را به عنوان پاسخ‌های بالقوه تولید می‌کند. سپس این مسیرهای استدلالی توسط یک مدل داور<sup>۳۰</sup> مورد ارزیابی قرار می‌گیرند. مدل داور با بررسی صحت منطقی، انسجام و کیفیت استدلال،

<sup>۲۴</sup>group reward policy optimization

<sup>۲۵</sup>Benchmarks

<sup>۲۶</sup>Language Mixing

<sup>۲۷</sup>Cold-start Supervised Data


<sup>۲۸</sup>Multi-stage Training Pipeline

<sup>۲۹</sup>Thought Preference Optimization (TPO)

<sup>۳۰</sup>Judge Model

بهترین و ضعیف‌ترین نمونه‌ها را از میان خروجی‌ها شناسایی می‌کند. در گام بعد، جفت‌های انتخاب‌شده از پاسخ‌های «بهتر» و «ضعیف‌تر» برای آموزش مدل پایه با استفاده از روش بهینه‌سازی مستقیم ترجیحات<sup>۳۱</sup> به کار گرفته می‌شوند. این فرآیند باعث می‌شود مدل به صورت تدریجی مسیرهای استدلالی باکیفیت‌تر را ترجیح دهد و یاد بگیرد که استدلال‌هایی منطقی‌تر، پیوسته‌تر و نزدیک‌تر به شیوه تفکر انسانی تولید کند.

نتایج این پژوهش نشان داد که به کارگیری چارچوب TPO موجب بهبود چشمگیری در کیفیت استدلال مدل‌های زبانی می‌شود. این یافته بیانگر آن است که ارتقای توانایی استدلالی مدل‌ها تنها از طریق افزایش مقیاس یا داده‌های آموزشی نظارت‌شده حاصل نمی‌شود، بلکه می‌توان با بهره‌گیری از سازوکارهای یادگیری مبتنی بر ترجیح و بازخورد ارزیابانه، به بهبودی مؤثرتر و پایدارتر در فرآیند استدلال مدل دست یافت.



شکل ۲.۳: بلوک دیاگرام Thought Preference Optimization

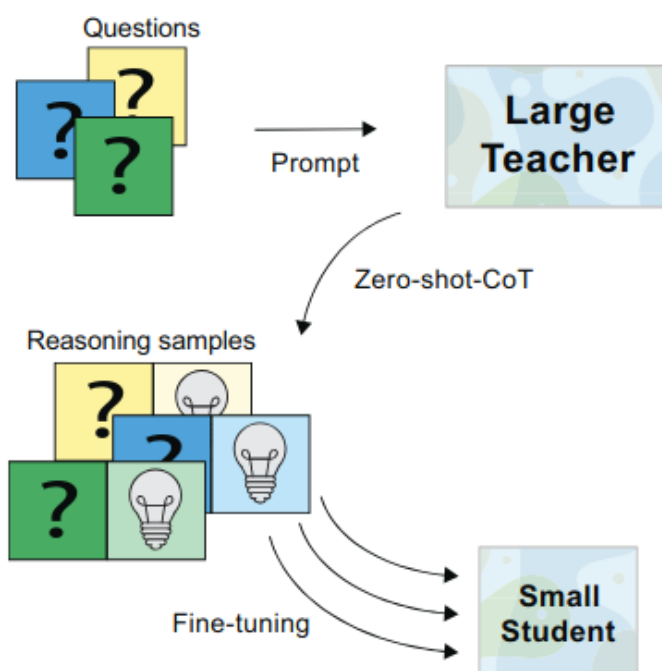
### ۳.۵.۳ آموزش استدلال مدل‌های بزرگ به مدل‌های کوچک

یکی از پژوهش‌های مرتبط در زمینه انتقال توانایی استدلال میان مدل‌های زبانی، توسط آقای هو و همکاران انجام شده است. [۴۱] در این پژوهش، نویسندگان به بررسی چگونگی انتقال قابلیت‌های استدلالی از مدل‌های زبانی بزرگ به مدل‌های کوچک‌تر پرداختند. ایده اصلی این رویکرد بر آن استوار است که مدل‌های کوچک‌تر می‌توانند از داده‌های تولیدشده توسط مدل‌های بزرگ‌تر، که از قدرت استدلالی بالاتری برخوردارند، برای بهبود عملکرد خود بهره ببرند.

همانطور که در تصویر ۳.۳ در این روش، ابتدا یک مدل زبانی بزرگ با عملکرد استدلالی قوی‌تر به تولید مسیرهای استدلالی<sup>۳۲</sup> و جفت‌های پرسش و پاسخ می‌پردازد. این خروجی‌ها به عنوان داده‌های آموزشی باکیفیت و مبتنی بر استدلال، برای تنظیم دقیق مدل کوچک‌تر مورد استفاده قرار می‌گیرند. بدین ترتیب، مدل کوچک‌تر از این طریق، الگوهای حل مسئله و استراتژی‌های استدلالی را از مدل بزرگ‌تر فرا می‌گیرد.

<sup>۳۱</sup> Direct Preference Optimization (DPO)  
<sup>۳۲</sup> Reasoning Trajectories

نتایج نشان داد که مدل کوچک‌تر پس از این آموزش هدفمند، توانست عملکردی رقابتی در وظایف استدلالی از خود نشان دهد؛ در حالی که هزینه محاسباتی آن به‌طور قابل‌توجهی کمتر از مدل بزرگ‌تر بود. این پژوهش اهمیت استفاده از داده‌های مصنوعی مبتنی بر استدلال و یادگیری انتقالی هدفمند را در بهبود بازده و کارایی مدل‌های زبانی کوچک‌تر برجسته می‌کند. به عبارت دیگر، توانایی استدلال را می‌توان به‌صورت مؤثر میان مدل‌هایی با مقیاس‌های متفاوت منتقل کرد، مشروط بر آنکه فرآیند تنظیم دقیق بر اساس داده‌های تولیدشده از مدل‌های استدلالی پیشرفته انجام گیرد.



شکل ۳.۳: بلوک دیاگرام آموزش دلیل آوری توسط مدل بزرگ‌تر به مدل کوچک‌تر

## فصل ۴

# جمع آوری دادگان

### ۱.۴ مقدمه

همان طور که پیشتر اشاره شد، در حوزه زبان فارسی نه مدل های عمومی موجود هستند و نه مجموعه داده های مناسب برای استفاده در پژوهش های مرتبط. بنابراین، برای پیشبرد این پایان نامه، ناچار به جمع آوری دادگان اختصاصی بودیم تا بتوانیم نیازهای تحقیقاتی را برآورده کنیم. فرآیند جمع آوری دادگان شامل روش هایی مانند ترجمه<sup>۱</sup> داده های موجود از زبان های دیگر و خزش داده ها از منابع مختلف برای ایجاد یک مجموعه داده جامع و کاربردی بوده است.

### ۲.۴ معرفی پیکره پزشکی فارسی

عدم وجود یک پیکره پزشکی اختصاصی به زبان فارسی، چالشی قابل توجه برای پژوهشگران و توسعه دهندگانی ایجاد می کند که هدفشان توسعه مدل های پزشکی در زبان فارسی است. بدون داده های متنی باکیفیت و تخصصی که برای آموزش مدل های هوش مصنوعی ضروری است، این تلاش ها ممکن است با موانع روبه رو شوند و در نهایت بر توسعه فناوری ها و راه حل های پیشرفته پزشکی مناسب برای جمعیت فارسی زبان تاثیر بگذارند. برای حل این مشکل، ما یک مجموعه داده جامع شامل تقریباً نود میلیون توکن و حدود صد هزار مقاله گردآوری کرده ایم.<sup>۲</sup>

<sup>۱</sup> ترجمه می تواند به صورت ماشینی یا انسانی انجام شود.

<sup>۲</sup> برای بازدید از این پیکره می توانید به آدرس [huggingface.co/datasets/gaokerena/medical\\_corpus](https://huggingface.co/datasets/gaokerena/medical_corpus) مراجعه کنید



گارسیا فررو و همکاران [۴۲] مجموعه‌ای از متون پزشکی را که به چهار زبان (انگلیسی، فرانسوی، اسپانیایی و ایتالیایی) اختصاص داشت، گردآوری کردند که می‌توان آن را همانطور که در جدول ۱.۴ نشان داده شده است با مجموعه ما مقایسه کرد. پیکره ای که ما گردآوری کرده ایم از مجله های آنلاین پزشکی خزش شده است که می‌توانید سهم هر مجله در این پیکره را در تصویر ۱.۴ ببینید.

زبان	تعداد پرسش و پاسخ ها	گردآورنده
انگلیسی	1.1B	I. Garcia Ferrero et al.
اسپانیایی	950M	I. Garcia Ferrero et al.
فرانسوی	675M	I. Garcia Ferrero et al.
ایتالیایی	143M	I. Garcia Ferrero et al.
فارسی	90M	ما

جدول ۱.۴: مقایسه پیکره گردآوری شده با پیکره های گردآوری شده توسط I. Garcia Ferrero et al.

### ۳.۴ معرفی مجموعه داده MF3QA

گردآوری یک مجموعه داده واقعی از پرسش و پاسخ های پزشک و بیمار اهمیت بسیاری در ارتقا توانایی های مدل های زبانی در حوزه بهداشت و درمان دارد. چنین مجموعه داده ای به مدل ها امکان می دهد تا اطلاعات ارزشمندی را که از تعاملات واقعی میان ارائه دهندگان خدمات بهداشتی و بیماران به دست می آید، بیاموزند. با تحلیل این تعاملات واقعی، مدل های زبانی می توانند به درک جزئیات اصطلاحات پزشکی، نگرانی های بیماران، و زمینه پیرامون سؤالات بهداشتی دست یابند. علاوه بر این، این مجموعه داده مدل ها را قادر می سازد نه تنها محتوای دقیق پاسخ ها، بلکه ساختار و لحن مناسب برای پاسخ دهی به سؤالات را نیز یاد بگیرند. این فرآیند دوگانه یادگیری از اهمیت بالایی برخوردار است، زیرا به مدل امکان می دهد پاسخ هایی دقیق، همدلانه و متناسب با زمینه ارائه دهد و در نهایت ارتباط و پشتیبانی از بیماران در محیط های پزشکی را بهبود بخشد.

در این زمینه، یانگ لیو در مقاله مروری<sup>۳</sup> خود [۴۳] به چندین مجموعه داده واقعی پرسش و پاسخ پزشک و بیمار اشاره کرده است، مقایسه ای میان این مجموعه دادگان و مجموعه داده ما در جدول ۲.۴ ارائه شده است.

<sup>۳</sup>survey

نام مجموعه داده	زبان	تعداد پرسش و پاسخ ها	گردآورنده
ChatDoctor	انگلیسی	100K	[۲۵] Yunxiang Li et al.
CMtMedQA	چینی	68K	[۴۴] Songhua Yang et al.
DISC-Med-SFT	چینی	465K	[۴۵] Zhijie Bao et al.
HuatuoGPT-sft-data-v1	چینی	226K	[۴۶] Hongbo Zhang et al.
Huatuo-26M	چینی	26M	[۴۷] Jianquan Li et al.
MedDialog	چینی و انگلیسی	3.66M	[۴۸] Guangtao Zeng et al.
Medical-Meadow	انگلیسی	160k	[۴۹] Tianyu Han et al.
MF3QA	فارسی	20k	ما

جدول ۲.۴: مقایسه مجموعه داده های پرسش و پاسخ آزاد پزشکی با مجموعه داده گردآوری شده

### ۱.۳.۴ منابع مجموعه داده MF3QA


همان طور که در شکل ۲.۴ نشان داده شده است، برای گردآوری مجموعه داده MF3QA مراحل مختلفی طی شده است. در بخش آموزش، پرسش و پاسخ های بیمار و پزشک موجود در تالارهای گفت و گوی پزشکی فارسی<sup>۴</sup> "دکترهست" و "نی نی بان" را خزش کرده ایم. برای بخش اعتبارسنجی، تنها از داده های موجود در سایت "نی نی بان" استفاده کرده ایم تا انسجام بیشتری در این بخش حاصل شود. در بخش آزمایش نیز، از سایت های "دکتر یاب" و "ایزوویت" بهره برده ایم و به منظور اطمینان از تنوع داده ها، مجموعه داده پرسش و پاسخ K-QA [۱۳] را ترجمه کرده و به این بخش اضافه کرده ایم.

### ۲.۳.۴ فیلتر کردن رکورد های مجموعه داده MF3QA

در پایان نامه حاضر، بیش از صد و هشتاد هزار جفت پرسش و پاسخ از تالارهای گفت و گوی پزشکی فارسی گردآوری شده است. این جفت های پرسش و پاسخ، چه به صورت دستی<sup>۵</sup> و چه به صورت خودکار، مورد بررسی

<sup>۴</sup>Persian medical forums

<sup>۵</sup>فرآیند فیلتر کردن دستی توسط خانم زهرا کاظمی و آقای میلاد توکلی، از دانشجویان کارشناسی مهندسی کامپیوتر، انجام شده است.



شکل ۱.۴: سهم هر مجله در پیکره پزشکی فارسی گردآوری شده

قرار گرفته و جفت‌هایی که حاوی اطلاعات مفید نبودند، حذف شده‌اند.<sup>۶</sup>

این رویکرد مشابه کاری است که یونشیانگ لی و همکارانش برای توسعه مدل زبانی Chat Doctor انجام داده‌اند. [۲۵] آنها نیز داده‌ها را از تالارهای گفت‌وگوی پزشکی انگلیسی استخراج کرده و نیمی از جفت‌های پرسش و پاسخ را بر اساس طول پاسخ‌ها کنار گذاشته‌اند.<sup>۷</sup>، چراکه پاسخ‌های کوتاه‌تر معمولاً حاوی اطلاعات مفیدی نیستند. با این حال، ما با چالش بزرگ‌تری مواجه بودیم؛ پزشکان فارسی‌زبان معمولاً پاسخ‌های بسیار کوتاه‌تری نسبت به هم‌تایان انگلیسی خود ارائه می‌دهند. این امر ما را مجبور کرد تا بیش از هشتاد درصد از رکوردهای پرسش و پاسخ خود را برای تضمین کیفیت کنار بگذاریم.

<sup>۶</sup> برای بازدید از مجموعه داده MF3QA به آدرس [huggingface.co/datasets/gaokerena/MF3QA](https://huggingface.co/datasets/gaokerena/MF3QA) و برای بازدید از صد و هشتاد هزار جفت پرسش و پاسخ خزش شده به آدرس [huggingface.co/datasets/gaokerena/MF3QA\\_uncleaned](https://huggingface.co/datasets/gaokerena/MF3QA_uncleaned) مراجعه کنید.

<sup>۷</sup> فیلتر کردن آنها صرفاً بر اساس طول پاسخ بوده ولی همانطور که پیشتر اشاره شد ما برای فیلتر کردن از روش‌های دستی نیز استفاده کرده ایم.



شکل ۲.۴: سهم هر تالار گفتگو در مجموعه داده MF3QA

#### ۱.۲.۳.۴ خزش از تالار گفتگو دکترهست

خزش از تالار گفتگوی “دکترهست”، که اصلی ترین منبع مجموعه داده MF3QA است، با چالش خاصی همراه بود. این تالار گفتگو تمام رکوردهای تعامل پزشک و بیمار خود را به صورت مستقیم در سایت ارائه نمی دهد و فقط به دو هزار رکورد آخر دسترسی می دهد. علاوه بر این، هر رکورد به صد رکورد مرتبط دیگر پیوند داده شده است.

برای حل این چالش، از الگوریتم ۱.۴ استفاده شد. در این روش، داده های تالار گفتگو به صورت یک گراف در نظر گرفته شده و با استفاده از جستجوی عرض-اول<sup>۹</sup> توانستیم حدود صد و بیست هزار رکورد از مجموع دویست هزار رکورد موجود در این تالار گفتگو را استخراج کنیم. این فرایند حدود دو هفته طول کشید.

#### ۴.۴ ترجمه قسمت پزشکی مجموعه داده MMLU

مجموعه داده MMLU [۱۱]<sup>۹</sup> یکی از معتبرترین مجموعه داده ها برای ارزیابی توانایی مدل های زبانی در درک و پاسخ دهی به سوالات چندوظیفه ای است. این مجموعه شامل سوالاتی در موضوعات مختلف از جمله علوم پزشکی، مهندسی، علوم انسانی و دیگر حوزه ها است که به صورت چندگزینه ای طراحی شده اند. در پروژه ما، برای ارزیابی مدل زبانی پزشکی توسعه یافته، بخش پزشکی این مجموعه داده را به زبان فارسی ترجمه کردیم.<sup>۱۰</sup> هدف از این کار، تطبیق داده های ارزیابی با زبان مورد استفاده در مدل و بررسی توانایی مدل در پاسخ دهی دقیق به سوالات تخصصی پزشکی در زبان فارسی بود.<sup>۱۱</sup>

<sup>۹</sup>breadth first search

<sup>۹</sup>Massive Multitask Language Understanding

<sup>۱۰</sup>ترجمه توسط آقای امیرحسین پورسینا دانشجوی پزشکی انجام شده است.

<sup>۱۱</sup>برای بازدید از ترجمه این مجموعه داده به آدرس [huggingface.co/datasets/gaokerena/FA\\_MED\\_MMLU](https://huggingface.co/datasets/gaokerena/FA_MED_MMLU) مراجعه کنید.

## الگوریتم ۱۰۴ الگوریتم جستجو اول عرض برای استخراج رکورد های پرسش و پاسخ پزشکی

ورودی: گره های دارای دسترسی در تالار گفتگو (برگ ها)

خروجی: مجموعه ای از گره های بازدید شده

۱: یک پشته خالی  $S$  ایجاد کن

۲: یک مجموعه خالی  $Visited$  ایجاد کن

۳: گره مبدأ  $v$  را به پشته  $S$  اضافه کن

۴: تا زمانی که پشته  $S$  خالی نیست انجام بده

۵: یک گره  $u$  را از پشته  $S$  بردار

۶: اگر گره  $u$  بازدید نشده است آنگاه

۷: گره  $u$  را به مجموعه  $Visited$  اضافه کن

۸: برای هر همسایه  $n$  از گره  $u$  انجام بده

۹: اگر گره  $n$  بازدید نشده است آنگاه

۱۰: گره  $n$  را به پشته  $S$  اضافه کن

۱۱: پایان شرط اگر

۱۲: پایان حلقه برای

۱۳: پایان شرط اگر

۱۴: پایان حلقه تا زمانی که

۱۵: بازگردان نود های بازدید شده

## ۵.۴ گردآوری سوالات کنکور علوم پایه پزشکی ایران

آزمون علوم پایه پزشکی یک آزمون سراسری در ایران است که دانشجویان پزشکی موظف هستند پس از گذراندن دروس علوم پایه معمولاً در پنج ترم در آن شرکت کنند. این آزمون به منظور سنجش میزان آموخته های دانشجویان از دروس علوم پایه و آمادگی آنها برای ورود به مراحل بالینی برگزار می شود. در صورتی که دانشجو پس از سه مرتبه در این آزمون قبول نشود<sup>۱۲</sup> از ادامه تحصیل در رشته پزشکی محروم میشود.

برای سنجش دانش پزشکی مدل زبانی خود ما سوالات این آزمون را از pdf سوالاتی که سازمان سنجش برای آن منتشر میکند استخراج کرده ایم.<sup>۱۳ ۱۴</sup>

<sup>۱۲</sup>نمره قبولی در این آزمون در سالهای مختلف متفاوت است و معمولاً حدود سی و شش درصد میباشد

<sup>۱۳</sup>برای این کار از کتابخانه fitz پایتون استفاده شده است.

<sup>۱۴</sup> برای بازدید از این مجموعه داده به آدرس <https://huggingface.co/datasets/gaokerena/KOPP> مراجعه کنید.

## ۶.۴ ترجمه ماشینی مجموعه داده MedMCQA

برای پیاده‌سازی روش پیشنهادی خود، نیاز به یک مجموعه‌داده‌ی پرسش‌های چندگزینه‌ای پزشکی به زبان فارسی داشتیم. از آنجا که در زمان انجام پژوهش، چنین مجموعه‌داده‌ای در دسترس نبود، تصمیم گرفتیم از مدل زبانی بزرگ DeepSeek-V3 [۵۰] که از نظر هزینه و کارایی مقرون‌به‌صرفه است، برای ترجمه‌ی بخشی از مجموعه‌داده‌ی MedMCQA [۵۱] از زبان انگلیسی به فارسی استفاده کنیم.

به‌منظور حفظ تنوع موضوعی، پرسش‌ها به‌صورت تصادفی از مجموعه‌داده‌ی MedMCQA انتخاب شدند تا دامنه‌ی وسیعی از مباحث علوم پزشکی — از جمله فیزیولوژی، داروشناسی، پاتولوژی، و سایر حوزه‌ها — در مجموعه‌ی نهایی پوشش داده شود.

برای اطمینان از کیفیت ترجمه‌ها، از دو داور زبانی مستقل به نام‌های grok-3-mini [۵۲] و gpt-4.1-mini [۵۳] استفاده کردیم. هر یک از این داوران موظف بودند که ترجمه‌ی هر پرسش و گزینه‌های آن را از نظر دقت معنایی، روانی زبانی و حفظ اصطلاحات تخصصی ارزیابی کنند. ترجمه تنها در صورتی به عنوان «تاییدشده» در نظر گرفته می‌شد که هر دو داور به آن امتیاز کامل پنج از پنج اختصاص دهند.

در پایان این فرآیند چندمرحله‌ای، موفق شدیم حدود ۱۸۰۰۰ پرسش چندگزینه‌ای پزشکی به زبان فارسی را که از نظر کیفیت ترجمه تایید شده بودند، گردآوری کنیم.

## ۷.۴ مجموعه دادگان PersianMedQA و PerMedCQA

پس از اتمام فاز جمع‌آوری داده‌ها و انتشار آن‌ها به صورت عمومی، دو مقاله مهم در حوزه جمع‌آوری مجموعه‌داده‌های پزشکی منتشر شد. مقاله نخست به معرفی مجموعه‌داده PerMedCQA [۵۴] پرداخته و مقاله دوم به معرفی مجموعه‌داده PersianMedQA [۵۵] اختصاص داشت.

مجموعه‌داده PerMedCQA از نظر ساختار و نوع پرسش‌ها شباهت زیادی به مجموعه‌داده MF3QA دارد. نویسنده مقاله PerMedCQA ادعا کرده است که این مجموعه‌داده نخستین مجموعه‌داده در نوع خود است. با این حال، بررسی شماره آرشو این مقاله نشان می‌دهد که این ادعا نادرست است، زیرا مجموعه‌داده MF3QA پیش از PerMedCQA معرفی شده بود.

برای گسترش مجموعه‌داده خود و افزایش تنوع منابع، ما از مجموعه‌داده PersianMedQA استفاده کردیم. در این راستا، ۱۰۰۰ پرسش به صورت تصادفی از بخش آموزشی این مجموعه‌داده انتخاب و به مجموعه‌داده اصلی ما اضافه شد. این اقدام موجب افزایش داده‌ها و تنوع منابع مجموعه‌داده شد.

با اضافه کردن این پرسش‌ها به ۱۸۰۰۰ پرسشی که از ترجمه ماشینی مجموعه داده MedMCQA به دست آمده بود، در نهایت مجموعه داده نهایی شامل ۱۹۰۰۰ پرسش چندگزینه‌ای پزشکی به زبان فارسی شد. این مجموعه داده، ترکیبی از پرسش‌های ترجمه شده، پرسش‌های جمع‌آوری شده و پرسش‌های انتخاب شده از PersianMedQA است و یک منبع ارزشمند برای توسعه مدل‌های زبانی پزشکی فارسی در حوزه پزشکی به شمار می‌آید.

## فصل ۵

# معرفی مدل زبانی گائوکرنا-V

### ۱.۵ مقدمه

در این فصل با استفاده از دادگانی که گردآوری کرده ایم یک مدل پایه<sup>۱</sup> را تمرین می‌دهیم تا مدل جدید مدل گائوکرنا-V را معرفی کنیم که همانطور که در فصل نخست درباره آن صحبت شد دارای توانایی استدلال نیست. در ادامه با استفاده از ترجمه قسمت پزشکی مجموعه داده MMLU به مقایسه مدل جدید خود با مدل پایه و بقیه جایگزین‌ها خواهیم پرداخت.

### ۲.۵ مدل پایه

به دلیل عدم وجود یک مدل زبانی پزشکی فارسی متن باز<sup>۲</sup> ما مجبور به انتخاب یک مدل زبانی همه منظوره<sup>۳</sup> به عنوان مدل پایه هستیم.

گزینه‌های متعددی مانند qwen2.5 [۵۶] ، aya-expanse [۵۷] ، gemma2 [۵۸] و PersianMind [۵۹] برای انتخاب در دسترس بودند، که به دو دلیل زیر مدل aya-expanse-8b انتخاب شده است.

دلیل نخست این است که داده‌های آموزشی سایر مدل‌ها عمدتاً شامل زبان‌های غیر فارسی هستند، که این امر می‌تواند منجر به ایجاد سوگیری‌هایی در مدل شود که حتی در صورت دستور صریح به استفاده از زبان فارسی،

---

<sup>۱</sup>baseline model

<sup>۲</sup>open source

<sup>۳</sup>general purpose



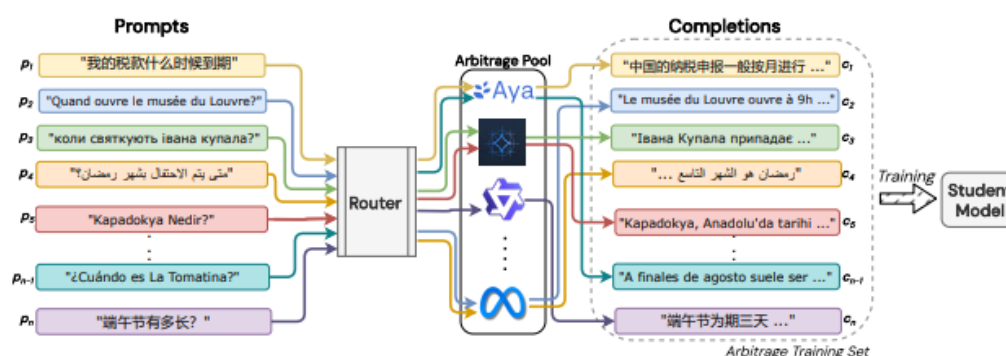
باعث تولید کاراکترهای غیر فارسی می‌شود. در مقابل، aya-expanse درک قوی‌ای از دستور زبان فارسی نشان می‌دهد و متنی غنی و دستوری صحیح به زبان فارسی تولید می‌کند، که آن را به گزینه‌ای بهتر برای پژوهش ما تبدیل می‌کند.

علاوه بر این، اگر ما پارامترهای به‌روزرسانی شده خود را به جای aya-expanse در مدل دیگری از خانواده aya، یعنی aya-vision [۶۰] ادغام کنیم، این امکان را به دست می‌آوریم که تصاویر پزشکی مانند MRI و CT scan را به عنوان ورودی بپذیریم. این امر باعث افزایش قابلیت کاربرد مدل ما در حوزه پزشکی خواهد شد.

### ۱.۲.۵ ویژگی‌های مدل aya-expanse

همانطور که پیشتر از آن یاد شد مدل زبانی aya-expanse قابلیت تولید متن‌های فارسی غنی با دستور زبانی صحیح را داراست<sup>۴</sup> و ویژگی که بقیه مدل‌های زبانی تنها برای برخی از زبان‌های دارای منابع غنی<sup>۵</sup> مانند انگلیسی و چینی دارا هستند.

این ویژگی زمانی قابل دسترس است که علاوه بر در دسترس بودن منابع غنی برای تمرین منابع به صورت مساوی بین زبان‌هایی که مدل زبانی پشتیبانی می‌کند تقسیم شده باشد؛ aya-expanse با تولید دادگان مصنوعی<sup>۶</sup> بر مشکل نبود دادگان فائق آمده است، البته تمرین دادن یک مدل زبانی با دادگان مصنوعی تولید شده توسط یک مدل زبانی دیگر باعث فروپاشی مدل<sup>۷</sup> [۶۱] می‌شود که aya-expanse با معرفی مکانیسم آربیتراژ داده [۶۲] که در شکل ۱.۵ می‌بینید از رخ دادن این اتفاق جلوگیری کرده است.



شکل ۱.۵: مکانیسم آربیتراژ داده

<sup>۴</sup> به جز زبان فارسی این مدل از بیست و دو زبان دیگر نیز پشتیبانی می‌کند.

<sup>۵</sup> resource-rich languages

<sup>۶</sup> synthetic data

<sup>۷</sup> model collapse

## ۳.۵ تنظیم دقیق روی پیکره پزشکی

برای دستیابی به مدل مدل گائوکرنا-V همان طور که در نمودار کاهش خطا در تصویر ۲.۵ میبینید ابتدا مدل پایه روی شصت درصد از پیکره پزشکی گردآوری شده تنظیم دقیق<sup>۸</sup> شده است<sup>۹</sup>، برای این کار از اندازه دسته<sup>۱۰</sup> برابر با دو استفاده کردیم تا نیاز به حافظه در طول آموزش کاهش یابد. علاوه بر این، از تجمع گرادیان<sup>۱۱</sup> با شانزده مرحله استفاده کردیم که به طور مؤثر اندازه‌ی کلی دسته را به سی و دو افزایش داد و دینامیک پایدار آموزش را فراهم کرد.

برای کاهش بیشتر مصرف حافظه در فرآیند تنظیم دقیق، از روش LoRA [۶۳]<sup>۱۲</sup> بهره بردیم تا تعداد پارامترهای قابل آموزش به طور چشمگیری کاهش یابد. برای این کار از رتبه<sup>۱۳</sup> برابر با هشت، مقدار آلفا برابر با شانزده، نرخ حذف<sup>۱۴</sup> برابر با پنج درصد و نرخ پوسیدگی وزن<sup>۱۵</sup> ده درصد استفاده کرده و وزن‌های LoRA را به تمام پارامترهای قابل آموزش در هر لایه ترنسفورمر اختصاص دادیم.

برای بهینه‌سازی بیشتر این فرآیند، از تکنیک‌های کارآمد توکن‌سازی<sup>۱۶</sup> و تکنیک‌های آموزش مبتنی بر مدیریت حافظه<sup>۱۷</sup> بهره بردیم. فرآیند توکن‌سازی متن ورودی را به دنباله‌های قابل مدیریت توکن تقسیم کرد، و با کوتاه کردن، پر کردن، و مدیریت توکن‌های اضافی، ساختار ورودی و برچسب‌ها را ثابت نگه داشت تا یکپارچگی مفهومی در طول ثابت زمینه حفظ شود. این آماده‌سازی ساده‌شده، همراه با تنظیم دقیق مبتنی بر LoRA، و استفاده از Flash Attention 2 [۶۴]<sup>۱۸</sup> بهبود یافت.

Flash Attention 2 با کاهش سربار حافظه، امکان مدیریت طول‌های زمینه بلندتر و اندازه‌های دسته بزرگ‌تر را به صورت کارآمد فراهم میکند، که به تنظیم دقیق مؤثر کمک کرده و تعادل بین کارایی محاسباتی و عملکرد مدل را برقرار میسازد.

<sup>۸</sup> fine tune

<sup>۹</sup> برای دسترسی به کد تنظیم دقیق مدل پایه روی پیکره پزشکی گردآوری شده میتوانید به آدرس <https://github.com/Mehrdadghassabi/Gaokerena-V/blob/main/fine-tuning/Pretraining.ipynb> مراجعه کنید

<sup>۱۰</sup> batch size

<sup>۱۱</sup> gradient accumulation

<sup>۱۲</sup> low rank adaptation


<sup>۱۳</sup> rank

<sup>۱۴</sup> drop out

<sup>۱۵</sup> weight decay

<sup>۱۶</sup> efficient tokenization

<sup>۱۷</sup> memory-aware training techniques



شکل ۲.۵: نمودار کاهش خطا تنظیم دقیق روی پیکره پزشکی

## ۴.۵ تنظیم دستورالعملی روی مجموعه داده MF3QA

پس از تنظیم دقیق روی پیکره پزشکی، بایستی فرآیند تنظیم دستورالعملی<sup>۱۸</sup> را با استفاده از مجموعه داده MF3QA که فصل پیشین معرفی شد انجام دهیم.<sup>۱۹</sup> همان‌طور که در نمودار کاهش خطا در تصویر ۳.۵ می‌بینید برای این کار به طور مشخص، باز هم از روش LoRA استفاده کرده ایم ولی این بار با رتبه<sup>۲۰</sup> برابر با دو، آلفا برابر با دو، نرخ حذف برابر با چهل درصد و نرخ پوسیدگی وزن<sup>۲۱</sup> پنجاه درصد استفاده کرده ایم. فرآیند تنظیم دستورالعمل تنها برای یک دوره<sup>۲۲</sup> انجام شد تا مدل شیوه پاسخگویی درست را بهتر درک کند.

## ۵.۵ رد پای کربن مدل گائوکرنا-V

اثر کربنی حاصل از بهینه‌سازی مدل گائوکرنا-V که شامل مراحل تنظیم دقیق و تنظیم دستورالعملی میشود، بر اساس مشخصات سخت‌افزاری و مدت زمان اجرا تخمین زده شده است. فرآیند تمرین به مدت نوزده ساعت

<sup>۱۸</sup> instruction tuning


<sup>۱۹</sup> برای دسترسی به کد تنظیم دستورالعملی روی مجموعه داده MF3QA می‌توانید به آدرس <https://github.com/Mehrdadghassabi/Gaokerena-V/blob/main/fine-tuning/InstructionTuning.ipynb>

مراجعه کنید

<sup>۲۰</sup> rank

<sup>۲۱</sup> weight decay

<sup>۲۲</sup> epoch



شکل ۳.۵: نمودار کاهش خطا تنظیم دقیق روی مجموعه داده MF3QA

بر روی کارت گرافیک NVIDIA A100 PCIe 40GB که در منطقه شرق آسیا<sup>۲۳</sup> پلتفرم ابری گوگل میزبانی می‌شدند، اجرا شده است.

با توجه به مصرف برق معمولی هر پردازنده گرافیکی که برابر با دویست و پنجاه وات است، کل انرژی مصرف‌شده در این مدت برابر 4.750 کیلووات‌ساعت است. با در نظر گرفتن ضریب شدت کربن شبکه شرق آسیا که برابر با 560 گرم کربن دی اکسید معادل به ازای هر کیلووات‌ساعت است، میزان انتشار کربن در طول این فرآیند به 2660 گرم می‌رسد. [۶۵]

## ۶.۵ نتایج

در نمود مدل های پزشکی فارسی برای مقایسه ما مدل گائوکرنا-V را با مدل های زبانی فارسی همه منظوره<sup>۲۴</sup> و جایگزین های خط لوله ای<sup>۲۵</sup> مقایسه کرده ایم.

همانطور که در شکل ۴.۵ می‌بینید جایگزین های خط لوله ای شامل یک سری مراحل است ابتدا، یک مترجم پرسش کاربر را از فارسی به انگلیسی تبدیل می‌کند، سپس این پرسش انگلیسی به یک مدل زبانی پزشکی انگلیسی داده می‌شود، و در نهایت، پاسخ تولیدشده توسط مدل انگلیسی دوباره از انگلیسی به فارسی ترجمه می‌شود.

<sup>۲۳</sup>asia-east1

<sup>۲۴</sup>general purpose language models

<sup>۲۵</sup>pipeline alternatives




شکل ۴.۵: مکانیسم جایگزین خط لوله ای

### ۱.۶.۵ مقایسه با مدل های زبانی فارسی همه منظوره

همان طور که در جدول ۱.۵ مشاهده می کنید، مدل گائوکرنا-V توانست با موفقیت کنکور علوم پایه پزشکی شهریور ۱۴۰۲، را پشت سر بگذارد<sup>۲۶</sup> و به اولین مدل زبان فارسی با کمتر از هشت میلیارد پارامتر تبدیل شد که این آزمون را با موفقیت پشت سر گذاشته است. علاوه بر این، مدل ما در قسمت پزشکی مجموعه داده<sup>۲۷</sup> نیز بهبودهایی را نشان داد و نه تنها میانگین نمرات بالاتری کسب کرد، بلکه در اکثر زیرشاخه ها عملکرد برجسته ای داشت و توانایی خود را در درک و تولید دانش پزشکی به زبان فارسی به نمایش گذاشت.

قابل توجه است که دلیل سرعت بالای پاسخگویی PersianMind، همان طور که در جدول ۱.۵ نشان داده شده، این است که این مدل تمایل دارد پاسخ های بسیار کوتاه تری نسبت به مدل های دیگر تولید کند و توکن پایان پاسخ را زودتر ایجاد نماید. علاوه بر ارزیابی پرسش و پاسخ چندگزینه ای، ما از GPT-4o [۶۶] به عنوان داور برای پرسش و پاسخ آزاد نیز استفاده کردیم. قسمت تست مجموعه داده MF3QA به مدل زبان رقیب و مدل ما ارائه شد. همان طور که در شکل ۵.۵ نشان داده شده است، GPT-4o به طور عمده پاسخ های تولید شده توسط مدل ما را نسبت به سه مدل دیگر ترجیح داده است.



شکل ۵.۵: نرخ پیروزی گائوکرنا-V در رقابت با بقیه مدل های زبانی فارسی همه منظوره

<sup>۲۶</sup> نمره قبولی در این امتحان سی و شش درصد بدون نمره منفی بوده است.  
MMLU<sup>۲۷</sup>

## ۲.۶.۵ مقایسه با جایگزین های خط لوله ای

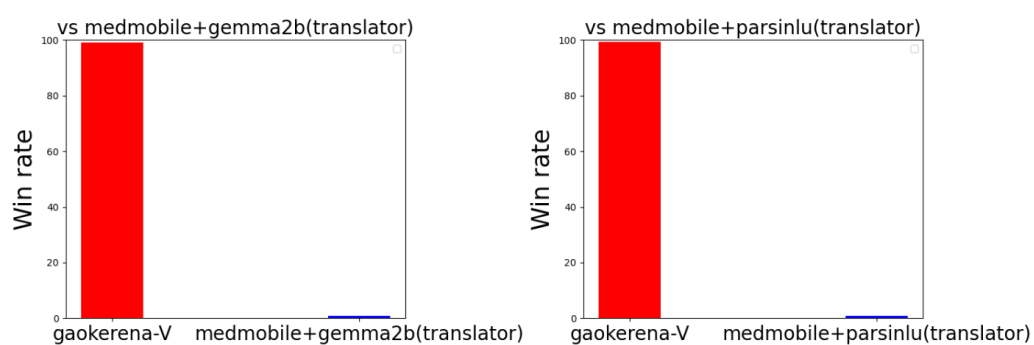
همان طور که قبلاً اشاره شد، یکی از گزینه های جایگزین برای توسعه یک مدل زبانی پزشکی فارسی، استفاده از جایگزین های خط لوله ای<sup>۲۸</sup> است. با این حال، یکی از مشکلات عمده این سیستم ها سرعت پایین آن ها است. این سیستم ها زمان استنتاج بالایی دارند، زیرا خروجی یک مدل باید به مدل دوم منتقل شود و سپس خروجی مدل دوم دوباره توسط مدل اول پردازش شود. این فرآیند تکراری به طور قابل توجهی کارایی سیستم را کاهش می دهد.

برای رفع مشکل سرعت پایین سیستم های مرحله ای، ما تمام پارامترها شامل پارامترهای مربوط به مترجم ها و مدل زبانی پزشکی را به طور همزمان بارگذاری کرده ایم. آزمایش های ما با مدل هایی مانند Medmobile همراه با gemma-2b-it به عنوان مترجم، و Medmobile همراه با مدل های parsinlu [۶۷] [۶۸] به عنوان مترجم انجام گرفته است؛ همان طور که در جدول ۲.۵ مشاهده میکنید جایگزین های خط لوله ای دقت و سرعت بسیار پایینی از خود نشان دادند.

یکی دیگر از مشکلات مهم جایگزین های خط لوله ای، عملکرد ضعیف آن ها در شناسایی و ترجمه دقیق اصطلاحات پزشکی است. این محدودیت چالشی جدی ایجاد می کند، زیرا دقت در استفاده از اصطلاحات تخصصی برای ارتباط موثر در محیط های مراقبت های بهداشتی حیاتی است. علت اصلی این ضعف احتمالاً به این دلیل است که مترجم های استفاده شده در این سیستم ها به طور خاص برای ترجمه پزشکی توسعه نیافته اند. برخلاف مدل های ترجمه عمومی، ترجمه پزشکی نیازمند درک دقیق واژگان تخصصی، زمینه و پیچیدگی های زبان پزشکی است.

در حال حاضر، هیچ مدلی برای ترجمه پزشکی به زبان فارسی طراحی نشده است، که این امر باعث می شود سیستم های موجود توانایی کافی برای مدیریت پیچیدگی های اصطلاحات پزشکی نداشته باشند. همان طور که در شکل ۶.۵ نشان داده شده است، این محدودیت ها منجر به نرخ پیروزی بسیار پایین جایگزین های خط لوله ای در رقابت با مدل گائوکرنا-V شده است.

<sup>۲۸</sup> pipeline alternatives



شکل ۶.۵: نرخ پیروزی گائوکرنا-V در رقابت با جایگزین های خط لوله ای

<b>PersianMind</b>	<b>Qwen2.5</b>	<b>aya-expanse-8b</b> (baseline)	<b>Gaokerena-V</b> (ours)	
25.18	41.48	40.74	<b>48.14</b>	MMLU-anatomy(fa)
34.0	52.0	49.0	<b>53.0</b>	MMLU-medical genetics(fa)
20.23	43.35	<b>44.51</b>	43.93	MMLU-college medicine(fa)
25.28	47.92	52.07	<b>55.47</b>	MMLU-clinical knowledge(fa)
23.89	43.01	45.58	<b>47.05</b>	MMLU-professional medicine(fa)
32.63	44.85	45.14	<b>47.22</b>	MMLU-college biology(fa)
25.89	45.17	46.64	<b>49.31</b>	MMLU(avg)
19.64	33.33	34.52	<b>38.69</b>	IBMSEE Sept 2023
6.8b	7.6b	8b	8b	Number of parameters
حدود 2s	حدود 15s	حدود 8s	حدود 10s	inference time

جدول ۱.۵: مقایسه مدل گائوکرنا-V با بقیه مدل های زبانی فارسی همه منظوره



<b>MedMobile parsinlu +</b>	<b>MedMobile + gemma2 -2b-it</b>	<b>Gaokerena (ours)</b>	
25.18	14.07	<b>48.14</b>	MMLU- anatomy(fa)
35.0	20.0	<b>53.0</b>	MMLU- medical-genetics(fa)
27.17	19.08	<b>43.93</b>	MMLU- college-medicine(fa)
31.70	27.54	<b>55.47</b>	MMLU- clinical-knowledge(fa)
33.82	17.27	<b>47.05</b>	MMLU- professional-medicine(fa)
31.25	18.75	<b>47.22</b>	MMLU- college-biology(fa)
30.99	20.11	<b>49.31</b>	MMLU(avg)
32.73	24.40	<b>38.69</b>	IBMSEE Sept2023
3.8b+1.2b+1.2b	3.8b+2b	8b	Number of parameters
حدود 30s	حدود 20s	حدود 10s	inference time

جدول ۲.۵: مقایسه مدل گائوکرنا-V با جایگزین های خط لوله ای

## فصل ۶

# استدلال در مدل های زبانی

ظهور معماری ترنسفورمر<sup>۱</sup> [۵] در سال ۲۰۱۷ نقطه‌ی عطفی بنیادین در تحول مدل های زبانی بزرگ به شمار می‌آید. این معماری با معرفی سازوکار توجه<sup>۲</sup> و جایگزینی آن به جای پردازش متوالی، بسیاری از محدودیت های مدل های پیشین — از جمله پدیده‌ی محو شدن گرادیان ها و ناتوانی در مدل سازی وابستگی های بلندمدت — را برطرف ساخت. بدین ترتیب، امکان موازی سازی کامل در فرایند آموزش فراهم شد و مدل توانست ساختارهای زبانی پیچیده را با دقت و کارایی بسیار بالاتری درک و بازنمایی کند.

در این فصل، تمرکز بر بررسی توانایی استدلال در معماری ترنسفورمر و رویکردهای نوین برای بهبود آن است. هرچند این معماری در وظیفه‌ی پیش بینی توکن بعدی عملکردی خیره کننده دارد، اما نحوه‌ی استدلال آن عموماً الگو محور است تا منطق محور. به بیان دیگر، تمامی مدل های زبانی مدرن که بر پایه‌ی ترنسفورمر ساخته شده اند، در هسته‌ی خود از همان ضعف بنیادی رنج می‌برند: ناتوانی در درک و بازتولید فرایندهای استدلالی عمیق و مبتنی بر منطق.

## ۱.۶ ناتوانی معماری ترنسفورمر در تفکر سیستم دو

در سال ۲۰۱۹، در کنفرانس NeurIPS، یوشوا بنجیو — یکی از چهره های پیشگام در حوزه‌ی یادگیری عمیق به یکی از محدودیت های بنیادین سیستم های یادگیری عمیق امروزی، از جمله مدل های زبانی، اشاره کرد: ناتوانی

---

<sup>۱</sup>Transformer  
<sup>۲</sup>Attention

در انجام وظایفی که نیازمند مهارت های استدلالی قوی هستند. [۶۹]<sup>۳</sup> به رغم عملکرد چشمگیر این سیستم ها در وظایف شهودی و ادراکی نظیر تشخیص تصویر، ترجمه ماشینی یا تولید متن آن ها در مواجهه با مسائلی که مستلزم استدلال منطقی، درک روابط علی و پردازش شناختی عمیق هستند، عملکرد ضعیفی از خود نشان می دهند. در واقع، بسیاری از اشتباهات ساده و احمقانه ی مدل های زبانی مانند ناتوانی در حل مسائل ریاضی ابتدایی یا استنتاج های منطقی آشکار را می توان با همین محدودیت در تفکر سیستم دو توضیح داد. این مشاهده یادآور تمایز مطرح شده توسط دنیل کانمن در علوم شناختی [۷۰] میان دو نوع تفکر است: تفکر سریع که بنجیو آن را «تفکر سیستم یک» می نامد و تفکر آهسته که بنجیو آن را «تفکر سیستم دو» می خواند. تفکر سریع، ماهیتی شهودی، واکنشی و خودکار دارد و با نقاط قوت سیستم های فعلی هوش مصنوعی هم راستا است؛ در مقابل، تفکر آهسته فرایندی آگاهانه، تحلیلی و منطقی است که مستلزم توانایی در برنامه ریزی، استدلال و بازنمایی مفاهیم انتزاعی می باشد. به بیان دیگر، شبکه های عصبی عمیق و به ویژه مدل های زبانی مبتنی بر ترنسفورمر عمدتاً در سطح تفکر سیستم یک، یعنی شناخت شهودی، عمل می کنند و فاقد شناخت منطقی یا استدلال علی تفکر سیستم دو هستند. این شکاف میان شهود و منطق، چالشی اساسی در مسیر توسعه ی نسل بعدی مدل های زبانی و سامانه های هوش مصنوعی با قابلیت تفکر مشابه انسان به شمار می رود.

## ۲.۶ طراحی یک معماری دارای قابلیت تفکر سیستم دو

بهترین رویکرد برای غلبه بر ناتوانی ترنسفورمرها در تفکر سیستم دو، توسعه ی یک معماری جدید است که بتواند این قابلیت را به طور ذاتی در خود داشته باشد. اما طراحی و پیاده سازی چنین معماری ای کار ساده ای نیست! چنین معماری ای باید دارای توانایی تعمیم خارج از توزیع<sup>۴</sup> نیز باشد؛ به این معنا که مدل بتواند مفاهیم و روابطی را یاد بگیرد که به صورت صریح و مستقیم در داده های آموزشی وجود ندارند. به بیان دیگر، سیستم باید قادر باشد از دانش موجود در داده ها به موقعیت های جدید و نادیده تعمیم دهد — ویژگی ای که برای استدلال واقعی و تفکر سطح بالا ضروری است.

در سال های اخیر، پژوهشگران چندین مدل و معماری جایگزین را برای بهبود توانایی استدلال در شبکه های عصبی پیشنهاد داده اند. برای مثال، یکی از این تلاش ها معماری ای به نام RIM [۷۱] بود که توسط یوشوا بنجیو معرفی شد. یا معماری مدل استدلال سلسله مراتبی<sup>۵</sup> [۷۲] که با الهام از سلسله مراتبی بودن تفکر انسان پیشنهاد

<sup>۳</sup>سخنرانی بنجیو اهمیت بسزایی داشت و مفهوم «تفکر سیستم دو» را در هوش مصنوعی برجسته کرد. درس دکتر رهبان در دانشگاه شریف با این عنوان، راهنمایی کلیدی برای پایان نامه ی حاضر بوده است.

<sup>۴</sup>Out-of-Distribution Generalization

<sup>۵</sup>Hierarchical Reasoning Model

شده است؛

با این حال، مدل های پیشنهاد شده در عمل معماری مقیاس پذیری نبوده و نتوانسته اند در مقیاس های بزرگ عملکرد قابل قبولی ارائه دهند. به همین دلیل، نمی توان آن ها را یک پیشنهاد موفق برای حل مشکل استدلال در مدل های مبتنی بر ترنسفورمر دانست.

در نتیجه، همچنان یکی از چالش های باز در حوزه ی یادگیری عمیق و مدل های زبانی بزرگ، یافتن معماری ای کارا، مقیاس پذیر، دارای توان استدلالی و برخوردار از قابلیت تعمیم خارج از توزیع است؛ معماری ای که بتواند محدودیت های ذاتی ترنسفورمرها را پشت سر بگذارد.

### ۳.۶ بهبود توانایی دلیل آوری مدل های زبانی مبتنی بر ترنسفورمر

تا زمانی که هنوز معماری ای با قابلیت استدلال ذاتی<sup>۶</sup> در دسترس نداریم، ناچاریم همچنان با معماری ترنسفورمر کار کنیم و به نوعی بر محدودیت ها و ضعف های ذاتی آن غلبه نماییم.

با وجود تمام پیشرفت ها، ترنسفورمرها هنوز فاقد سازوکار درونی برای استدلال گام به گام، تعمیم منطقی و درک علیت هستند. با این حال، از آن جا که در حال حاضر موثرترین و مقیاس پذیرترین معماری در حوزه ی مدل های زبانی محسوب می شوند، راهبرد عملی این است که به جای کنار گذاشتن آن ها، راهکارهایی برای تقویت توانایی استدلالی شان طراحی و به کار گرفته شود. روش های گوناگونی برای این هدف پیشنهاد شده است که برای اطلاعات بیشتر میتوانید در مقاله مروری آقای پان [۷۳] در این زمینه مراجعه کنید.

در این بخش، به بررسی مهم ترین این رویکردها و روش هایی که می توانند به بهبود توانایی استدلالی مدل های مبتنی بر ترنسفورمر منجر شوند، خواهیم پرداخت.

### ۱.۳.۶ روش های مبتنی بر هوش مصنوعی عصبی-نمادین

در حوزه ی هوش مصنوعی، دو مکتب فکری اصلی وجود دارد: نمادگرایی<sup>۷</sup> و ارتباط گرایی<sup>۸</sup>. در مکتب نمادگرایی، هدف اصلی این است که منطق، قوانین و روابط صریح میان مفاهیم جمع آوری شده و در قالب یک مدل منطقی یا قاعده محور نمایش داده شود. این رویکرد بر پایه ی استدلال نمادین استوار است؛ یعنی سیستم تلاش می کند با استفاده از قواعد صریحی که توسط انسان تعریف شده اند، به نتیجه برسد.

<sup>۶</sup>Intrinsic Reasoning Capability  
<sup>۷</sup>Symbolism  
<sup>۸</sup>Connectionism

در مقابل، مکتب ارتباط‌گرایی بر پایه‌ی ایده‌ی یادگیری از داده‌ها شکل گرفته است. در این رویکرد، به‌جای تعریف قوانین منطقی، حجم زیادی از داده به مدل داده می‌شود تا خود سیستم از درون داده‌ها الگوها و روابط را کشف کند. شبکه‌های عصبی مصنوعی و به‌ویژه مدل‌های عمیق<sup>۹</sup> از نمونه‌های شاخص این مکتب هستند.

با معرفی معماری ترنسفورمر، مکتب ارتباط‌گرایی به شکل چشمگیری غالب شد و تقریباً تمامی پژوهش‌های پیشرفته‌ی حوزه‌ی هوش مصنوعی حول آن متمرکز گردید. دلیل این غلبه روشن است: جمع‌آوری داده‌های عظیم بسیار ساده‌تر از استخراج و تعریف قوانین منطقی دقیق است، و مدل‌های ارتباط‌گرا با استفاده از این داده‌های گسترده می‌توانند عملکردی چشمگیر در وظایف گوناگون مانند ترجمه، تولید متن، بینایی ماشین و غیره داشته باشند.

با این حال، همان‌طور که پیش‌تر اشاره شد، ترنسفورمرها ضعف بزرگی دارند: ناتوانی در استدلال! این مدل‌ها اگرچه در شناسایی الگوها و پیش‌بینی توالی‌ها بسیار قدرتمندند، اما فاقد سازوکار درونی برای انجام استدلال منطقی و تفکر نظام‌مند (تفکر سیستم دو) هستند. از آن‌جا که تاکنون معماری‌ای با قابلیت استدلال ذاتی معرفی نشده است، تمامی مدل‌های مبتنی بر ارتباط‌گرایی نیز همین ضعف بنیادی را به ارث برده‌اند. در مقابل، رویکردهای نمادین از این نظر برترند که توانایی استدلال و نتیجه‌گیری منطقی را به‌صورت ذاتی در خود دارند، اما مشکل بزرگ آن‌ها عدم مقیاس‌پذیری<sup>۱۰</sup> است؛ یعنی پیاده‌سازی و گسترش آن‌ها برای مسائل واقعی و داده‌های بزرگ بسیار دشوار است.

برای رفع این شکاف، گروهی از پژوهشگران پیشنهاد یک رویکرد میان‌رشته‌ای جدید را مطرح کرده‌اند که ترکیبی از این دو مکتب است: رویکرد عصبی-نمادین<sup>۱۱</sup>. در این دیدگاه، تلاش می‌شود از قدرت یادگیری و تعمیم مدل‌های عصبی (ارتباط‌گرا) در کنار توان استدلال و شفافیت سیستم‌های نمادین استفاده شود تا هوشی ترکیبی و متوازن به‌دست آید؛ هوشی که هم بتواند از داده بیاموزد، و هم به‌طور منطقی بیندیشد. [۷۴]

با این حال، یوشوا بنجیو معتقد است که این مسیر، راه‌حل نهایی مناسبی نیست و ممکن است با مقیاس‌پذیری در تضاد باشد. او تأکید می‌کند که به جای ترکیب دو مکتب مجزا، بهترین راه، توسعه‌ی معماری‌هایی است که قابلیت استدلال را به‌طور ذاتی در درون خود داشته باشند؛ یعنی سامانه‌هایی که بتوانند استدلال، تعمیم و یادگیری را در یک چارچوب واحد و منسجم ادغام کنند.

### ۲.۳.۶ روش های مبتنی بر راهنمایی مدل زبانی توسط یک مدل پاداش

یکی از روش های بهبود مهارت های استدلالی یک مدل زبانی، هدایت فرآیند رمزگشایی آن با استفاده از یک مدل پاداش است. مدل پاداش می تواند به دو صورت باشد: مدل پاداش خروجی<sup>۱۲</sup> و مدل پاداش فرآیند<sup>۱۳</sup> [۷۵]. مدل پاداش خروجی بر ارزیابی کیفیت پاسخ نهایی تولید شده توسط مدل زبانی تمرکز دارد. این مدل به خروجی ها امتیاز می دهد و بر اساس معیارهای مشخص، مانند دقت، انسجام یا ارتباط با پرس و جو، آن ها را رتبه بندی می کند. از سوی دیگر، مدل پاداش فرآیند به مراحل میانی استدلال مدل توجه می کند. این مدل هر گام از فرآیند تفکر یا حل مسئله را بررسی و ارزیابی می کند تا اطمینان حاصل شود که مسیر استدلال منطقی و بهینه است. استفاده از این دو نوع مدل پاداش می تواند به بهبود عملکرد مدل زبانی در وظایف پیچیده کمک کند. برای مثال، در حل مسائل ریاضی یا پاسخ به سؤالات استدلالی، مدل پاداش فرآیند می تواند مدل را به سمت رویکردهای گام به گام و دقیق تر هدایت کند، در حالی که مدل پاداش خروجی کیفیت نهایی پاسخ را تضمین می کند. ترکیب این دو مدل می تواند به ایجاد پاسخ هایی منجر شود که نه تنها درست هستند، بلکه فرآیند رسیدن به آن ها نیز شفاف و قابل اعتماد است. یکی از کارهایی که سعی در بهبود توانایی دلیل آوری کرده است مدل Medsss [۳۵] است که در فصل کارهای پیشین در مورد آن توضیحات لازمه داده شده است.

### ۳.۳.۶ روش های مبتنی بر تمرین روی داده های دلیل آوری

یکی دیگر از روش های بهبود مهارت های استدلالی یک مدل زبانی، آموزش آن با داده های استدلالی است. با انجام این کار، مدل زبانی می تواند یاد بگیرد که چگونه استدلال را تقلید کند یا استدلال هایی را که قبلاً در داده های آموزشی خود مشاهده کرده است، بازایی کند. این رویکرد به مدل کمک می کند تا در مواجهه با مسائل پیچیده، پاسخ هایی منطقی تر و ساختار یافته تر ارائه دهد. [۷۶]

در این روش، داده های آموزشی شامل نمونه هایی از فرآیندهای استدلالی، مانند حل گام به گام مسائل ریاضی، تحلیل های منطقی، یا استدلال های مبتنی بر شواهد هستند. با قرار گرفتن در معرض این داده ها، مدل زبانی نه تنها یاد می گیرد که پاسخ های درست تولید کند، بلکه می آموزد که چگونه به طور نظام مند به آن پاسخ ها برسد. این فرآیند به بهبود توانایی مدل در درک عمیق تر پرسش ها و ارائه پاسخ هایی با کیفیت بالاتر کمک می کند. در حقیقت مدل زبانی پایه با تمرین روی داده های استدلالی یاد می گیرد که فرآیند استدلال را شبیه سازی کند و ما تصور کنیم که در حال دلیل آوری است در حالی که معماری که آن مدل روی آن بنا شده توانایی استدلال را ندارد این پدیده

<sup>۱۲</sup> Output Reward Model

<sup>۱۳</sup> Process Reward Model

ای است که به آن توهم دلیل آوری<sup>۱۴</sup> میگویند. [۷۷] [۷۸] یکی از مهم ترین کارهایی که این رویکرد را با موفقیت پیاده سازی کرده، مدل DeepSeek-R [۳۹] است. این مدل با استفاده از مجموعه داده های استدلالی گسترده و متنوع آموزش دیده است و توانسته است عملکرد قابل توجهی در وظایف استدلالی پیچیده از خود نشان دهد. DeepSeek-R با بهره گیری از تکنیک های پیشرفته در آموزش مدل های زبانی، قادر است استدلال های منطقی را با دقت بالا تولید کند و حتی در مواردی که نیاز به تفکر چند مرحله ای است، عملکردی رقابتی با مدل های بزرگ تر ارائه دهد. برای اطلاعات بیشتر درباره این مدل و جزئیات رویکرد آن، می توانید به بخش کارهای پیشین مراجعه کنید.

---

<sup>۱۴</sup>delusion of thinking

## فصل ۷

# معرفی مدل زبانی گائوکرنا-R

### ۱.۷ مقدمه

در این بخش، ما به معرفی gaokerena-R می‌پردازیم. در این نسخه، دو روش نوین ارائه می‌شود که با استفاده از مقدار کمی داده می‌توانند توانایی‌های استدلالی مدل پایه را به‌صورت قابل‌توجهی بهبود بخشند. نتایج نشان می‌دهد که این رویکرد جدید عملکردی بهتر از gaokerena-V دارد؛ مدلی که با حجم زیادی از داده‌ها آموزش دیده است. در ادامه، این فرضیه مطرح می‌شود که ارتقای مهارت‌های استدلالی در مدل‌های زبانی کوچک و کم‌منبع حوزه پزشکی، تاثیرگذارتر و سودمندتر از صرفاً افزایش مقیاس داده‌ها است.

### ۲.۷ مدل پایه

به همان دلیلی که برای مدل gaokerena-V، مدل aya-expans-8b [۵۷] را به‌عنوان مدل پایه<sup>۱</sup> انتخاب کردیم، برای مدل gaokerena-R نیز از همان مدل پایه استفاده می‌کنیم. هدف از این انتخاب، حفظ یک مبنای یکسان برای ارزیابی دقیق و منصفانه میان دو رویکرد است. دلیل دیگر این تصمیم، امکان مقایسه‌ی عادلانه میان آموزش مدل بر حجم عظیمی از داده‌ها و روش پیشنهادی ما برای بهبود مهارت‌های استدلالی است. با این کار، می‌توان به‌روشنی تاثیر واقعی افزایش توانایی استدلال در برابر صرفاً گسترش داده‌های آموزشی را بررسی کرد و نشان داد که چگونه تقویت استدلال می‌تواند حتی در شرایط داده‌های محدود، موجب ارتقای عملکرد مدل شود.

---

<sup>۱</sup>baseline model



به دلیل محدودیت‌های سخت‌افزاری و سرعت بالای چارچوب اول، مدل پایه aya-expanse-8b را با چارچوب اول برای 95 درصد داده‌ها و چارچوب دوم برای 5 درصد باقی‌مانده آموزش دادیم. این رویکرد، آموزش کارآمد با بهینه‌سازی ترجیح مستقیم را ممکن ساخت و شامل 11000 جفت پاسخ ترجیحی-ردشده با حدود 2 میلیون توکن ترجیحی و 2.5 میلیون توکن ردشده بود. این ترکیب، زمان آموزش را بهینه کرد و با بهره‌گیری از بازخورد دقیق چارچوب دوم، مهارت‌های استدلالی مدل را در مسائل پزشکی تقویت نمود.

### ۳.۷ متد های معرفی شده

همان‌طور که پیش‌تر اشاره شد، برای تقویت مهارت‌های استدلالی در حوزه پزشکی، دو روش نوین معرفی شده‌اند. روش نخست سریع‌تر از روش دوم عمل می‌کند، اما روش دوم داده‌های باکیفیت‌تری برای آموزش تولید می‌نماید. در ادامه، به توضیح جزئیات این دو روش می‌پردازیم.

#### ۱.۳.۷ روش نخست

روش نخست، که در شکل ۱.۷ و الگوریتم ۲.۷ نمایش داده شده است، از یک مدل معلم (در این پژوهش از مدل زبانی DeepSeek-R استفاده شده است) بهره می‌گیرد. این مدل معلم، خود یک مدل زبانی با قابلیت استدلال پیشرفته است که وظیفه دارد خطاهای استدلالی مدل دانش‌آموز را در پاسخ به پرسش‌های چندگزینه‌ای حوزه پزشکی شناسایی و اصلاح کند. در این فرآیند، اگر مدل دانش‌آموز گزینه‌ی صحیح را انتخاب کند، بدون نیاز به مداخله‌ی بیشتر، به سؤال بعدی در مجموعه‌داده منتقل می‌شویم. اما در صورتی که مدل دانش‌آموز پاسخ نادرست دهد، مدل معلم با در نظر گرفتن پاسخ درست، یک توضیح گام‌به‌گام و دقیق در قالب زنجیره استدلال<sup>۲</sup> تولید می‌کند که منطق، شواهد و روند تفکر پشت پاسخ صحیح را آشکار می‌سازد. این توضیحات نه تنها اشتباه مدل دانش‌آموز را مشخص می‌کنند، بلکه نحوه‌ی استدلال صحیح در مسائل پزشکی را نیز آموزش می‌دهند. در این سازوکار، خروجی مدل معلم به‌عنوان پاسخ برگزیده<sup>۳</sup> تلقی می‌شود و پاسخ اولیه‌ی مدل دانش‌آموز به‌عنوان پاسخ مردود<sup>۴</sup> برای فرآیند بهینه‌سازی مستقیم ترجیحات<sup>۵</sup> [۱۹] مورد استفاده قرار می‌گیرد. این چارچوب آموزشی به مدل دانش‌آموز امکان می‌دهد تا از طریق بازخورد مستقیم مدل معلم، به شکلی هدفمند مهارت‌های استدلالی


<sup>۲</sup>chain-of-thought

<sup>۳</sup>preferred answer

<sup>۴</sup>rejected answer

<sup>۵</sup>direct preference optimization

خود را تقویت کرده و درک عمیق‌تری از منطق پزشکی در پرسش‌های چندگزینه‌ای به دست آورد.



شکل ۱.۷: بلوک دیاگرام شیوه نخست

## ۲.۳.۷ روش دوم

روش دوم، که در شکل ۲.۷ و الگوریتم ۲.۷ نشان داده شده است، از مدل معلم استفاده می‌کند تا بازخورد دقیق‌تری ارائه دهد. این روش با شناسایی خطاهای خاص در پاسخ مدل دانش‌آموز به یک پرسش چندگزینه‌ای عمل می‌کند. پس از دریافت این بازخورد، مدل دانش‌آموز تشویق می‌شود تا پاسخ خود را دقیقاً از نقطه‌ای که خطا رخ داده است، اصلاح کند. از طریق این فرآیند تکراری، مدل دانش‌آموز به تدریج مسیر استدلالی<sup>۶</sup> [۷۹] خود را بهبود می‌بخشد و به پاسخ صحیح همگرا می‌شود. این بازخورد سازنده به مدل دانش‌آموز امکان می‌دهد تا استقلال استدلالی خود را تقویت کند، زیرا یاد می‌گیرد خطاهای خود را به جای تقلید صرف از پاسخ‌های مدل معلم، اصلاح نماید. در این چارچوب، پاسخ نهایی تولیدشده توسط مدل دانش‌آموز به عنوان پاسخ ترجیحی در نظر گرفته می‌شود، در حالی که تلاش اولیه آن به عنوان پاسخ رد شده برای آموزش بهینه سازی مستقیم ترجیحات استفاده می‌شود. اگرچه این چارچوب دوم به دلیل فرآیند بازخورد تکراری زمان‌برتر است، اما آموزش بهینه سازی مستقیم ترجیحات را ساده‌تر می‌کند، زیرا هر دو پاسخ رد شده و ترجیحی به طور کامل توسط خود مدل دانش‌آموز و به صورت توالی‌هایی از توکن‌های خودش تولید می‌شوند. این رویکرد نه تنها به مدل دانش‌آموز کمک می‌کند

<sup>۶</sup>reasoning trajectories

## الگوریتم ۱.۷ شیوه دوم پیشنهاد شده برای بهبود دلیل آوری

- ورودی:** پرسش و پاسخ های چند گزینه پزشکی
- ۱: برای به ازای تمامی پرسش ها انجام بده
  - ۲: یکی از پرسش های پزشکی را از مدل دانشجو پرس
  - ۳: اگر اگر پاسخ دانشجو درست بود آنگاه
  - ۴: این پرسش را کنار بگذار و به سراغ پرسش بعدی برو
  - ۵: پایان شرط اگر
  - ۶: پاسخ نادرست دانشجو را ذخیره کن
  - ۷: پاسخ نادرست دانشجو را به همراه کلید پاسخ معلم بده و از او بخواه که استدلال نادرست دانشجو را اصلاح کند
  - ۸: پاسخ معلم را به عنوان پاسخ صحیح ذخیره کن
  - ۹: پاسخ درست و نادرست را به عنوان جفت ذخیره کن
  - ۱۰: اگر در صورت جمع شدن تعداد کافی جفت پاسخ درست و نادرست آنگاه
  - ۱۱: مدل دانشجو را با استفاده از بهینه سازی مستقیم ترجیحات تمرین بده
  - ۱۲: پایان شرط اگر
  - ۱۳: پایان حلقه برای

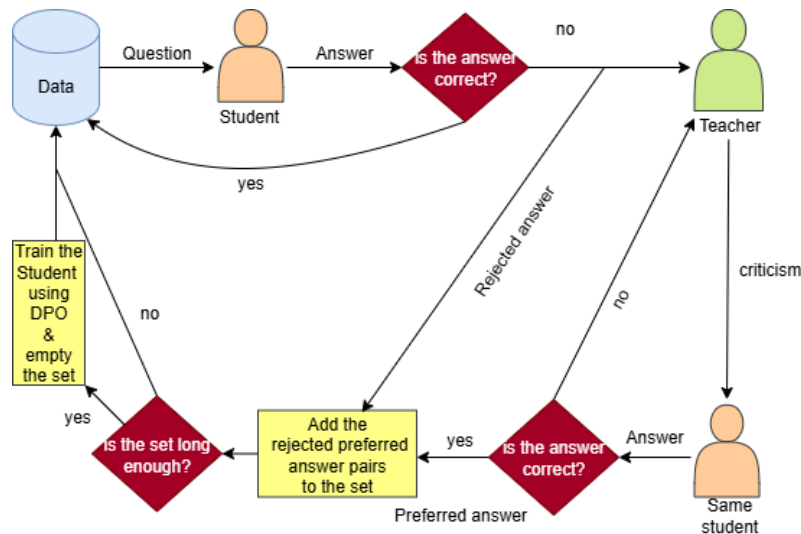
تا مهارت های استدلالی خود را به صورت مستقل توسعه دهد، بلکه با تولید داده های آموزشی باکیفیت تر، کارایی فرآیند یادگیری را نیز افزایش می دهد.

## ۴.۷ ردپای کربن

ردپای کربنی فرآیند تمرین مدل gaokerena-R بر اساس پیکربندی سخت افزاری و مدت زمان کل اجرا برآورد شده است. در این فرآیند، با بهره گیری از مجموعه داده ی ترجمه شده ی ماشینی MedMCQA [۵۱] و به کارگیری دوروش پیشنهادی همراه با بهینه سازی مستقیم ترجیحات مدل مورد نظر به مدت تقریبی یک ساعت بر روی یک کارت گرافیک NVIDIA H100 PCIe با حافظه ی 80 گیگابایت آموزش داده شد. در طول این فرآیند، حدود 43 گیگابایت از حافظه ی گرافیکی<sup>۷</sup> مورد استفاده قرار گرفت. نمودار تغییرات تابع خطا در طول آموزش در شکل ۳.۷ نمایش داده شده است.

با در نظر گرفتن میانگین توان مصرفی حدود 350 وات برای هر GPU، میزان کل انرژی مصرفی در این فرآیند

VRAM<sup>۷</sup>



شکل ۲.۷: بلوک دیاگرام شیوه دوم

تقریباً 0.35 کیلووات ساعت برآورد می شود. با توجه به شدت متوسط کربن شبکه‌ی برق کانادا، جایی که سرور ما در آن قرار داشت (هشتاد و شش گرم دی اکسید کربن معادل برای هر کیلووات ساعت)، میزان انتشار کربن حاصل از این فرآیند در حدود سی گرم دی اکسید کربن تخمین زده می شود.

در مقایسه با مدل قبلی ما، gaokerena-V، که انتشار تقریبی 2.66 کیلوگرم دی اکسید کربن داشت، این مقدار کاهش چشمگیری در تأثیرات زیست محیطی را نشان می دهد. این نتیجه بیانگر آن است که روش جدید ما نه تنها از نظر کارایی و بهینه سازی استدلال عملکرد بهتری دارد، بلکه از منظر پایداری زیست محیطی نیز بسیار کارآمدتر و سازگارتر با محیط زیست عمل می کند. [۶۵]

## ۵.۷ نتایج

در این بخش، مدل تازه توسعه یافته gaokerena-R را با مدل پیشین، gaokerena-V، مقایسه می کنیم. در حالی که gaokerena-V روی مجموعه داده های پزشکی بزرگی آموزش دیده و دانش پزشکی قوی و قابلیت های بازیابی خوبی را نشان می دهد، gaokerena-R به طور خاص برای تقویت استدلال پزشکی<sup>۱</sup> طراحی شده است. به دلیل خط مشی آموزشی متمرکز بر استدلال، gaokerena-R روی مجموعه داده ای به مراتب کوچک تر آموزش دیده که منجر به پوشش کمی محدودتر دانش پزشکی عمومی شده است. با این حال، مدل gaokerena-R توانسته شایستگی استدلالی عمیق تری نشان داده و در وظایفی که نیاز به استنتاج چند مرحله ای و انسجام منطقی دارند،

<sup>۱</sup>medical reasoning

## الگوریتم ۲.۷ شیوه دوم پیشنهاد شده برای بهبود دلیل آوری


- ورودی:** پرسش و پاسخ های چند گزینه پزشکی
- ۱: برای به ازای تمامی پرسش ها انجام بده
  - ۲: یکی از پرسش های پزشکی را از مدل دانشجو بپرس
  - ۳: اگر اگر پاسخ دانشجو درست بود آنگاه
  - ۴: این پرسش را کنار بگذار و به سراغ پرسش بعدی برو
  - ۵: پایان شرط اگر
  - ۶: پاسخ نادرست دانشجو را ذخیره کن
  - ۷: تا زمانی که تا زمانی که دانشجو پاسخ نادرست را نیافته است انجام بده
  - ۸: پاسخ نادرست دانشجو را به معلم بده و از او بخواه که استدلال نادرست را گزارش کند
  - ۹: گزارش معلم را به دانشجو بده و از او بخواه به پرسش دوباره پاسخ دهد
  - ۱۰: پایان حلقه تا زمانی که
  - ۱۱: پاسخ درست دانشجو را ذخیره کن
  - ۱۲: پاسخ درست و نادرست را به عنوان جفت ذخیره کن
  - ۱۳: اگر در صورت جمع شدن تعداد کافی جفت پاسخ درست و نادرست آنگاه
  - ۱۴: مدل دانشجو را با استفاده از بهینه سازی مستقیم ترجیحات تمرین بده
  - ۱۵: پایان شرط اگر
  - ۱۶: پایان حلقه برای

عملکرد بهتری داشته باشد. در ارزیابی نهایی، عملکرد gaokerena-V با استفاده از درخواست های<sup>۹</sup> مستقیم با عملکرد gaokerena-R هنگام استفاده از درخواست های زنجیره ای فکری<sup>۱۰</sup> مقایسه میشود. نتایج نشان می دهد که gaokerena-R، با وجود مقیاس کوچک تر و داده های آموزشی محدود، از طریق هدایت استدلال ساختاریافته، عملکرد برتری را نشان داده و این موضوع اثربخشی بهینه سازی متمرکز بر استدلال را در مقایسه با افزایش صرف مقیاس داده ها نشان می دهد.

## ۱.۵.۷ سنجش استدلال پزشکی

برای ارزیابی قابلیت های استدلال پزشکی مدل ها، از آن ها خواستیم تا مسیرهای استدلال زنجیره ای فکری را با تنظیم دمای 1.0 تولید کنند. از آنجا که همه مدل ها ممکن است پاسخ های متفاوتی برای یک پرسش یکسان ارائه دهند، عملکرد آن ها را با استفاده از دو معیار دقت و pass@k [۸۰] روی مجموعه داده های ترجمه فارسی

<sup>۹</sup> prompt  
<sup>۱۰</sup> chain of thought



شکل ۳.۷: نمودار کاهش خطا بهینه سازی مستقیم ترجیحات

MMLU [۱۱] و کنکور علوم پایه پزشکی شهریور ۱۴۰۱ ارزیابی شده است.

#### ۱.۱.۵.۷ دقت

معیار اول، دقت برای هر پرسش در مجموعه داده‌ها است. برای هر پرسش، پنج نمونه مستقل تولید شد و مکانیزم رای گیری اکثریت اعمال گردید: اگر سه یا بیشتر از پنج پاسخ تولید شده گزینه یکسانی را انتخاب کردند، آن گزینه به عنوان پیش بینی نهایی انتخاب شد؛ در غیر این صورت، پرسش بدون پاسخ باقی ماند تا عدم قطعیت مدل را نشان دهد. این چارچوب، برآورد قوی‌ای از سازگاری استدلالی در مسیرهای مختلف ارائه می‌دهد. نتایج در جدول ۱.۷ (بدون نمره منفی) و جدول ۲.۷ (با نمره منفی) ارائه شده‌اند، جایی که در تنظیم نمره منفی، هر سؤال پاسخ داده شده به صورت نادرست، امتیاز -0.33 دریافت می‌کند.

#### Pass@k ۲.۱.۵.۷

معیار Pass@k که ابتدا توسط براون و همکاران معرفی شد، یک معیار قوی برای ارزیابی مدل‌های زبانی ارائه می‌دهد که برای یک ورودی یکسان، در نمونه‌گیری‌های متعدد، خروجی‌های متفاوتی تولید می‌کنند. این معیار، احتمال اینکه مدل حداقل یک پاسخ درست را در k تلاش مستقل تولید کند، محاسبه می‌کند و بدین ترتیب ارزیابی جامع‌تری از قابلیت اطمینان استدلال و تنوع نمونه‌ها ارائه می‌دهد. تعریف رسمی این معیار در فرمول

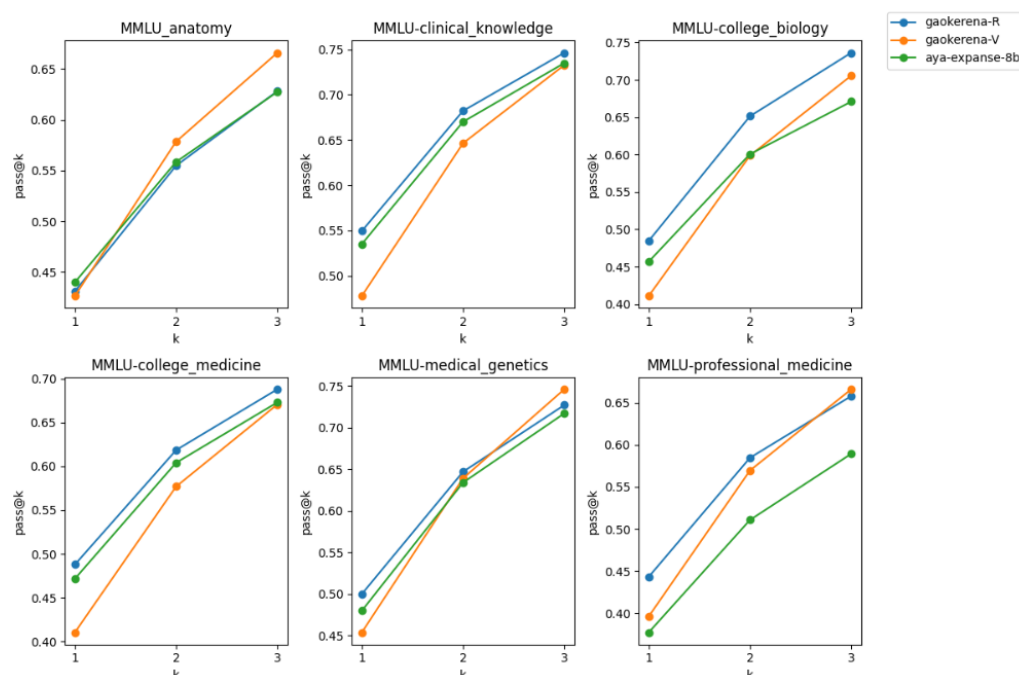
۱.۷ آمده است، که در آن  $N$  نشان دهنده تعداد کل نمونه های تولید شده و  $C_i$  نشان دهنده تعداد نمونه های درست برای مسئله  $i$  است.

$$\text{pass@k} = \frac{1}{\# \text{ of problems}} \sum_{i=1}^{\# \text{ of problems}} \left( 1 - \frac{\binom{N-C_i}{k}}{\binom{N}{k}} \right) \quad (1.7)$$

با پیروی از همان تنظیمات آزمایشی که پیش تر توضیح داده شد، امتیازهای  $\text{Pass@k}$  را با  $k = 1, 2, 3$  روی دو مجموعه داده ترجمه قسمت پزشکی MMLU و کنکور علوم پایه پزشکی شهریور 1401 محاسبه کردیم. ارزیابی شامل سه مدل گائوکرنا-R، گائوکرنا-V و aya-expanse-8b بود. نتایج مربوط به مجموعه داده ترجمه قسمت پزشکی MMLU در شکل ۴.۷ و نتایج کنکور علوم پایه پزشکی شهریور 1401 در شکل ۵.۷ نشان داده شده اند. همان طور که در شکل های ۴.۷ و ۵.۷ مشاهده می شود، مدل گائوکرنا-R به طور مداوم در تقریباً تمام مقادیر  $k$  و دسته های ارزیابی، عملکرد برتری از خود نشان داد. این بهبود حاکی از آن است که گائوکرنا-R از قابلیت های استدلالی پایدارتر و منسجم تری برخوردار است و حتی با تعداد نمونه های محدود، پاسخ های درست را با اطمینان بیشتری تولید می کند. در مقابل، مدل گائوکرنا-V در مقادیر کوچک  $k$  عملکرد نسبتاً ضعیفی داشت، اما با افزایش  $k$  نتایج آن بهبود یافت. این الگو نشان می دهد که گائوکرنا-V هنگام تولید مسیرهای استدلالی زنجیره ای افکار به طور قابل توجهی نامطمئن تر عمل می کند و اغلب در نمونه های مختلف، پاسخ های متنوع یا ناسازگاری تولید می نماید. بنابراین نتایج، برتری چشمگیر در ثبات و قابلیت اطمینان استدلال را که از طریق رویکرد آموزشی هدفمند و متمرکز بر استدلال در مدل گائوکرنا-R به دست آمده است، به خوبی برجسته می کنند.

## ۲.۵.۷ سنجش دانش پزشکی

همان طور که پیش تر اشاره شد، مدل گائوکرنا-V دارای پایه دانش پزشکی گسترده تری نسبت به مدل جدیدتر گائوکرنا-R است؛ عمدتاً به این دلیل که بر روی مجموعه داده های پزشکی به مراتب بزرگ تر و متنوع تری آموزش دیده است. این تفاوت به ویژه زمانی آشکار می شود که هر دو مدل با درخواست های مستقیم ارزیابی شوند، نه زمانی که از آن ها درخواست زنجیره افکار می شود؛ زیرا در حالت دوم، توانایی استدلال مدل نیز بر عملکرد نهایی تاثیر قابل توجهی می گذارد. همان طور که در جدول ۳.۷ نشان داده شده، در شرایط درخواست مستقیم، گائوکرنا-V عملکرد برتری از خود نشان می دهد که این امر بیانگر توانایی قوی تر آن در به خاطر سپردن و بازیابی حقایق پزشکی ناشی از پیش آموزش گسترده است. نکته جالب توجه اینکه عملکرد گائوکرنا-R و مدل پایه آن aya-expanse-8b در شرایط درخواست مستقیم تقریباً برابر است. این مشاهدت حاکی از آن است که برتری



شکل ۴.۷: نتایج Pass@k روی مجموعه داده ترجمه قسمت پزشکی MMLU


گائوکرنا-R در سناریوهای زنجیره افکار، عمدتاً ناشی از مهارت‌های استدلالی پیشرفته‌تر آن نسبت به مدل پایه است، نه افزایش قابل توجه دانش پزشکی.

### ۳.۵.۷ سنجش پایانی

همان‌طور که پیش‌تر بحث شد، مدل گائوکرنا-V در حالت درخواست مستقیم عملکرد بهتری از خود نشان می‌دهد، در حالی که گائوکرنا-R زمانی برتر است که از آن درخواست زنجیره افکار شود؛ یعنی از مدل خواسته شود پیش از ارائه پاسخ نهایی، گام به گام استدلال کند. یکی از مزایای کلیدی پرامپت کردن با زنجیره افکار - به‌ویژه هنگامی که با نمونه‌برداری چندگانه<sup>۱۱</sup> و رای‌گیری اکثریت<sup>۱۲</sup> ترکیب شود - این است که به‌طور طبیعی میزان اطمینان مدل را نشان می‌دهد. اگر پاسخ‌های تولیدشده در نمونه‌های مختلف به یک گزینه همگرا شوند، می‌توان مدل را مطمئن دانست؛ در مقابل، پراکندگی زیاد پاسخ‌ها نشان‌دهنده عدم اطمینان مدل است. این روش جایگزین عملی و مؤثری برای پرس‌وجو مستقیم از «اطمینان خودارزیابی شده مدل» به شمار می‌رود؛ قابلیت‌های مدل‌های کوچک‌تر معمولاً به دلیل محدودیت در خودآگاهی و توانایی استدلال درون‌نگرانه از آن بی‌بهره‌اند. [۸۱]

<sup>۱۱</sup> multiple sampling  
<sup>۱۲</sup> majority voting





شکل ۵.۷: نتایج Pass@k روی مجموعه داده کنکور علوم پایه پزشکی شهریور ۱۴۰۱

در مواردی که گائوکرنا-R عدم اطمینان نشان می دهد (یعنی چندین پاسخ متمایز تولید می کند)، از مدل پایه یعنی aya-expanse-8b به عنوان یک تاییدکننده کمکی<sup>۱۳</sup> استفاده می کنیم. پاسخ های تولید شده توسط گائوکرنا-R به aya-expanse-8b ارائه می شود و این مدل مأمور می شود گزینه ای را انتخاب کند که کمترین اطلاعات نادرست یا ناسازگار را داشته باشد.

در نتیجه، دو پیکربندی زیر را با هم مقایسه کردیم که در جدول ۴.۷ خلاصه شده اند:

- گائوکرنا-V فقط با درخواست مستقیم و بدون هیچ گونه راهنمایی استدلالی ارزیابی می شود.
- به گائوکرنا-R درخواست زنجیره افکار داده می شود و در صورت بروز عدم اطمینان، پاسخ های تولید شده آن توسط aya-expanse-8b بررسی و معتبرترین پاسخ انتخاب می شود.

<sup>۱۳</sup>verifier auxiliary

<b>aya- expanse-8b</b> (baseline)	<b>gao kerena-V</b>	<b>gao kerena-R</b>	
40.74	39.25	<b>42.22</b>	MMLU- anatomy(fa)
45.0	41.0	<b>50.0</b>	MMLU- medical-genetics(fa)
<b>48.55</b>	37.57	47.97	MMLU- college-medicine(fa)
54.71	46.79	<b>55.84</b>	MMLU- clinical-knowledge(fa)
43.75	37.13	<b>44.85</b>	MMLU- professional- medicine(fa)
43.75	36.80	<b>48.61</b>	MMLU- college-biology(fa)
47.10	40.40	<b>48.76</b>	MMLU(avg)
35.71	29.76	<b>38.69</b>	IBMSEE Sept2023
8b	8b	8b	of Number parameters
$\approx 5 \times 35s$	$\approx 5 \times 35s$	$\approx 5 \times 35s$	time inference

جدول ۱.۷: دقت با درخواست زنجیره افکار بدون نمره منفی

<b>aya- expanse-8b (baseline)</b>	<b>gao kerena-V</b>	<b>gao kerena-R</b>	
24.93	27.65	<b>29.13</b>	MMLU- anatomy(fa)
33.0	32.0	<b>40.0</b>	MMLU- medical-genetics(fa)
34.48	25.24	<b>34.68</b>	MMLU- college-medicine(fa)
42.51	35.59	<b>44.65</b>	MMLU- clinical-knowledge(fa)
<b>30.39</b>	25.0	<b>30.39</b>	MMLU- professional- medicine(fa)
30.09	25.0	<b>36.80</b>	MMLU- college-biology(fa)
33.55	28.57	<b>36.14</b>	MMLU(avg)
19.84	15.87	<b>24.60</b>	IBMSEE Sept2023
8b	8b	8b	of Number parameters
$\approx 5 \times 35s$	$\approx 5 \times 35s$	$\approx 5 \times 35s$	time inference

جدول ۲.۷: دقت با درخواست زنجیره افکار با نمره منفی

<b>aya- expanse-8b</b> (baseline)	<b>gao kerena-V</b>	<b>gao kerena-R</b>	
40.74	<b>48.14</b>	41.48	MMLU- anatomy(fa)
49.0	<b>53.0</b>	49.0	MMLU- medical-genetics(fa)
44.51	43.93	<b>46.24</b>	MMLU- college-medicine(fa)
52.07	<b>55.47</b>	52.45	MMLU- clinical-knowledge(fa)
45.58	<b>47.05</b>	41.91	MMLU- professional- medicine(fa)
45.14	<b>47.22</b>	44.44	MMLU- college-biology(fa)
46.64	<b>49.31</b>	46.28	MMLU(avg)
34.52	<b>38.69</b>	35.11	IBMSEE Sept2023
8b	8b	8b	of Number parameters
$\approx 10s$	$\approx 10s$	$\approx 10s$	time inference

جدول ۳.۷: دقت با درخواست مستقیم

<b>gaokerena-V</b>	<b>gaokerena-R</b> + <b>aya-expanse-8b</b> (verifier)	
<b>48.14</b>	47.40	MMLU- anatomy(fa)
53.0	<b>56.0</b>	MMLU- medical-genetics(fa)
43.93	<b>50.28</b>	MMLU- college-medicine(fa)
55.47	<b>58.86</b>	MMLU- clinical-knowledge(fa)
47.05	<b>48.89</b>	MMLU- professional- medicine(fa)
47.22	<b>54.86</b>	MMLU- college-biology(fa)
49.31	<b>52.98</b>	MMLU(avg)
38.69	<b>46.42</b>	IBMSEE Sept2023
Straight	COT for the main model Straight for the verifier	prompt
$\approx 10s$	$\approx 5 \times 35 + 8s$	time inference

جدول ۴.۷: ارزیابی دو پیکربندی

## فصل ۸

### نتیجه گیری

در این پایان نامه، علاوه بر جمع آوری و معرفی مجموعه داده پزشکی فارسی، دو مدل زبانی کوچک تخصصی پزشکی نیز آموزش داده و ارائه شدند. نتایج به دست آمده نشان دهنده عملکرد مطلوب این مدل ها است و می توانند به عنوان گام های اولیه در مسیر توسعه مدل های زبانی کوچک و کارآمد پزشکی به زبان فارسی محسوب شوند. نوآوری های این پایان نامه به شرح زیر است:

- معرفی اولین مدل های زبانی پزشکی فارسی منبع باز که در مقایسه با سایر مدل های قابل اجرا روی دستگاه های خانگی (مانند لپ تاپ و کامپیوتر شخصی) به نتایج امیدوارکننده دست یافته است.
- معرفی یک پیکره پزشکی فارسی که از طریق خزش<sup>۱</sup> وب سایت های مختلف پزشکی جمع آوری شده است.
- معرفی اولین مجموعه داده پرسش و پاسخ پزشکی فارسی فرم آزاد<sup>۲</sup> که از طریق خزش سایت های پرسش و پاسخ پزشکی جمع آوری شده است.
- ترجمه بخش پزشکی مجموعه داده MMLU به زبان فارسی که می تواند به عنوان یک معیار استاندارد و قابل اعتماد برای ارزیابی هر مدل زبانی پزشکی فارسی مورد استفاده قرار گیرد.
- معرفی چارچوب های کارآمد که با استفاده از یک حلقه آموزگار-شاگرد باعث بهبود توانایی دلیل آوری مدل زبانی شاگرد میشوند.

---

<sup>۱</sup>crawling  
<sup>۲</sup>free form

## ۱.۸ تحقیقات آینده

هرچند مدل های معرفی شده در مقایسه با مدل پایه و سایر گزینه های موجود، دانش پزشکی فارسی به مراتب بهتری از خود نشان می دهد، اما عملکرد فعلی آن هنوز به سطحی نرسیده است که بتوان آن را به طور قابل اعتماد در سناریوهای بالینی واقعی به کار گرفت. در تحقیقات آینده پارامترهای به روز شده خود را به جای aya-expanse، با مدل aya-vision ادغام کنیم تا مدل قادر به پذیرش ورودی های چندوجهی<sup>۳</sup> نظیر تصاویر پزشکی شود. با این حال، توانایی مدل در پردازش پرسش های چندوجهی هنوز به طور جامع بررسی نشده است. در تحقیقات آتی، تمرکز اصلی ما بر بهبود توانایی مدل در درک و هم راستا کردن اطلاعات متنی و بصری خواهد بود تا کاربرد تشخیصی و تحلیلی آن در پزشکی گسترش یابد. همچنین، کارهای آینده شامل همکاری نزدیک با پزشکان واقعی برای بهبود مدل از طریق یادگیری تقویتی مبتنی بر بازخورد انسانی<sup>۴</sup> و اعتبارسنجی بالینی دقیق خواهد بود تا ایمنی و قابلیت استفاده عملی مدل در محیط های واقعی مراقبت های بهداشتی تضمین شود.

<sup>۳</sup>multimodal  
<sup>۴</sup>reinforcement learning with human feedback

## کتاب نامه

- Momani, Ahmad. "Implications of Artificial Intelligence on Health Data Privacy and Confidentiality." arXiv preprint arXiv:2501.01639 .(2025) [۱]
- Brown, Peter F., et al. "A statistical approach to machine translation." (1990): 79-85. [۲]
- Williams, Ronald J., and David Zipser. "A learning algorithm for continually running fully recurrent neural networks." Neural computation 1.2 (1989): 270-280. [۳]
- Hochreiter, Sepp, and Jürgen Schmidhuber. "Long short-term memory." Neural computation 9.8 (1997): 1735-1780. [۴]
- Vaswani, Ashish, et al. "Attention is all you need." Advances in neural information processing systems 30 (2017). [۵]
- Koroteev, Mikhail V. "BERT: a review of applications in natural language processing and understanding." arXiv preprint arXiv:2103.11943 (2021). [۶]
- Devlin, Jacob, et al. "Bert: Pre-training of deep bidirectional transformers for language understanding." Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019. [۷]
- Yenduri, Gokul, et al. "Generative pre-trained transformer: A comprehensive review on enabling technologies, potential applications, emerging challenges, and future directions." arXiv preprint arXiv:2305.10435 (2023). [۸]



- Raffel, Colin, et al. "Exploring the limits of transfer learning with a unified text-to-text transformer." *Journal of machine learning research* 21.140 (2020): 1-67. [۹]
- Luo, Man, et al. "Choose your QA model wisely: A systematic study of generative and extractive readers for question answering." *arXiv preprint arXiv:2203.07522* (2022). [۱۰]
- Hendrycks, Dan, et al. "Measuring massive multitask language understanding." *arXiv preprint arXiv:2009.03300* (2020). [۱۱]
- Liu, Yang, et al. "G-eval: NLG evaluation using gpt-4 with better human alignment." *arXiv preprint arXiv:2303.16634* (2023). [۱۲]
- Manes, Itay, et al. "K-qa: A real-world medical q&a benchmark." *arXiv preprint arXiv:2401.14493* (2024). [۱۳]
- Zhang, Tianyi, et al. "Bertscore: Evaluating text generation with bert." *arXiv preprint arXiv:1904.09675* (2019). [۱۴]
- Christiano, Paul F., et al. "Deep reinforcement learning from human preferences." *Advances in neural information processing systems* 30 (2017): 3537-3546. [۱۵]
- Lee, Harrison, et al. "Rlaif vs. rlhf: Scaling reinforcement learning from human feedback with ai feedback." *arXiv preprint arXiv:2309.00267* (2023). [۱۶]
- Schulman, John, et al. "Proximal policy optimization algorithms." *arXiv preprint arXiv:1707.06347* (2017). [۱۷]
- Shao, Zhihong, et al. "Deepseekmath: Pushing the limits of mathematical reasoning in open language models." *arXiv preprint arXiv:2402.03300* (2024). [۱۸]
- Rafailov, Rafael, et al. "Direct preference optimization: Your language model is secretly a reward model." *Advances in neural information processing systems* 36 (2023): 53728-53741. [۱۹]

- Ji, Kaixuan, et al. "Enhancing multi-step reasoning abilities of language models [۲۰] through direct q-function optimization." arXiv preprint arXiv:2410.09302. (2024)
- Haarnoja, Tuomas, et al. "Soft actor-critic: Off-policy maximum entropy deep re- [۲۱] inforcement learning with a stochastic actor." International conference on machine learning. Pmlr, .2018
- Singhal, Karan, et al. "Toward expert-level medical question answering with large [۲۲] language models." Nature Medicine (2025): 1-8.
- Singhal, Karan, et al. "Large language models encode clinical knowledge." Nature [۲۳] 620.7972 (2023): 172-180.
- Saab, Khaled, et al. "Capabilities of gemini models in medicine." arXiv preprint [۲۴] arXiv:2404.18416 (2024).
- Li, Yunxiang, et al. "Chatdoctor: A medical chat model fine-tuned on a large lan- [۲۵] guage model meta-ai (llama) using medical domain knowledge." Cureus 15.6 (2023).
- Touvron, Hugo, et al. "Llama: Open and efficient foundation language models." [۲۶] arXiv preprint arXiv:2302.13971 (2023).
- Kim, Hyunjae, et al. "Small language models learn enhanced reasoning skills from [۲۷] medical textbooks." arXiv preprint arXiv:2404.00376 (2024).
- Vishwanath, Krithik, et al. "MedMobile: A mobile-sized language model with [۲۸] expert-level clinical capabilities." arXiv preprint arXiv:2410.09019 (2024).
- Abdin, Marah, et al. "Phi-3 technical report: A highly capable language model lo- [۲۹] cally on your phone." arXiv preprint arXiv:2404.14219 (2024).
- Taghizadeh, Nasrin, et al. "SINA-BERT: a pre-trained language model for analysis [۳۰] of medical texts in Persian." arXiv preprint arXiv:2104.07613 (2021).

- Koroteev, Mikhail V. "BERT: a review of applications in natural language processing [۳۱] and understanding." arXiv preprint arXiv:2103.11943 (2021).
- Veisi, Hadi, and Hamed Fakour Shandi. "A Persian medical question answering sys- [۳۲] tem." International Journal on Artificial Intelligence Tools 29.06 (2020): 2050019.
- Darabi, Leila. Medical Question Answering for Persian. Master's thesis, LIACS, [۳۳] Leiden University, 2024.
- Farahani, Mehrdad, et al. "Parsbert: Transformer-based model for persian language [۳۴] understanding." Neural Processing Letters 53 (2021): 3831-3847.
- Jiang, Shuyang, et al. "MedS<sup>3</sup>: Towards Medical Slow Thinking with Self-Evolved [۳۵] Soft Dual-sided Process Supervision." arXiv preprint arXiv:2501.12051 .(2025)
- Coulom, Rémi. "Efficient selectivity and backup operators in Monte-Carlo tree [۳۶] search." International conference on computers and games. Berlin, Heidelberg: Springer Berlin Heidelberg, .2006
- Wu, Juncheng, et al. "Medreason: Eliciting factual medical reasoning steps in llms [۳۷] via knowledge graphs." arXiv preprint arXiv:2504.00993 .(2025)
- Chen, Junying, et al. "Huatuogpt-o1, towards medical complex reasoning with [۳۸] llms." arXiv preprint arXiv:2412.18925 .(2024)
- Guo, Daya, et al. "Deepseek-r1: Incentivizing reasoning capability in llms via rein- [۳۹] forcement learning." arXiv preprint arXiv:2501.12948 .(2025)
- Wu, Tianhao, et al. "Thinking llms: General instruction following with thought gen- [۴۰] eration." arXiv preprint arXiv:2410.10630 .(2024)
- Ho, Namgyu, Laura Schmid, and Se-Young Yun. "Large language models are rea- [۴۱] soning teachers." Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). 2023.

- García-Ferrero, Iker, et al. "Medical mT5: an open-source multilingual text-to-text LLM for the medical domain." arXiv preprint arXiv:2404.07613 (2024). [۴۲]
- Liu, Yang, et al. "Datasets for large language models: A comprehensive survey." arXiv preprint arXiv:2402.18041 (2024). [۴۳]
- Yang, Songhua, et al. "Zhongjing: Enhancing the chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue." Proceedings of the AAAI conference on artificial intelligence. Vol. 38. No. 17. 2024. [۴۴]
- Bao, Zhijie, et al. "Disc-medllm: Bridging general large language models and real-world medical consultation." arXiv preprint arXiv:2308.14346 (2023). [۴۵]
- Zhang, Hongbo, et al. "Huatuogpt, towards taming language model to be a doctor." arXiv preprint arXiv:2305.15075 (2023). [۴۶]
- Wang, Xidong, et al. "Huatu-26M, a Large-scale Chinese Medical QA Dataset." Findings of the Association for Computational Linguistics: NAACL 2025. 2025. [۴۷]
- Zeng, Guangtao, et al. "MedDialog: Large-scale medical dialogue datasets." Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP). 2020. [۴۸]
- Han, Tianyu, et al. "MedAlpaca—an open-source collection of medical conversational AI models and training data." arXiv preprint arXiv:2304.08247 (2023). [۴۹]
- Bi, Xiao, et al. "Deepseek llm: Scaling open-source language models with longtermism." arXiv preprint arXiv:2401.02954 (2024). [۵۰]
- Pal, Ankit, Logesh Kumar Umapathi, and Malaikannan Sankarasubbu. "Medmcqa: A large-scale multi-subject multi-choice dataset for medical domain question answering." Conference on health, inference, and learning. PMLR, .2022 [۵۱]
- C-LARA-Instance, Manny Rayner ChatGPT. "How Woke is Grok? Empirical Evidence that xAI's Grok Aligns Closely with Other Frontier Models." (2025) [۵۲]

- Achiam, Josh, et al. "Gpt-4 technical report." arXiv preprint arXiv:2303.08774 [۵۳] (2023).
- Jamali, Naghmeh, et al. "PerMedCQA: Benchmarking Large Language Models [۵۴] on Medical Consumer Question Answering in Persian Language." arXiv preprint arXiv:2505.18331 (2025).
- Kalahroodi, Mohammad Javad Ranjbar, et al. "PersianMedQA: Language- [۵۵] Centric Evaluation of LLMs in the Persian Medical Domain." arXiv preprint arXiv:2506.00250 (2025).
- Yang, An, et al. "Qwen2 Technical Report." arXiv Preprint arXiv:2407.10671, 2024. [۵۶]
- Dang, John, et al. "Aya expanse: Combining research breakthroughs for a new mul- [۵۷] tilingual frontier." arXiv preprint arXiv:2412.04261 (2024).
- Team, Gemma, et al. "Gemma 2: Improving open language models at a practical [۵۸] size, 2024." URL <https://arxiv.org/abs/2408.00118> 1.3 (2024).
- Rostami, Pedram, Ali Salemi, and Mohammad Javad Dousti. "Persian- [۵۹] mind: A cross-lingual persian-english large language model." arXiv preprint arXiv:2401.06466 (2024).
- Dash, Saurabh, et al. "Aya Vision: Advancing the Frontier of Multilingual Multi- [۶۰] modality." arXiv preprint arXiv:2505.08751 (2025).
- Shumailov, Ilia, et al. "AI models collapse when trained on recursively generated [۶۱] data." Nature 631.8022 (2024): 755-759.
- Odumakinde, Ayomide, et al. "Multilingual arbitrage: Optimizing data pools to ac- [۶۲] celerate multilingual progress, 2024." URL <https://arxiv.org/abs/2408.14960>.
- Hu, Edward J., et al. "Lora: Low-rank adaptation of large language models." ICLR [۶۳] 1.2 (2022): 3.

- Dao, Tri. "Flashattention-2: Faster attention with better parallelism and work partitioning." arXiv preprint arXiv:2307.08691 (2023). [۶۴]
- Lacoste, Alexandre, et al. "Quantifying the carbon emissions of machine learning." arXiv preprint arXiv:1910.09700 (2019). [۶۵]
- Hurst, Aaron, et al. "Gpt-4o system card." arXiv preprint arXiv:2410.21276 (2024). [۶۶]
- Khashabi, Daniel, et al. "Parsinlu: a suite of language understanding challenges for persian." Transactions of the Association for Computational Linguistics 9 (2021): 1147-1162. [۶۷]
- Kashefi, Omid. "MIZAN: a large persian-english parallel corpus." arXiv preprint arXiv:1801.02107 (2018). [۶۸]
- Bengio, Yoshua. "From system 1 deep learning to system 2 deep learning." Neural Information Processing Systems. 2019. [۶۹]
- Kahneman, Daniel. "Thinking, fast and slow." Farrar, Straus and Giroux. (2011) [۷۰]
- Goyal, Anirudh, et al. "Recurrent independent mechanisms." arXiv preprint arXiv:1909.10893. (2019) [۷۱]
- Wang, Guan, et al. "Hierarchical Reasoning Model." arXiv preprint arXiv:2506.21734. (2025) [۷۲]
- Pan, Liangming, et al. "Automatically correcting large language models: Surveying the landscape of diverse self-correction strategies." arXiv preprint arXiv:2308.03188. (2023) [۷۳]
- Liang, Baoyu, Yuchen Wang, and Chao Tong. "AI Reasoning in Deep Learning Era: From Symbolic AI to Neural-Symbolic AI." Mathematics 13.11 (2025): 1707. [۷۴]
- Lightman, Hunter, et al. "Let's verify step by step." The Twelfth International Conference on Learning Representations. 2023. [۷۵]

- Huang, Jie, and Kevin Chen-Chuan Chang. "Towards reasoning in large language [۷۶] models: A survey." Findings of the association for computational linguistics: ACL 2023. 2023.
- Shojaee, Parshin, et al. "The illusion of thinking: Understanding the strengths and [۷۷] limitations of reasoning models via the lens of problem complexity." arXiv preprint arXiv:2506.06941 .(2025)
- Wei, Jason, et al. "Emergent abilities of large language models." arXiv preprint [۷۸] arXiv:2206.07682 .(2022)
- Wei, Jason, et al. "Chain-of-thought prompting elicits reasoning in large language [۷۹] models." Advances in neural information processing systems 35 (2022): 24824-24837.
- Brown, Bradley, et al. "Large language monkeys: Scaling inference compute with [۸۰] repeated sampling." arXiv preprint arXiv:2407.21787 .(2024)
- Zhang, Mozhi, et al. "Calibrating the confidence of large language models by eliciting [۸۱] fidelity." arXiv preprint arXiv:2404.02655 .(2024)

# پیوست آ

## اجرای مدل های زبانی

### آ.۱ اجرای مدل ها

وزن های مدل های معرفی شده به صورت عمومی منتشر شده است برای دریافت آن میتوانید به مخزن هاگینگ فیس گائوکرنا<sup>۱</sup> مراجعه کنید؛ برای اجرای این مدل ها میتوانید از برنامه آ.۱ برای دادن تنها متن به ورودی و از برنامه آ.۲ برای دادن متن و تصویر به ورودی استفاده کنید.

کیفیت پاسخدهی مدل در حالت چندوجهی (ورودی همزمان متن و تصویر) در چارچوب این پایان نامه به صورت جامع ارزیابی نشده است و نتایج ممکن است بسته به کیفیت تصویر، رزولوشن و نوع پرسش متفاوت باشد. بنابراین توصیه می شود در کاربردهای حساس ابتدا ارزیابی های اضافی انجام دهید.

---

<sup>۱</sup>[huggingface.co/gaokerena](https://huggingface.co/gaokerena)



```

import torch 1
from transformers import AutoModelForCausalLM, 2
    AutoTokenizer, pipeline 3
from peft.peft_model import PeftModel 4

device = "cuda" if torch.cuda.is_available() else "cpu" 5
dtype = torch.bfloat16 6

base_model_id = "CohereForAI/aya-expanse-8b" 7
our_model_id = "gaokerena/gaokerena-v1.0" 8
# our_model_id = "gaokerena/gaokerena-r1.0" 9

model = AutoModelForCausalLM.from_pretrained( 10
    base_model_id, 11
    torch_dtype=dtype, 12
    device_map=device 13
) 14
tokenizer = AutoTokenizer.from_pretrained(base_model_id) 15

model = PeftModel.from_pretrained(model = model, 16
    model_id = our_model_id) 17
model = model.merge_and_unload() 18

pipe = pipeline("text-generation", model=model, 19
    tokenizer=tokenizer) 20
pipe_output = pipe([{"role": "user", 21
    "content": "your prompt!"}], 22
    max_new_tokens=1024, 23
    eos_token_id=[tokenizer.eos_token_id], 24
    do_sample=False, 25
) 26

output = pipe_output[0]["generated_text"][-1]["content"] 27
print(output) 28

```

برنامه آ.۱: اجرای مدل های زبانی ورودی فقط متن

```

1 from transformers import AutoProcessor,
2   AutoModelForImageTextToText
3 import torch
4 from peft.peft_model import PeftModel
5
6 base_model_id = "CohereForAI/aya-expanse-8b"
7 our_model_id = "gaokerena/gaokerena-v1.0"
8 #our_model_id = "gaokerena/gaokerena-r1.0"
9
10 processor = AutoProcessor.from_pretrained(base_model_id)
11 model = AutoModelForImageTextToText.from_pretrained(
12     base_model_id, device_map="auto",
13     torch_dtype=torch.float16
14 )
15 model = PeftModel.from_pretrained(model=model,
16                                   model_id=our_model_id)
17 model = model.merge_and_unload()
18
19 messages = [
20     {"role": "user",
21      "content": [
22          {"type": "image", "url": "your image!"},
23          {"type": "text", "text": "your prompt!"},
24      ]},
25 ]
26
27 inputs = processor.apply_chat_template(
28     messages, padding=True, add_generation_prompt=True,
29     tokenize=True, return_dict=True, return_tensors="pt"
30 ).to(model.device)
31
32 gen_tokens = model.generate(
33     **inputs,
34     max_new_tokens=1024,
35     do_sample=True,
36     temperature=0.3,
37 )
38 print(processor.tokenizer.decode(
39     gen_tokens[0][inputs.input_ids.shape[1]:],
40     skip_special_tokens=True))

```

برنامه آ.۲: اجرای مدل های زبانی ورودی متن و تصویر







## Abstract

The use of artificial intelligence in answering medical questions is recognized as one of the emerging and critical fields in technology and healthcare, which has garnered widespread attention in recent years. This advanced technology, with its unique capabilities, can significantly enhance the quality of medical services provided to patients. Additionally, by accelerating the process of delivering medical information and providing quick and accurate responses to the questions of doctors and patients, it plays a vital role in reducing the workload of physicians. As such, artificial intelligence not only increases efficiency in healthcare systems but also improves the overall patient experience and paves the way for better and more effective treatments. On the other hand, since medicine is based on reasoning and logical analysis, developing a medical model designed on a chain of logical thoughts and reasoning can significantly enhance the accuracy and efficiency of such a model. This approach facilitates the execution of complex diagnostic and therapeutic processes in a more structured and purposeful manner. In this regard, every stage of diagnosis and treatment must be based on scientific evidence and reliable data. For instance, in the process of diagnosing diseases, doctors typically rely on medical history, clinical symptoms, and test results. By designing a logical model, these data can be interconnected in a logical chain, helping identify patterns and relationships between symptoms and diseases.

**Keywords** Artificial Intelligence in medicine, Persian language models, Medical language models, Natural language processing, Artificial Intelligence reasoning





University of Isfahan  
Faculty of Computer Engineering

# **Developing a medical language model based on reasoning in Persian language**

A Thesis submitted to the Graduate Studies Office  
In partial fulfillment of the requirements for  
The degree of Master of Science  
in Computer Engineering - Artificial Intelligence and Robotics

By:

**Mehrdad Ghassabi**

Supervisor:

**Dr. Hamidreza Baradaran Kashani**

Dec 2025