



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر

توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی

پایان نامه برای دریافت درجه کارشناسی ارشد در رشته هوش مصنوعی و رباتیک

مهرداد قصابی

استاد راهنما

دکتر حمیدرضا برادران کاشانی

بهمن ۱۴۰۴

齊民要術



دانشگاه اصفهان
دانشکده مهندسی کامپیوتر

توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی

پایان نامه برای دریافت درجه کارشناسی ارشد در رشته هوش مصنوعی و رباتیک

مهرداد قصابی

استاد راهنما

دکتر حمیدرضا برادران کاشانی

بهمن ۱۴۰۴



گواهی دفاع از پایان نامه کارشناسی ارشد

هیات داوران پایان نامه کارشناسی ارشد آقای مهرداد قصابی به شماره دانشجویی ۴۰۲۳۶۱۴۰۲۹ در رشته هوش

مصنوعی را در تاریخ ۱۴۰۴/۱۱/۲۱ با عنوان « توسعه یک مدل زبانی پزشکی مبتنی بر استدلال در زبان فارسی »
به عدد به حروف

--	--

با نمره نهایی

ارزیابی کرد.

--

و درجه

ردیف	مشخصات هیات داوران	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا موسسه	امضا
۱	استاد راهنما	دکتر حمیدرضا برادران کاشانی	استاد	دانشگاه اصفهان	
۲	استاد داور داخلی	دکتر الهام کردی قصردشتی	استاد	دانشگاه اصفهان	
۳	استاد مدعو	دکتر محمدعلی نعمت بخش	استاد	دانشگاه اصفهان	
۴	نماینده تحصیلات تکمیلی دانشکده	دکتر فریا نصیری مفخم	استاد	دانشگاه اصفهان	

نام و نام خانوادگی معاون آموزشی و تحصیلات

تکمیلی پردیس دانشکده های فنی:

تاریخ و امضا:

نام و نام خانوادگی معاون تحصیلات تکمیلی و

پژوهشی دانشکده / گروه:

تاریخ و امضا:

تعهدنامه اصالت اثر

به نام خدا

اینجانب مهرداد قصابی تأیید می‌کنم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آن‌ها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتری ارائه نشده است.

نام و نام خانوادگی دانشجو: مهرداد قصابی

تاریخ و امضای دانشجو:

کلیه حقوق مادی و معنوی این اثر
متعلق به دانشگاه اصفهان است.

تقديم به:

هم کلاسی عزیزم محمد جعفرپور

قدردانی

دستان پدر و مادر نازنینم را به پاس مهر بیکرانشان میبوسم و از استاد راهنما خود جناب آقای دکتر حمیدرضا برادران بابت راهنمایی هایشان در طول انجام این پایان نامه سپاس گزاری میکنم.

مهرداد قصابی

بهمن ۱۴۰۴

چکیده

استفاده از هوش مصنوعی در پاسخگویی به سوالات پزشکی به عنوان یکی از حوزه‌های نوظهور و مهم در فناوری و بهداشت، در سال‌های اخیر توجه زیادی را به خود جلب کرده است. در حالی که تحقیقات گسترده‌ای در این زمینه به زبان انگلیسی منتشر شده، در زمان آغاز این پایان‌نامه، حوزه زبان فارسی خالی از پژوهش بود. در فاز نخست این تحقیق، یک پیکره پزشکی شامل نود میلیون توکن و مجموعه داده‌ای متشکل از بیست هزار پرسش و پاسخ پزشکی که توسط پزشکان پاسخ داده شده، از مجلات و تالارهای پرسش و پاسخ آنلاین جمع‌آوری شد. با استفاده از بخشی از این داده‌ها، مدل پایه «آیا اکسپنس» آموزش داده شد و مدل جدیدی به نام «گائوکرنا وی» معرفی گردید که موفق به کسب 2.67 درصد عملکرد بهتر نسبت به مدل پایه خود بر روی مجموعه داده MMLU پزشکی ترجمه شده به زبان فارسی شد. در فاز دوم، با توجه به اینکه پزشکی به شدت وابسته به استدلال و تحلیل‌های منطقی است، یک مدل جدید مبتنی بر زنجیره‌ای از افکار و استدلال‌های منطقی طراحی شد تا دقت و کارایی آن را به طور قابل توجهی افزایش دهد. برای این منظور، دو چهارچوب جدید بر اساس یادگیری تقویتی با بازخورد هوش مصنوعی معرفی شد تا قابلیت دلیل‌آوری مدل پایه یعنی آیا اکسپنس را از طریق بهینه‌سازی مستقیم ترجیحات بهبود بخشد. نتیجه این بهبود، مدل «گائوکرنا آر» بود که با وجود آموزش بر روی تعداد توکن‌های بسیار کمتر نسبت به گائوکرنا وی، موفق به کسب 6.34 درصد عملکرد بهتر نسبت به مدل پایه خود بر روی همان مجموعه داده MMLU پزشکی ترجمه شده به زبان فارسی شد که این میزان بهبود نشان‌دهنده اهمیت استدلال در حوزه پزشکی است.

واژگان کلیدی هوش مصنوعی در پزشکی، مدل‌های زبانی فارسی، مدل‌های زبانی پزشکی، پردازش زبان‌های طبیعی، توانایی استدلال هوش مصنوعی

فهرست مطالب

ج	فهرست تصاویر
چ	فهرست جداول
ح	فهرست الگوریتم‌ها
د	فهرست برنامه‌ها
۱	فصل ۱: دیباچه
۱	۱.۱ هدف پژوهش
۲	۲.۱ کاربرد پژوهش
۲	۱.۲.۱ کاربرد مدل های زبانی پزشکی
۲	۲.۲.۱ کاربرد مدل های زبانی پزشکی دارای قابلیت استدلال
۳	۳.۲.۱ کاربرد مدل های زبانی پزشکی فارسی
۳	۳.۱ مراحل انجام پایان نامه
۴	۴.۱ ساختار پایان نامه
۵	فصل ۲: ادبیات موضوع
۵	۱.۲ مقدمه
۵	۲.۲ مدل های زبانی
۶	۱.۲.۲ مدل های زبانی آماری
۶	۲.۲.۲ مدل های زبانی بازگشتی

۳.۲.۲	مدل های زبانی مبتنی بر ترنسفورمر	۷
۱.۳.۲.۲	مدل های زبانی فقط رمزگذار	۷
۲.۳.۲.۲	مدل های زبانی فقط رمزگشا	۸
۳.۳.۲.۲	مدل های زبانی رمزگذار-رمزگشا	۸
۳.۲	سیستم های پرسش و پاسخ	۸
۱.۳.۲	سیستم های پرسش و پاسخ استخراجی	۹
۲.۳.۲	سیستم های پرسش و پاسخ تولیدی	۹
۴.۲	شیوه های سنجش مدل های زبانی	۹
۱.۴.۲	سنجش بر اساس میزان پاسخگویی به پرسش و پاسخ های چند گزینه ای	۱۰
۲.۴.۲	سنجش بر اساس نظر مدل داور	۱۰
۳.۴.۲	سنجش بر اساس استنتاج زبان طبیعی	۱۱
۴.۴.۲	سنجش بر اساس امتیاز برت	۱۱
۵.۲	یادگیری تقویتی در مدل های زبانی	۱۲
۱.۵.۲	یادگیری تقویتی با بازخورد انسان یا هوش مصنوعی	۱۲
۲.۵.۲	الگوریتم های بهینه سازی مدل زبانی	۱۳
۶.۲	استدلال در مدل های زبانی	۱۴
۱.۶.۲	ناتوانی معماری ترنسفورمر در تفکر سیستم دو	۱۵
۲.۶.۲	طراحی یک معماری دارای قابلیت تفکر سیستم دو	۱۵
۳.۶.۲	بهبود توانایی دلیل آوری مدل های زبانی مبتنی بر ترنسفورمر	۱۶
۱.۳.۶.۲	روش های مبتنی بر هوش مصنوعی عصبی-نمادین	۱۶
۲.۳.۶.۲	روش های مبتنی بر راهنمایی مدل زبانی توسط یک مدل پاداش	۱۸
۳.۳.۶.۲	روش های مبتنی بر تمرین روی داده های دلیل آوری	۱۸

فصل ۳: بررسی کارهای پیشین

۱.۳	مقدمه	۲۱
۲.۳	کارهای پیشین در حوزه زبان انگلیسی	۲۱

۲۱	مدل های MedPaLM	۱.۲.۳
۲۲	مدل ChatDoctor	۲.۲.۳
۲۲	مدل های Meerkat	۳.۲.۳
۲۳	مدل MedMobile	۴.۲.۳
۲۳	کار های پیشین در حوزه زبان فارسی	۳.۳
۲۴	مدل Sina-bert	۱.۳.۳
۲۴	سیستم پرسش و پاسخ پزشکی دکتر ویسی و همکاران	۲.۳.۳
۲۴	پایان نامه کارشناسی ارشد خانم لیلا دارابی	۳.۳.۳
۲۵	بهبود قابلیت دلیل آوری در حوزه پزشکی	۴.۳
۲۵	مدل MedSSS	۱.۴.۳
۲۶	مدل MedReason	۲.۴.۳
۲۷	مدل HuatuoGPT-o1	۳.۴.۳
۲۷	بهبود قابلیت دلیل آوری در حوزه های دیگر	۵.۳
۲۷	مدل دیپ سیک	۱.۵.۳
۲۸	چهارچوب بهینه سازی ترجیحات فکری	۲.۵.۳
۲۹	آموزش استدلال مدل های بزرگ به مدل های کوچک	۳.۵.۳
۳۱	جمع آوری دادگان	فصل ۴:
۳۱	مقدمه	۱.۴
۳۱	معرفی پیکره پزشکی فارسی	۲.۴
۳۲	معرفی مجموعه داده MF3QA	۳.۴
۳۳	منابع مجموعه داده MF3QA	۱.۳.۴
۳۵	فیلتر کردن رکورد های مجموعه داده MF3QA	۲.۳.۴
۳۵	خزش از تالار گفتگو دکتر هست	۱.۲.۳.۴
۳۶	معرفی مجموعه داده پرسش های چند گزینه ای	۴.۴
۳۷	ترجمه قسمت پزشکی مجموعه داده MMLU	۱.۴.۴

۳۷	گردآوری سوالات کنکور علوم پایه پزشکی ایران	۲.۴.۴
۳۸	ترجمه ماشینی مجموعه داده MedMCQA	۳.۴.۴
۳۸	مجموعه دادگان معرفی شده پس از گردآوری	۵.۴
۳۹	مجموعه داده PerMedCQA	۱.۵.۴
۳۹	مجموعه داده PersianMedQA	۲.۵.۴
۳۹	مجموعه داده PerMed-MM	۳.۵.۴
۴۱	معرفی مدل زبانی گائوکرنا وی	فصل ۵:
۴۱	مقدمه	۱.۵
۴۱	مدل پایه	۲.۵
۴۲	ویژگی های مدل آیا اکسپنس	۱.۲.۵
۴۳	تنظیم دقیق روی پیکره پزشکی	۳.۵
۴۴	تنظیم دستورالعملی روی مجموعه داده MF3QA	۴.۵
۴۵	رد پای کربن مدل گائوکرنا وی	۵.۵
۴۶	نتایج	۶.۵
۴۶	مقایسه با مدل های زبانی فارسی همه منظوره	۱.۶.۵
۴۷	مقایسه با جایگزین های خط لوله ای	۲.۶.۵
۵۱	معرفی مدل زبانی گائوکرنا آر	فصل ۶:
۵۱	مقدمه	۱.۶
۵۱	مدل پایه	۲.۶
۵۲	چارچوب های معرفی شده	۳.۶
۵۲	روش نخست	۱.۳.۶
۵۳	روش دوم	۲.۳.۶
۵۴	رد پای کربن	۴.۶
۵۵	نتایج	۵.۶
۵۷	سنجش استدلال پزشکی	۱.۵.۶

۵۷	دقت	۱.۱.۵.۶
۵۸	Pass@k	۲.۱.۵.۶
۵۸	سنجش دانش پزشکی	۲.۵.۶
۵۹	سنجش پایانی	۳.۵.۶
۶۵	نتیجه گیری	فصل ۷:
۶۵	نوآوری ها	۱.۷
۶۶	تحقیقات آینده	۲.۷
۶۶	توسعه یک مدل زبانی دیداری	۱.۲.۷
۶۷	بهبود مدل از طریق یادگیری تقویتی مبتنی بر بازخورد انسانی	۲.۲.۷
۶۷	توسعه یک مدل مستقل از نوع درخواست	۳.۲.۷
۶۷	بررسی عدم اطمینان در مدل آیا اکسپنس	۴.۲.۷
۶۹	کتابنامه	
۷۹	اجرای مدل های زبانی	فصل ۸:
۷۹	اجرای مدل ها	۱.۸
۸۳	نمونه های اجرا	پیوست ب:
۸۳	نمونه های اجرای گائوکرنا وی در مقایسه با مدل پایه	ب.۱
۸۵	نمونه های اجرای گائوکرنا آر در مقایسه با مدل پایه	ب.۲

فهرست تصاویر

۱.۲	معماری ترنسفورمر [۸]	۲۰
۲.۲	مقایسه الگوریتم بهینه‌سازی سیاست مجاورتی و بهینه‌سازی مستقیم ترجیحات [۲۲]	۲۰
۱.۳	بلوک دیاگرام مدل medsss [۳۲]	۲۶
۲.۳	بلوک دیاگرام بهینه‌سازی ترجیحات فکری [۵۳]	۲۹
۳.۳	بلوک دیاگرام آموزش دلیل آوری توسط مدل بزرگتر به مدل کوچکتر [۵۴]	۳۰
۱.۴	سهم هر مجله در پیکره پزشکی فارسی گردآوری شده	۳۴
۲.۴	سهم هر تالار گفتگو در مجموعه داده MF3QA	۳۴
۱.۵	مکانیسم آریتاژ داده	۴۳
۲.۵	نمودار کاهش خطا تنظیم دقیق روی پیکره پزشکی	۴۴
۳.۵	نمودار کاهش خطا تنظیم دقیق روی مجموعه داده MF3QA	۴۵
۴.۵	مکانیسم جایگزین خط لوله ای	۴۶
۵.۵	نرخ پیروزی گائوکرنا وی در رقابت با بقیه مدل های زبانی فارسی همه منظوره	۴۷
۶.۵	نرخ پیروزی گائوکرنا وی در رقابت با جایگزین های خط لوله ای	۴۸
۱.۶	بلوک دیاگرام چارچوب نخست	۵۳
۲.۶	بلوک دیاگرام چارچوب دوم	۵۵
۳.۶	نمودار کاهش خطا بهینه‌سازی مستقیم ترجیحات	۵۷
۴.۶	نتایج Pass@k روی مجموعه داده ترجمه قسمت پزشکی MMLU	۵۹
۵.۶	نتایج Pass@k روی مجموعه داده کنکور علوم پایه پزشکی شهرپور 1401	۶۰

فهرست جداول

۱.۱	اطلاعات دو فاز پایان نامه	۴
۱.۴	مقایسه پیکره گردآوری شده با پیکره های گردآوری شده توسط گارسیا فررو	۳۲
۲.۴	مقایسه مجموعه داده های پرسش و پاسخ آزاد پزشکی با مجموعه داده گردآوری شده	۳۳
۱.۵	مقایسه مدل گائوکرنای با بقیه مدل های زبانی فارسی همه منظوره	۴۹
۲.۵	مقایسه مدل گائوکرنای با جایگزین های خط لوله ای	۵۰
۱.۶	دقت با درخواست زنجیره افکار بدون نمره منفی	۶۱
۲.۶	دقت با درخواست زنجیره افکار با نمره منفی	۶۲
۳.۶	دقت با درخواست مستقیم	۶۳
۴.۶	ارزیابی دو پیکربندی	۶۴
۱.۷	مقایسه اطمینان مدل ها روی مجموعه داده سوالات کنکور علوم پایه پزشکی شهرپور 1402	۶۸

فهرست الگوریتم‌ها

۱.۴	الگوریتم جستجو اول عرض برای استخراج رکورد های پرسش و پاسخ پزشکی	۳۶
۱.۶	چارچوب دوم پیشنهاد شده برای بهبود دلیل آوری	۵۴
۲.۶	چارچوب دوم پیشنهاد شده برای بهبود دلیل آوری	۵۶

فهرست برنامه‌ها

۸۰		۱.آ	اجرای مدل های زبانی ورودی فقط متن
۸۱		۲.آ	اجرای مدل های زبانی ورودی متن و تصویر

فصل ۱

دیباچه

۱.۱ هدف پژوهش

استفاده از هوش مصنوعی در پاسخگویی به سوالات پزشکی به عنوان یکی از حوزه‌های نوظهور و حیاتی در فناوری و بهداشت، در سال‌های اخیر توجه زیادی را به خود جلب کرده است. در حالی که تحقیقات گسترده‌ای در این زمینه به زبان انگلیسی منتشر شده، در زمان آغاز این پایان‌نامه، حوزه زبان فارسی از پژوهش‌های کافی برخوردار نبود. هدف این پژوهش جمع‌آوری داده‌های پزشکی فارسی، توسعه مدل‌های زبانی کوچک پزشکی به زبان فارسی و ایجاد شیوه‌های محک‌زنی^۱ جدید برای سنجش دانش این مدل‌ها است. همچنین، این پژوهش بر توسعه یک مدل زبانی کوچک پزشکی فارسی مبتنی بر استدلال^۲ تمرکز دارد. مزیت مدل‌های کوچک زبانی نسبت به مدل‌های بزرگ، قابلیت اجرای آن‌ها بر روی دستگاه‌های محلی است. این موضوع اهمیت ویژه‌ای دارد زیرا داده‌های پزشکی معمولاً حساس و خصوصی هستند و ارسال آن‌ها به سرورهای خارجی می‌تواند خطرات جدی برای حریم خصوصی بیماران ایجاد کند [۱].

benchmarks^۱
reasoning^۲

۲.۱ کاربرد پژوهش

۱.۲.۱ کاربرد مدل های زبانی پزشکی

مدل های زبانی در سال های اخیر با استفاده از داده های بسیار گسترده تر و معماری های پیشرفته تر به پیشرفت های چشمگیری دست یافته اند. این مدل ها توانایی درک بهتر مفاهیم، تولید متن های طبیعی تر و پاسخ دهی دقیق تر به سوالات را پیدا کرده اند.

این پیشرفت ها منجر به افزایش چشمگیر کاربرد هوش مصنوعی^۳ در حوزه های مختلف، به ویژه در زمینه پزشکی، شده است. [۲] امروزه در حوزه پزشکی، مدل های زبانی مبتنی بر یادگیری ژرف^۴ نقش مهمی در تحلیل داده های پزشکی، بهبود دقت تشخیص بیماری ها، ارائه پیشنهادهای درمانی دقیق تر و افزایش کیفیت مراقبت از بیماران ایفا می کنند. علاوه بر این، این فناوری، به بهینه سازی سیستم های اداری و کاهش بار کاری کادر درمانی کمک شایانی کرده است. به عنوان مثال، مدل های هوش مصنوعی قادرند با تحلیل داده های حاصل از پرونده های پزشکی، الگوهای مرتبط با بیماری ها را شناسایی کنند و اطلاعات ارزشمندی را برای تصمیم گیری سریع تر و دقیق تر در اختیار پزشکان قرار دهند. این مدل ها همچنین می توانند نقش مهمی در تکمیل مشاوره های پزشکی ایفا کرده و به پزشکان در ارائه اطلاعات دقیق تر و سریع تر کمک کنند. و حتی شاید در آینده ای نه چندان دور بتوانند جای پزشکان را در مشاوره های پزشکی بگیرند. [۳]

این تحول نه تنها به افزایش کارایی و بهره وری در سیستم های درمانی منجر شده است، بلکه تجربه کلی بیماران را نیز بهبود بخشیده و امکان ارائه خدمات درمانی بهتر و موثرتر را فراهم کرده است. به همین دلیل، توسعه و استفاده از مدل های زبانی پزشکی^۵، همچنان مورد توجه پژوهشگران و متخصصان قرار دارد.

۲.۲.۱ کاربرد مدل های زبانی پزشکی دارای قابلیت استدلال

پزشکی به عنوان یک علم تجربی و کاربردی، بیش از هر چیز به استدلال دقیق وابسته است. تشخیص بیماری، انتخاب درمان، پیش بینی پیامد و حتی آموزش پزشکی، همگی بر پایه زنجیره های منطقی، تحلیل داده های بالینی و استنتاج از شواهد بنا شده اند. از آن روی که پزشکی علم وابسته به استدلال است، توسعه یک مدل زبانی که دارای قابلیت های استدلال برتری باشد می تواند بسیار تحول آفرین باشد. این مدل ها نه تنها می توانند اطلاعات را بازیابی کنند، بلکه می توانند دلیل بیاورند، احتمالات را مقایسه کنند، تناقضات را شناسایی کنند و تصمیمات را

^۳ artificial intelligence

^۴ deep learning

^۵ medical language models

توجیه‌پذیر سازند. بنابراین توسعه این نوع از مدل‌های زبانی در حوزه پزشکی بسیار مفید است. [۴]

۳.۲.۱ کاربرد مدل‌های زبانی پزشکی فارسی

علیرغم پیشرفت‌های چشمگیر در توسعه مدل‌های زبانی پزشکی به زبان انگلیسی، در حوزه زبان فارسی هنوز کار چندانی صورت نگرفته است. این در حالی است که در سرتاسر جهان میلیون‌ها نفر تنها قادر به استفاده از این زبان هستند؛ بنابراین تلاش برای توسعه یک مدل زبانی پزشکی در زبان فارسی می‌تواند گامی رو به جلو در ارتباطات و خدمات درمانی کشور های فارسی زبان باشد.

۳.۱ مراحل انجام پایان نامه

همانطور که در جدول ۱.۱ این پایان‌نامه در دو فاز اصلی طراحی و اجرا شده است. فاز نخست به جمع‌آوری دادگان پزشکی فارسی و توسعه مدلی با نام «گائوکرنا وی» اختصاص دارد که فاقد توانایی استدلال بوده و بیشتر بر درک سیستم یک^۶ زبان تمرکز دارد. از این فاز، مقاله‌ای با عنوان «اهرم قرار دادن داده‌های آنلاین برای بهبود دانش پزشکی یک مدل زبانی کوچک پزشکی فارسی»^۷ استخراج شده است که به تشریح فرآیند جمع‌آوری داده‌ها و نحوه بهینه‌سازی دانش پزشکی مدل می‌پردازد. در فاز دوم این پژوهش ابتدا تکنیک‌های جدیدی برای ارتقای توانایی استدلال و درک سیستم دو مدل معرفی شده و سپس مدل «گائوکرنا آر» در این فاز توسعه داده شده است. از این فاز نیز، مقاله‌ای با عنوان «بهبود مهارت‌های استدلال در مدل‌های زبانی پزشکی فارسی کوچک می‌تواند از آموزش داده‌های بزرگ مقیاس پیشی بگیرد»^۸ استخراج شده است.

مقاله نخست در سی و دومین کنفرانس ملی و دهمین کنفرانس بین‌المللی مهندسی پزشکی ایران و مقاله دوم در یازدهمین کنفرانس بین‌المللی پردازش سیگنال و سیستم‌های هوشمند منتشر شده است.

^۶ در علم رفتارشناسی به درک سریع، شهودی و بدون نیاز به تفکر ژرف درک سیستم یک و به درک آهسته، غیر شهودی و نیازمند استدلال درک سیستم دو می‌گویند. در فصل بعدی به این موضوع بیشتر پرداخته خواهد شد.

^۷ Leveraging Online Data to Enhance Medical Knowledge in a Small Persian Language Model
^۸ Enhancing Reasoning Skills in Small Persian Medical Language Models Can Outperform Large-Scale Data Training

	gaokerena-V	gaokerena-R
مخزن گیت هاب	mehrdadghassabi/gaokerena-V	mehrdadghassabi/gaokerena-R
مخزن پارامترها	gaokerena/gaokerena-v1.0	gaokerena/gaokerena-r1.0
پیوند مقاله	arxiv.org/pdf/2505.16000	arxiv.org/pdf/2510.20059
هزینه	۳۰۰ دلار	۷۰ دلار
توانایی استدلال	خیر	بله
منتشر شده در	سی و دومین کنفرانس ملی و دهمین کنفرانس بین‌المللی مهندسی پزشکی ایران	یازدهمین کنفرانس بین‌المللی پردازش سیگنال و سیستم‌های هوشمند

جدول ۱.۱: اطلاعات دو فاز پایان نامه

۴.۱ ساختار پایان نامه

در این پایان‌نامه، ساختار فصل‌ها به گونه‌ای طراحی شده است که مراحل مختلف پژوهش به صورت منظم و هدفمند ارائه شوند. فصل دوم به بررسی ادبیات موضوع مورد تحقیق اختصاص دارد، در حالی که فصل سوم به مرور کارهای پیشین پرداخته و مطالعات انجام‌شده در زمینه‌های مرتبط را بررسی می‌کند. فصل چهارم به دلیل کمبود داده‌های پزشکی در حوزه زبان فارسی، فرآیند گردآوری و آماده‌سازی این داده‌ها را به طور دقیق تشریح خواهد کرد. سپس در فصل پنجم، با استفاده از داده‌های معرفی‌شده در فصل سوم، مدل اولیه‌ای با نام «گائوکرنا وی»^۹ معرفی و تحلیل می‌شود. در ادامه، فصل ششم به معرفی تکنیک‌هایی برای بهبود توانایی استدلال یک مدل زبانی می‌پردازد و مدل پیشرفته‌تری به نام «گائوکرنا آر» را معرفی کرده و ویژگی‌های آن را به تفصیل شرح می‌دهد. در نهایت، فصل پایانی به جمع‌بندی نتایج پژوهش و ارائه پیشنهاداتی برای تحقیقات آینده اختصاص دارد.

^۹ نام گائوکرنا از درختی افسانه‌ای الهام گرفته شده است که در روایات اساطیری زرتشتی به عنوان نماد شفادهی و جاودانگی شناخته می‌شود.

فصل ۲

ادبیات موضوع

۱.۲ مقدمه

در این فصل، به بررسی مفاهیم مدل‌های زبانی^۱ و انواع آن‌ها، همچنین روش‌های سنجش این مدل‌ها خواهیم پرداخت. علاوه بر این، تحلیل سیستم‌های پرسش و پاسخ^۲ را انجام خواهیم داد تا درک بهتری از عملکرد و کاربردهای مختلف این سیستم‌ها به دست آوریم. سپس به کاربرد یادگیری تقویتی^۳ در مدل‌های زبانی پرداخته و در نهایت به بررسی قابلیت‌های مدل‌های زبانی در استدلال خواهیم پرداخت.

۲.۲ مدل‌های زبانی

مدل‌های زبانی ابزارهای پیشرفته‌ای هستند که برای پردازش و تولید زبان طبیعی طراحی شده‌اند. این مدل‌ها با استفاده از یادگیری ماشین^۴ و به ویژه یادگیری عمیق^۵، توانایی درک و تولید متن را دارند. در حقیقت، وظیفه مدل‌های زبانی پیش‌بینی توکن بعدی^۶ بر اساس متنی است که تاکنون تولید شده است. این مدل‌ها دارای انواع مختلفی است که در ادامه آن‌ها را بررسی می‌کنیم.

language models^۱
question answering systems^۲
reinforcement learning^۳
machine learning^۴
deep learning^۵
next token prediction^۶

۱.۲.۲ مدل های زبانی آماری

مدل های زبانی n-gram ابتدایی ترین مدل های زبانی هستند که در دهه نود میلادی به عنوان جایگزینی برای ترجمه ماشینی مبتنی بر قانون^۷ معرفی شدند [۵] همانطور که در فرمول ۱.۲.۲ مشاهده میکنید این مدل ها برای پیش بینی توکن بعدی از فراوانی n-gram ها در پیکره^۸ موجود استفاده میکنند. به عنوان مثال در مدل زبانی 2-gram، احتمال وقوع یک کلمه تنها بر اساس کلمه قبلی محاسبه می شود.

$$P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i | w_{i-n+1}, w_{i-n+2}, \dots, w_{i-1})$$

۲.۲.۲ مدل های زبانی بازگشتی

شبکه های عصبی بازگشتی نوعی از شبکه های عصبی مصنوعی^۹ هستند که به طور خاص برای پردازش توالی ها^{۱۰} طراحی شده اند. [۶] از آنجا که زبان را نیز می توان به صورت یک توالی از توکن ها تعریف کرد، بنابراین می توان از شبکه های عصبی بازگشتی به عنوان مدل های زبانی استفاده کرد.

همانطور که در فرمول ۲.۲.۲ که فرمول پایه شبکه های عصبی است می بینید ویژگی اصلی شبکه های عصبی بازگشتی این است که دارای حلقه های بازگشتی است که به آن اجازه می دهد اطلاعات را از مراحل قبلی به مراحل بعدی منتقل کند. این ساختار باعث می شود شبکه های عصبی بازگشتی بتواند وابستگی های زمانی و ترتیبی داده ها را مدل سازی کند.

شبکه های عصبی بازگشتی مانند نوع ساده آن^{۱۱} معمولاً در مدل کردن وابستگی های بلند مدت^{۱۲} با مشکل مواجه میشوند، این وابستگی ها که در زبان های طبیعی به وفور یافت میشوند باعث شده اند که مدل های زبانی مبتنی بر شبکه های عصبی بازگشتی مدل های چندان خوبی نباشند. هر چند در انواع دیگر این شبکه ها مانند LSTM [۷] برای حل این مشکل تلاش شده است اما این مشکل هنوز در این نوع از شبکه های عصبی وجود دارد.

$$h_t = f(W_h h_{t-1} + W_x x_t + b)$$

rule-based machine translation^۷
corpus^۸
artificial neural networks^۹
sequences^{۱۰}
vanilla recurrent neural networks^{۱۱}
long term dependencies^{۱۲}

۳.۲.۲ مدل های زبانی مبتنی بر ترنسفورمر

همان طور که در قسمت پیشین اشاره شد، مدل های زبانی بازگشتی در مدل سازی وابستگی های بلندمدت با مشکل مواجه هستند و به دلیل ماهیت توالی گونه خود، سرعت پردازش آنها نیز بسیار پایین است.

مقاله Attention is All You Need [۸] با معماری نوآورانه خود توانست هر دوی این مشکلات را حل کند. این معماری از مکانیزم توجه^{۱۳} استفاده می کند که به مدل اجازه می دهد تا به طور همزمان به تمامی ورودی ها توجه کند و وابستگی های بلندمدت را به راحتی شناسایی کند. به این ترتیب، سرعت پردازش به طور قابل توجهی افزایش می یابد.

علاوه بر این، معماری ترنسفورمر^{۱۴} که در شکل ۱.۲ می توانید آن را ببینید، قابلیت پردازش موازی را دارد، زیرا معماری آن ماهیت توالی گونه ندارد. به همین دلیل، با استفاده از پردازنده های گرافیکی^{۱۵} می توان پردازش های موازی را انجام داد که سرعت پردازش را به طور چشمگیری بهبود می بخشد.

مدل های مبتنی بر معماری ترنسفورمر سه دسته هستند که در ادامه به بررسی این سه دسته خواهیم پرداخت.

۱.۳.۲.۲ مدل های زبانی فقط رمزگذار

مدل های زبانی فقط رمزگذار^{۱۶}، تنها از بخش رمزگذار معماری ترنسفورمر که در سمت چپ شکل ۱.۲ قابل مشاهده است، استفاده می کنند. این مدل ها به طور ویژه برای پردازش و درک متن طراحی شده اند و ورودی ها را به یک نمایش داخلی تبدیل می کنند که شامل اطلاعات معنایی و ساختاری متن است.

این نوع مدل ها عمدتاً در وظایفی مانند تحلیل احساسات^{۱۷}، دسته بندی متن^{۱۸} و استخراج ویژگی ها^{۱۹} کاربرد دارند. آن ها به خوبی می توانند الگوهای زبانی و معنایی را شناسایی کرده و اطلاعات مفیدی از داده های متنی استخراج کنند، اما به تنهایی توانایی تولید متن جدید را ندارند.

به عنوان مثال، می توان از برت^{۲۰} [۹] [۱۰]، که یکی از معروف ترین مدل های زبانی فقط رمزگذار است، یاد کرد.

^{۱۳}attention mechanism

^{۱۴}transformer

^{۱۵}graphical processing unit

^{۱۶}encoder only language models

^{۱۷}sentiment analysis

^{۱۸}text classification

^{۱۹}feature extraction

^{۲۰}BERT

۲.۳.۲.۲ مدل‌های زبانی فقط رمزگشا

مدل‌های زبانی فقط رمزگشا^{۲۱} نوعی از مدل‌های زبانی هستند که به طور خاص برای تولید متن و پیش‌بینی توکن‌های بعدی در یک توالی طراحی شده‌اند. این مدل‌ها تنها از ساختار رمزگشای معماری ترنسفورمر که در سمت راست شکل ۱.۲ قابل مشاهده است، استفاده می‌کنند و به صورت تک‌جهته عمل می‌کنند، به این معنا که برای تولید هر توکن، تنها به توکن‌های قبلی خود در توالی دسترسی دارند.

در این مدل‌ها، هدف اصلی پیش‌بینی توکن بعدی بر اساس توکن‌های قبلی است. به عنوان مثال، اگر ورودی مدل یک جمله باشد، مدل سعی می‌کند کلمه بعدی را پیش‌بینی کند. این نوع از مدل‌ها در کاربردهایی مانند تولید متن، چت‌بات‌ها و ترجمه ماشینی بسیار موثر هستند.

مدل‌های رمزگشا معمولاً با استفاده از داده‌های متنی بزرگ آموزش دیده و توانایی بالایی در تولید متن‌های معنادار و مرتبط دارند. یکی از معروف‌ترین نمونه‌های این دسته از مدل‌ها، مدل GPT^{۲۲} [۱۱] است که توسط OpenAI توسعه یافته است.

۳.۳.۲.۲ مدل‌های زبانی رمزگذار-رمزگشا

دل‌های زبانی رمزگذار-رمزگشا^{۲۳} نوعی از مدل‌های زبانی هستند که هر دو قسمت معماری ترنسفورمر که در شکل ۱.۲ مشاهده می‌کنید استفاده می‌کند.

این معماری که در مدل‌هایی مانند T5 [۱۲] به کار گرفته شده در وظایف پیچیده‌ای مانند ترجمه ماشینی، خلاصه‌سازی متن و تولید گفتار کاربرد دارد. به عنوان مثال، در ترجمه ماشینی، بخش رمزگذار جمله‌ای را به زبان مبدا تحلیل کرده و آن را به یک نمایش معنایی تبدیل می‌کند، سپس بخش رمزگشا این نمایش را به زبان مقصد ترجمه می‌کند.

۳.۲ سیستم‌های پرسش و پاسخ

سیستم‌های پرسش و پاسخ^{۲۴} فناوری‌های هوشمندی هستند که با استفاده از تکنیک‌های پردازش زبان طبیعی^{۲۵}، به کاربران این امکان را می‌دهند تا سوالات خود را مطرح کرده و پاسخ‌های دقیق و مرتبط دریافت کنند. این

^{۲۱} decoder-only language models
^{۲۲} generative pre-trained transformer
^{۲۳} encoder-decoder language models
^{۲۴} question answering systems
^{۲۵} natural language processing

سیستم‌ها بر دو نوع هستند استخراجی^{۲۶} و تولیدی^{۲۷} که در ادامه به بررسی آنها خواهیم پرداخت. [۱۳]

۱.۳.۲ سیستم‌های پرسش و پاسخ استخراجی

سیستم‌های پرسش و پاسخ استخراجی به منظور پاسخ‌گویی به سوالات کاربران، به جستجوی اطلاعات در پایگاه‌های داده یا مستندات می‌پردازند و پاسخ‌ها را از متن استخراج می‌کنند. این سیستم‌ها معمولاً از یک مدل زبانی فقط رمزگذار مانند برت استفاده می‌کنند.

۲.۳.۲ سیستم‌های پرسش و پاسخ تولیدی

با توسعه و گسترش هوش مصنوعی تولیدکننده^{۲۸} سیستم‌های پرسش و پاسخ‌هایی پدید آمدند که در آن برای پاسخ دادن به پرسش کاربر به دانش مدل زبانی تکیه می‌شود. یعنی مدل زبانی با توجه به دانشی که در زمینه پرسش مطرح شده دارد بایستی پاسخ را تولید کند. از آنجایی که در این سیستم‌ها بایستی چیزی تولید شود بنابراین در آن‌ها از مدل‌های زبانی فقط رمزگشا یا مدل‌های زبانی رمزگذار-رمزگشا استفاده می‌گردد. با بهبود دانش پزشکی و توانایی استدلال یک مدل پایه ما نیز در پایان نامه حاضر اقدام به طراحی یک سیستم پرسش و پاسخ تولیدی کرده ایم.

۴.۲ شیوه‌های سنجش مدل‌های زبانی

سنجش دانش یک مدل زبانی به ویژه در زمینه پزشکی از اهمیت بالایی برخوردار است، زیرا این فرآیند به شناخت ما از میزان دانش یک مدل زبانی، کمک شایانی می‌کند. در ادامه چندین روش سنجش کیفیت پاسخ‌های مدل‌های زبانی را مطرح خواهیم کرد، ضمناً ما از روش اول و دوم برای سنجش دانش مدل‌های خود استفاده کرده ایم.

^{۲۶}extractive

^{۲۷}generative

^{۲۸}generative artificial intelligence

۱.۴.۲ سنجش بر اساس میزان پاسخگویی به پرسش و پاسخ های چند گزینه ای

یکی از معیارهای مهم برای سنجش عملکرد مدل های زبانی، ارزیابی توانایی آن ها در پاسخگویی به پرسش های چهار گزینه ای است که از پیش آماده شده اند. این نوع ارزیابی به دلیل ساختار مشخص و استاندارد پرسش ها، امکان مقایسه دقیق تری بین مدل های مختلف را فراهم می آورد. یکی از مجموعه های داده ای که به طور گسترده در این زمینه مورد استفاده قرار می گیرد، مجموعه داده MMLU^{۲۹} [۱۴] است. این مجموعه شامل پرسش های متنوعی است که درباره موضوعات مختلفی مانند علوم، پزشکی، ریاضیات، تاریخ، و ادبیات طراحی شده اند.

مجموعه داده MMLU به عنوان یک استاندارد در ارزیابی مدل های زبانی، به محققان و توسعه دهندگان این امکان را می دهد که عملکرد مدل های زبانی خود را در زمینه های مختلف بسنجند و نقاط قوت و ضعف آن ها را شناسایی کنند. پرسش های چهار گزینه ای در MMLU به گونه ای طراحی شده اند که نیاز به درک عمیق و تحلیل دقیق متن دارند. این ویژگی، مدل ها را به چالش می کشد تا نه تنها اطلاعات را بازیابی کنند، بلکه توانایی استدلال و تحلیل خود را نیز به نمایش بگذارند. با استفاده از این معیار، می توان به راحتی مقایسه هایی بین مدل های مختلف انجام داد و پیشرفت های حاصل شده در زمینه هوش مصنوعی و پردازش زبان طبیعی را ارزیابی کرد.

۲.۴.۲ سنجش بر اساس نظر مدل داور

یک روش دیگر برای سنجش عملکرد یک مدل زبانی، استفاده از یک مدل زبانی دیگر به عنوان داور است. در این رویکرد، یک مدل زبانی مستقل به عنوان مرجع برای ارزیابی کیفیت پاسخ های تولید شده توسط مدل اصلی مورد استفاده قرار می گیرد. این روش به دلیل قابلیت های بالای مدل های زبانی در پردازش و درک زبان طبیعی، می تواند به طور موثری به ارزیابی دقت و کیفیت پاسخ ها کمک کند.

در این فرآیند، پاسخ های تولید شده توسط مدل اصلی به مدل قاضی ارائه می شود. مدل قاضی می تواند با استفاده از معیارهای مختلفی مانند شباهت معنایی با پاسخ اصلی^{۳۰}، صحت اطلاعات، و سازگاری با زمینه، کیفیت پاسخ ها را ارزیابی کند. به عنوان مثال، مدل قاضی می تواند با بررسی تطابق پاسخ ها با اطلاعات موجود در متون معتبر یا داده های آموزشی، نمره ای برای هر پاسخ تولید کرده [۱۵] یا پاسخی را بر پاسخ دیگر ترجیح دهد.

^{۲۹} massive multitask language understanding
^{۳۰} ground truth

۳.۴.۲ سنجش بر اساس استنتاج زبان طبیعی

با داشتن یک مجموعه داده مانند K-QA [۱۶]، شامل پاسخ‌های تولید شده توسط انسان که به همراه توضیحات دقیقی دسته‌بندی شده‌اند، این پاسخ‌ها به عنوان "الزامی" ^{۳۱} یا "مفید" ^{۳۲} مشخص گشته‌اند. این دسته‌بندی نشان می‌دهد که آیا توضیحات باید به طور ضروری در پاسخ گنجانده شوند یا اینکه اضافی و مفید هستند.

این حقایق اتمی می‌توانند برای به کارگیری یک روش ارزیابی مبتنی بر استنتاج زبان طبیعی ^{۳۳} استفاده شوند. در این روش، پاسخ مدل به عنوان "مقدمه" ^{۳۴} و هر یک از توضیحات انسانی به عنوان "فرضیه" ^{۳۵} در نظر گرفته می‌شود. سپس یک مدل زبانی توانا در حوزه استنتاج زبان طبیعی تعیین خواهد کرد که آیا مقدمه مستلزم ^{۳۶}، متناقض ^{۳۷} یا خنثی ^{۳۸} با فرضیه است.

با انجام این کار روی همه رکوردهای مجموعه داده، دو امتیاز کامل بودن ^{۳۹} و حقیقت داشتن ^{۴۰} به صورت زیر به دست می‌آید.

$$S_{comp}(r_i, A'_i) = \frac{\mathbb{1}[r_i \text{ entails } a]}{|A'_i|}$$

$$S_{fact}(r_i, A'_i) = \begin{cases} 0 & \text{if } \exists a \in A_i \text{ s.t. } r_i \text{ contradicts } a \\ 1 & \text{if otherwise} \end{cases}$$

۴.۴.۲ سنجش بر اساس امتیاز برت

در این معیار، کیفیت پاسخ‌های تولید شده توسط یک مدل زبانی فقط رمزگذار مانند برت ارزیابی می‌شود. [۱۷] در این فرآیند، پاسخ داده شده با پاسخ صحیح ^{۴۱} موجود در مجموعه داده مقایسه می‌گردد.

must have^{۳۱}
 nice to have^{۳۲}
 natural language inference^{۳۳}
 premise^{۳۴}
 hypothesis^{۳۵}
 entailment^{۳۶}
 contradiction^{۳۷}
 neutral^{۳۸}
 completeness^{۳۹}
 factuality^{۴۰}
 ground truth^{۴۱}

مدل زبانی پاسخ فقط رمزگذار را به دو بردار تبدیل می‌کند: یکی برای پاسخ داده شده و دیگری برای پاسخ صحیح. سپس برای محاسبه امتیاز برت، کافی است میزان شباهت این دو بردار را با یک روش شباهت‌سنجی مانند شباهت کسینوسی^{۴۲} محاسبه کنیم.

پس از محاسبه امتیازها برای تمامی پاسخ‌ها در مجموعه داده، این امتیازات جمع‌آوری و میانگین‌گیری می‌شوند. میانگین امتیازها نمای کلی از عملکرد مدل را ارائه می‌دهد و به شناسایی نقاط قوت و ضعف آن کمک می‌کند.

۵.۲ یادگیری تقویتی در مدل‌های زبانی

با داشتن یک مدل زبانی اولیه که بتواند برای هر پرسشی پاسخ خود را تولید کند، می‌توانیم یک مدل یا تابع پاداش^{۴۳} در نظر بگیریم و آن مدل زبانی را به گونه‌ای به‌روزرسانی کنیم که این تابع پاداش بیشینه گردد. به این صورت که ابتدا داده‌های ترجیحات انسانی (مانند مقایسه دو پاسخ و انتخاب بهتر) جمع‌آوری شده و با آن‌ها یک مدل پاداش آموزش داده می‌شود. سپس، با استفاده از الگوریتم‌های بهینه‌سازی که در ادامه به آن‌ها خواهیم پرداخت، سیاست تولید پاسخ مدل زبانی به تدریج اصلاح می‌گردد تا امتیاز پاداش بالاتری کسب کند. این شیوه باعث می‌شود که مدل زبانی نه تنها با ترجیحات انسانی هم‌راستا شود، بلکه پاسخ‌های مخرب، نادرست، جانبدارانه یا نامناسب کاهش یابد، ایمنی و قابلیت اطمینان افزایش یابد و کیفیت کلی مکالمه از نظر روانی بودن، مفید بودن و جذابیت به طور چشمگیری بهبود یابد. در نهایت، این روش به مدل‌های زبانی کمک می‌کند تا خروجی‌هایی تولید کنند که نه تنها دقیق و مرتبط باشند، بلکه با ارزش‌ها، فرهنگ و انتظارات کاربران انسانی نیز هماهنگ گردند.

۱.۵.۲ یادگیری تقویتی با بازخورد انسان یا هوش مصنوعی

برای مشخص کردن ترجیحات انسانی یاد شده علاوه بر انسان^{۴۴} [۱۸] می‌توان از بازخورد هوش مصنوعی نیز استفاده کرد؛ بدین صورت که از یک مدل هوش مصنوعی پیشرفته‌تر یا تخصصی (مانند یک مدل زبانی بزرگ‌تر یا یک سیستم ارزیابی خودکار) خواسته می‌شود که به پاسخی که یک مدل زبانی تولید کرده نمره‌ای عددی (مثلاً از ۱ تا ۱۰ بر اساس معیارهایی نظیر صحت، مفید بودن، روانی و ایمنی) بدهد یا آن را در قیاس با پاسخ‌های دیگر تولیدشده توسط همان مدل یا مدل‌های متفاوت رتبه‌بندی کند. این روش که از آن با عنوان یادگیری تقویتی با

^{۴۲} cosine similarity^{۴۳} reward model or function^{۴۴} reinforcement learning with human feedback

بازخورد هوش مصنوعی [۱۹]^{۴۵} یاد میشود، هزینه‌های جمع‌آوری داده‌های انسانی را به شدت کاهش می‌دهد، سرعت فرآیند را افزایش می‌دهد و امکان مقیاس‌پذیری گسترده‌تری فراهم می‌آورد، هرچند ممکن است به دلیل محدودیت‌های مدل ارزیابی‌کننده، برخی جنبه‌های ظریف فرهنگی، اخلاقی یا زمینه‌ای انسانی را به‌طور کامل پوشش ندهد؛ بنابراین اغلب ترکیبی از بازخورد انسانی و هوش مصنوعی برای دستیابی به بهترین نتایج به کار گرفته می‌شود.

۲.۵.۲ الگوریتم‌های بهینه‌سازی مدل زبانی

الگوریتم‌های متعددی برای بهبود عملکرد مدل‌های زبانی بزرگ پیشنهاد شده‌اند که هر یک از رویکردهای متفاوتی در چارچوب یادگیری تقویتی^{۴۶} بهره می‌برند. از میان این روش‌ها، می‌توان به الگوریتم بهینه‌سازی سیاست مجاورتی^{۴۷} [۲۰] به‌عنوان یکی از پرکاربردترین و پایدارترین روش‌ها اشاره کرد. این الگوریتم با محدود کردن میزان تغییر در سیاست، موجب پایداری در فرآیند آموزش می‌شود. در این رویکرد، ابتدا یک مدل پاداش آموزش داده می‌شود و سپس مدل زبانی تلاش می‌کند تا با بهینه‌سازی مقدار خروجی این مدل پاداش، عملکرد خود را بهبود دهد.

یکی دیگر از این الگوریتم‌ها، بهینه‌سازی سیاست بر پایه پاداش گروهی^{۴۸} [۲۱] است. این الگوریتم با معرفی پاداش‌های نسبی درون‌گروهی، تلاش می‌کند مشکلات نوسان و ناپایداری موجود در الگوریتم بهینه‌سازی سیاست مجاورتی را کاهش دهد و از طریق ارزیابی نسبی پاسخ‌ها در یک گروه، بازخورد دقیق‌تر و پایدارتری برای آموزش فراهم کند.

در ادامه، الگوریتم بهینه‌سازی مستقیم ترجیحات^{۴۹} [۲۲] به جای تکیه بر یک مدل پاداش بیرونی، سعی دارد تابع هدف درونی^{۵۰} را در مدل زبانی بهینه کند. همانطور که در تصویر ۲.۲ می‌بینید در این روش، مدل به‌صورت مستقیم از جفت پاسخ‌های ترجیحی (پاسخ تاییدشده و پاسخ ردشده)^{۵۱} یاد می‌گیرد و نیازی به تخمین یا آموزش مدل پاداش مجزا ندارد. این ویژگی باعث سادگی و پایداری بیشتر در فرآیند هم‌ترازسازی مدل با ترجیحات انسانی می‌شود. تابع هزینه این الگوریتم به‌صورت زیر تعریف می‌شود

^{۴۵} reinforcement learning with AI feedback

^{۴۶} reinforcement learning

^{۴۷} proximal policy optimization

^{۴۸} group reward policy optimization

^{۴۹} direct preference optimization

^{۵۰} intrinsic objective function

^{۵۱} rejected-preferred answer pairs

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y^+, y^-)} \left[\log \sigma \left(\beta \left(\log \frac{\pi_{\theta}(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi_{\theta}(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right) \right) \right] \quad (۱.۲)$$

در نهایت، روش بهینه‌سازی مستقیم تابع کیو^{۵۲} [۲۳] فرآیند تولید پاسخ را به صورت یک فرآیند تصمیم مارکوف^{۵۳} مدل می‌کند و با بهره‌گیری از چارچوب بازیگر-منتقد نرم^{۵۴} [۲۴] به طور مستقیم تابع Q را که به وسیله مدل زبانی پارامترگذاری شده است، بهینه می‌سازد. این مدل‌سازی بر پایه‌ی زنجیره تصمیم‌گیری مارکف، نسبت به روش‌های مبتنی بر Bandit از ساختار قوی‌تری برخوردار است و امکان نظارت فرایندی مؤثرتر را فراهم می‌کند. به طور کلی، هر یک از این الگوریتم‌ها با هدف افزایش کارایی، پایداری و هم‌خوانی رفتاری مدل‌های زبانی با ترجیحات انسانی توسعه یافته‌اند و بخش مهمی از پیشرفت‌های اخیر در حوزه‌ی آموزش و هم‌ترازسازی مدل‌های زبانی را تشکیل می‌دهند.

۶.۲ استدلال در مدل‌های زبانی

ظهور معماری ترنسفورمر^{۵۵} [۸] در سال ۲۰۱۷ نقطه‌ی عطفی بنیادین در تحول مدل‌های زبانی بزرگ به شمار می‌آید. این معماری با معرفی سازوکار توجه^{۵۶} و جایگزینی آن به جای پردازش متوالی، بسیاری از محدودیت‌های مدل‌های پیشین — از جمله پدیده‌ی محو شدن گرادین‌ها و ناتوانی در مدل‌سازی وابستگی‌های بلندمدت — را برطرف ساخت. بدین ترتیب، امکان موازی‌سازی کامل در فرایند آموزش فراهم شد و مدل توانست ساختارهای زبانی پیچیده را با دقت و کارایی بسیار بالاتری درک و بازنمایی کند.

در این فصل، تمرکز بر بررسی توانایی استدلال در معماری ترنسفورمر و رویکردهای نوین برای بهبود آن است. هرچند این معماری در وظیفه‌ی پیش‌بینی توکن بعدی عملکردی خیره‌کننده دارد، اما نحوه‌ی استدلال آن عموماً الگومحور است تا منطق‌محور. به بیان دیگر، تمامی مدل‌های زبانی مدرن که بر پایه‌ی ترنسفورمر ساخته شده‌اند، در هسته‌ی خود از همان ضعف بنیادی رنج می‌برند: ناتوانی در درک و بازتولید فرایندهای استدلالی عمیق و مبتنی بر منطق.

^{۵۲} direct q-function optimization

^{۵۳} markov decision process

^{۵۴} soft actor-critic

^{۵۵} transformer

^{۵۶} attention

۱.۶.۲ ناتوانی معماری ترنسفورمر در تفکر سیستم دو

در سال ۲۰۱۹، در کنفرانس NeurIPS، یوشوا بنجیو یکی از چهره‌های پیشگام در حوزه یادگیری عمیق به یکی از محدودیت‌های بنیادین سیستم‌های یادگیری عمیق امروزی، از جمله مدل‌های زبانی، اشاره کرد: ناتوانی در انجام وظایفی که نیازمند مهارت‌های استدلالی قوی هستند. [۲۵]^{۵۷} به‌رغم عملکرد چشمگیر این سیستم‌ها در وظایف شهودی و ادراکی نظیر تشخیص تصویر، ترجمه ماشینی یا تولید متن آن‌ها در مواجهه با مسائلی که مستلزم استدلال منطقی، درک روابط علی و پردازش شناختی عمیق هستند، عملکرد ضعیفی از خود نشان می‌دهند. در واقع، بسیاری از اشتباهات ساده و احمقانه‌ی مدل‌های زبانی مانند ناتوانی در حل مسائل ریاضی ابتدایی یا استنتاج‌های منطقی آشکار را می‌توان با همین محدودیت در تفکر سیستم دو توضیح داد. این مشاهده یادآور تمایز مطرح‌شده توسط دنیل کانمن در علوم شناختی [۲۶] میان دو نوع تفکر است: تفکر سریع که بنجیو آن را «تفکر سیستم یک» می‌نامد و تفکر آهسته که بنجیو آن را «تفکر سیستم دو» می‌خواند. تفکر سریع، ماهیتی شهودی، واکنشی و خودکار دارد و با نقاط قوت سیستم‌های فعلی هوش مصنوعی هم‌راستا است؛ در مقابل، تفکر آهسته فرایندی آگاهانه، تحلیلی و منطقی است که مستلزم توانایی در برنامه‌ریزی، استدلال و بازنمایی مفاهیم انتزاعی می‌باشد. به بیان دیگر، شبکه‌های عصبی عمیق و به‌ویژه مدل‌های زبانی مبتنی بر ترنسفورمر عمدتاً در سطح تفکر سیستم یک، یعنی شناخت شهودی، عمل می‌کنند و فاقد شناخت منطقی یا استدلال علی تفکر سیستم دو هستند. این شکاف میان شهود و منطق، چالشی اساسی در مسیر توسعه‌ی نسل بعدی مدل‌های زبانی و سامانه‌های هوش مصنوعی با قابلیت تفکر مشابه انسان به شمار می‌رود.

۲.۶.۲ طراحی یک معماری دارای قابلیت تفکر سیستم دو

بهترین رویکرد برای غلبه بر ناتوانی ترنسفورمرها در تفکر سیستم دو، توسعه‌ی یک معماری جدید است که بتواند این قابلیت را به‌طور ذاتی در خود داشته باشد. اما طراحی و پیاده‌سازی چنین معماری‌ای کار ساده‌ای نیست! چنین معماری‌ای باید دارای توانایی تعمیم خارج از توزیع^{۵۸} نیز باشد؛ به این معنا که مدل بتواند مفاهیم و روابطی را یاد بگیرد که به‌صورت صریح و مستقیم در داده‌های آموزشی وجود ندارند. به بیان دیگر، سیستم باید قادر باشد از دانش موجود در داده‌ها به موقعیت‌های جدید و نادیده تعمیم دهد — ویژگی‌ای که برای استدلال واقعی و تفکر سطح بالا ضروری است.

در سال‌های اخیر، پژوهشگران چندین مدل و معماری جایگزین را برای بهبود توانایی استدلال در شبکه‌های

^{۵۷}سخنرانی بنجیو اهمیت بسزایی داشت و مفهوم «تفکر سیستم دو» را در هوش مصنوعی برجسته کرد. درس دکتر رهبان در دانشگاه شریف با این عنوان، راهنمایی کلیدی برای پایان‌نامه‌ی حاضر بوده است.
^{۵۸}out of distribution generalization

عصبی پیشنهاد داده‌اند. برای مثال، یکی از این تلاش‌ها معماری‌ای به نام RIM [۲۷] بود که توسط یوشوا بنجیو معرفی شد. یا معماری مدل استدلال سلسله‌مراتبی^{۵۹} [۲۸] که با الهام از سلسله‌مراتبی بودن تفکر انسان پیشنهاد شده است؛

با این حال، مدل‌های پیشنهاد شده در عمل معماری مقیاس‌پذیری نبوده و نتوانسته‌اند در مقیاس‌های بزرگ عملکرد قابل‌قبولی ارائه دهند. به همین دلیل، نمی‌توان آن‌ها را یک پیشنهاد موفق برای حل مشکل استدلال در مدل‌های مبتنی بر ترنسفورمر دانست.

در نتیجه، همچنان یکی از چالش‌های باز در حوزه‌ی یادگیری عمیق و مدل‌های زبانی بزرگ، یافتن معماری‌ای کارا، مقیاس‌پذیر، دارای توان استدلالی و برخوردار از قابلیت تعمیم خارج از توزیع است؛ معماری‌ای که بتواند محدودیت‌های ذاتی ترنسفورمرها را پشت سر بگذارد.

۳.۶.۲ بهبود توانایی دلیل‌آوری مدل‌های زبانی مبتنی بر ترنسفورمر

تا زمانی که هنوز معماری‌ای با قابلیت استدلال ذاتی^{۶۰} در دسترس نداریم، ناچاریم همچنان با معماری ترنسفورمر کار کنیم و به‌نوعی بر محدودیت‌ها و ضعف‌های ذاتی آن غلبه نماییم.

با وجود تمام پیشرفت‌ها، ترنسفورمرها هنوز فاقد سازوکار درونی برای استدلال گام‌به‌گام، تعمیم منطقی و درک علیت هستند. با این حال، از آن‌جا که در حال حاضر موثرترین و مقیاس‌پذیرترین معماری در حوزه‌ی مدل‌های زبانی محسوب می‌شوند، راهبرد عملی این است که به جای کنار گذاشتن آن‌ها، راهکارهایی برای تقویت توانایی استدلالی‌شان طراحی و به کار گرفته شود. روش‌های گوناگونی برای این هدف پیشنهاد شده است که برای اطلاعات بیشتر می‌توانید در مقاله مروری آقای پان [۲۹] در این زمینه مراجعه کنید.

در این بخش، به بررسی مهم‌ترین این رویکردها و روش‌هایی که می‌توانند به بهبود توانایی استدلالی مدل‌های مبتنی بر ترنسفورمر منجر شوند، خواهیم پرداخت.

۱.۳.۶.۲ روش‌های مبتنی بر هوش مصنوعی عصبی-نمادین

در حوزه‌ی هوش مصنوعی، دو مکتب فکری اصلی وجود دارد: نمادگرایی^{۶۱} و ارتباط‌گرایی^{۶۲}.

^{۵۹} hierarchical reasoning model

^{۶۰} intrinsic reasoning capability

^{۶۱} symbolism

^{۶۲} connectionism

در مکتب نمادگرایی، هدف اصلی این است که منطق، قوانین و روابط صریح میان مفاهیم جمع‌آوری شده و در قالب یک مدل منطقی یا قاعده‌محور نمایش داده شود. این رویکرد بر پایه‌ی استدلال نمادین استوار است؛ یعنی سیستم تلاش می‌کند با استفاده از قواعد صریحی که توسط انسان تعریف شده‌اند، به نتیجه برسد.

در مقابل، مکتب ارتباط‌گرایی بر پایه‌ی ایده‌ی یادگیری از داده‌ها شکل گرفته است. در این رویکرد، به جای تعریف قوانین منطقی، حجم زیادی از داده به مدل داده می‌شود تا خود سیستم از درون داده‌ها الگوها و روابط را کشف کند. شبکه‌های عصبی مصنوعی و به‌ویژه مدل‌های عمیق^{۶۳} از نمونه‌های شاخص این مکتب هستند.

با معرفی معماری ترنسفورمر، مکتب ارتباط‌گرایی به شکل چشمگیری غالب شد و تقریباً تمامی پژوهش‌های پیشرفته‌ی حوزه‌ی هوش مصنوعی حول آن متمرکز گردید. دلیل این غلبه روشن است: جمع‌آوری داده‌های عظیم بسیار ساده‌تر از استخراج و تعریف قوانین منطقی دقیق است، و مدل‌های ارتباط‌گرا با استفاده از این داده‌های گسترده می‌توانند عملکردی چشمگیر در وظایف گوناگون مانند ترجمه، تولید متن، بینایی ماشین و غیره داشته باشند.

با این حال، همان‌طور که پیش‌تر اشاره شد، ترنسفورمرها ضعف بزرگی دارند: ناتوانی در استدلال! این مدل‌ها اگرچه در شناسایی الگوها و پیش‌بینی توالی‌ها بسیار قدرتمندند، اما فاقد سازوکار درونی برای انجام استدلال منطقی و تفکر نظام‌مند (تفکر سیستم دو) هستند. از آن‌جا که تاکنون معماری‌ای با قابلیت استدلال ذاتی معرفی نشده است، تمامی مدل‌های مبتنی بر ارتباط‌گرایی نیز همین ضعف بنیادی را به ارث برده‌اند. در مقابل، رویکردهای نمادین از این نظر برترند که توانایی استدلال و نتیجه‌گیری منطقی را به‌صورت ذاتی در خود دارند، اما مشکل بزرگ آن‌ها عدم مقیاس‌پذیری^{۶۴} است؛ یعنی پیاده‌سازی و گسترش آن‌ها برای مسائل واقعی و داده‌های بزرگ بسیار دشوار است.

برای رفع این شکاف، گروهی از پژوهشگران پیشنهاد یک رویکرد میان‌رشته‌ای جدید را مطرح کرده‌اند که ترکیبی از این دو مکتب است: رویکرد عصبی-نمادین^{۶۵}. در این دیدگاه، تلاش می‌شود از قدرت یادگیری و تعمیم مدل‌های عصبی (ارتباط‌گرا) در کنار توان استدلال و شفافیت سیستم‌های نمادین استفاده شود تا هوشی ترکیبی و متوازن به‌دست آید؛ هوشی که هم بتواند از داده بیاموزد، و هم به‌طور منطقی بیندیشد. [۳۰]

با این حال، یوشوا بنجیو معتقد است که این مسیر، راه‌حل نهایی مناسبی نیست و ممکن است با مقیاس‌پذیری در تضاد باشد. او تأکید می‌کند که به جای ترکیب دو مکتب مجزا، بهترین راه، توسعه‌ی معماری‌هایی است که قابلیت استدلال را به‌طور ذاتی در درون خود داشته باشند؛ یعنی سامانه‌هایی که بتوانند استدلال، تعمیم و یادگیری را در یک چارچوب واحد و منسجم ادغام کنند.

^{۶۳} deep learning
^{۶۴} unscalability
^{۶۵} neuro-symbolic AI

۲.۳.۶.۲ روش های مبتنی بر راهنمایی مدل زبانی توسط یک مدل پاداش

یکی از روش های بهبود مهارت های استدلالی یک مدل زبانی، هدایت فرآیند رمزگشایی آن با استفاده از یک مدل پاداش است. مدل پاداش می تواند به دو صورت باشد: مدل پاداش خروجی^{۶۶} و مدل پاداش فرآیند^{۶۷} [۳۱]. مدل پاداش خروجی بر ارزیابی کیفیت پاسخ نهایی تولید شده توسط مدل زبانی تمرکز دارد. این مدل به خروجی ها امتیاز می دهد و بر اساس معیارهای مشخص، مانند دقت، انسجام یا ارتباط با پرس و جو، آن ها را رتبه بندی می کند. از سوی دیگر، مدل پاداش فرآیند به مراحل میانی استدلال مدل توجه می کند. این مدل هر گام از فرآیند تفکر یا حل مسئله را بررسی و ارزیابی می کند تا اطمینان حاصل شود که مسیر استدلال منطقی و بهینه است. استفاده از این دو نوع مدل پاداش می تواند به بهبود عملکرد مدل زبانی در وظایف پیچیده کمک کند. برای مثال، در حل مسائل ریاضی یا پاسخ به سؤالات استدلالی، مدل پاداش فرآیند می تواند مدل را به سمت رویکردهای گام به گام و دقیق تر هدایت کند، در حالی که مدل پاداش خروجی کیفیت نهایی پاسخ را تضمین می کند. ترکیب این دو مدل می تواند به ایجاد پاسخ هایی منجر شود که نه تنها درست هستند، بلکه فرآیند رسیدن به آن ها نیز شفاف و قابل اعتماد است. یکی از کارهایی که سعی در بهبود توانایی دلیل آوری کرده است مدل Medsss [۳۲] است که در فصل کارهای پیشین در مورد آن توضیحات لازم داده شده است.

۳.۳.۶.۲ روش های مبتنی بر تمرین روی داده های دلیل آوری


یکی دیگر از روش های بهبود مهارت های استدلالی یک مدل زبانی، آموزش آن با داده های استدلالی است. با انجام این کار، مدل زبانی می تواند یاد بگیرد که چگونه استدلال را تقلید کند یا استدلال هایی را که قبلاً در داده های آموزشی خود مشاهده کرده است، بازایی کند. این رویکرد به مدل کمک می کند تا در مواجهه با مسائل پیچیده، پاسخ هایی منطقی تر و ساختار یافته تر ارائه دهد. [۳۳]

در این روش، داده های آموزشی شامل نمونه هایی از فرآیندهای استدلالی، مانند حل گام به گام مسائل ریاضی، تحلیل های منطقی، یا استدلال های مبتنی بر شواهد هستند. با قرار گرفتن در معرض این داده ها، مدل زبانی نه تنها یاد می گیرد که پاسخ های درست تولید کند، بلکه می آموزد که چگونه به طور نظام مند به آن پاسخ ها برسد. این فرآیند به بهبود توانایی مدل در درک عمیق تر پرسش ها و ارائه پاسخ هایی با کیفیت بالاتر کمک می کند. در حقیقت مدل زبانی پایه با تمرین روی داده های استدلالی یاد می گیرد که فرآیند استدلال را شبیه سازی کند و ما تصور کنیم که در حال دلیل آوری است در حالی که معماری که آن مدل روی آن بنا شده توانایی استدلال را ندارد این پدیده


output reward model^{۶۶}process reward model^{۶۷}

ای است که به آن توهم دلیل آوری^{۶۸} میگویند. [۳۴] [۳۵] یکی از مهم‌ترین کارهایی که این رویکرد را با موفقیت پیاده‌سازی کرده، مدل DeepSeek-R [۳۶] است. این مدل با استفاده از مجموعه داده‌های استدلالی گسترده و متنوع آموزش دیده است و توانسته است عملکرد قابل توجهی در وظایف استدلالی پیچیده از خود نشان دهد. DeepSeek-R با بهره‌گیری از تکنیک‌های پیشرفته در آموزش مدل‌های زبانی، قادر است استدلال‌های منطقی را با دقت بالا تولید کند و حتی در مواردی که نیاز به تفکر چندمرحله‌ای است، عملکردی رقابتی با مدل‌های بزرگ‌تر ارائه دهد. برای اطلاعات بیشتر درباره این مدل و جزئیات رویکرد آن، می‌توانید به بخش کارهای پیشین مراجعه کنید.

^{۶۸}delusion of thinking



شکل ۱.۲: معماری ترنسفورمر [۸]



شکل ۲.۲: مقایسه الگوریتم بهینه‌سازی سیاست مجاورتی و بهینه‌سازی مستقیم ترجیحات [۲۲]

فصل ۳

بررسی کارهای پیشین

۱.۳ مقدمه

همان‌طور که پیش‌تر اشاره شد، علیرغم پیشرفت‌های چشمگیر در توسعه مدل‌های زبانی پزشکی به زبان انگلیسی، مانند توسعه و معرفی مدل‌های MedPalm [۳۷] [۳۸] یا مدل Med-Gemini [۳۹]، متأسفانه در حوزه زبان فارسی هنوز کار چندانی در این زمینه انجام نشده است. این مسئله بدین معناست که ما در حوزه زبان فارسی تقریباً با یک کاغذ سفید روبه‌رو هستیم. در این پایان‌نامه تلاش شده است تا قدمی رو به جلو در جهت توسعه مدل‌های زبانی پزشکی برای زبان فارسی برداشته شود. در ادامه، به بررسی کارهای پیشین انجام‌شده در حوزه زبان انگلیسی، حوزه زبان فارسی و مدل‌های دارای قابلیت دلیل‌آوری خواهیم پرداخت.

۲.۳ کارهای پیشین در حوزه زبان انگلیسی

۱.۲.۳ مدل‌های MedPaLM

مدل‌های MedPaLM یکی از مدل‌های زبانی پزشکی بزرگ^۱ است که توسط تیم تحقیقاتی گوگل برای کاربرد های پزشکی توسعه داده شده است. این مدل با استفاده از داده‌های تخصصی پزشکی و بالینی آموزش

^۱large medical language models

دیده است. هدف اصلی این خانواده از مدل های زبانی پزشکی پاسخ گویی به پرسش های پزشکی با دقت بالا، کمک به پزشکان در تصمیم گیری های بالینی، و تسهیل دسترسی به اطلاعات پزشکی برای کاربران است. نسخه های مختلف این مدل، مانند MedPaLM و MedPaLM2، توانایی های قابل توجهی در درک و تحلیل زبان تخصصی پزشکی نشان داده اند و به عنوان یک ابزار نوین در حوزه هوش مصنوعی پزشکی شناخته می شوند. این مدل ها با استفاده از آزمون های استاندارد پزشکی (مانند USMLE) ارزیابی شده و توانسته اند عملکردی نزدیک به سطح متخصصین پزشکی ارائه دهند. مدل MedPaLM2 به عنوان یک گام مهم در جهت توسعه مدل های زبان تخصصی در حوزه سلامت و پزشکی شناخته می شود.

۲.۲.۳ مدل ChatDoctor

مدل ChatDoctor [۴۰] یکی از برجسته ترین تلاش ها در حوزه توسعه مدل های زبانی پزشکی است که شباهت قابل توجهی به فاز نخست پایان نامه حاضر دارد. تیم توسعه دهنده این مدل، داده های آموزشی خود را از دو پلتفرم آنلاین پرسش و پاسخ پزشکی به نام های HealthcareMagic و iCliniq جمع آوری کرده اند. این تیم ابتدا بیش از دویست هزار جفت پرسش و پاسخ پزشکی از این منابع گردآوری کرده و سپس با اعمال فیلترهایی بر اساس طول و کیفیت پاسخ ها، مجموعه ای با کیفیت بالا شامل صد هزار جفت پرسش و پاسخ نهایی ایجاد کرده اند. داده های مذکور به عنوان پایه ای برای آموزش و تنظیم دقیق^۲ مدل LLaMa [۴۱] مورد استفاده قرار گرفته اند تا مدلی توانمند در تولید اطلاعات پزشکی دقیق و مرتبط ایجاد شود.

علاوه بر این، این مدل از رویکرد تولید مبتنی بر بازبازی اطلاعات^۳ بهره برده است. این رویکرد به مدل امکان می دهد تا به اطلاعات جدید و خارجی دسترسی پیدا کرده و آن ها را به طور مؤثر در پاسخ های خود ادغام کند. چنین رویکردی موجب ارتقای عملکرد کلی سیستم شده و توانایی مدل در تولید پاسخ هایی دقیق تر و مرتبط تر را به طور چشمگیری بهبود بخشیده است.

۳.۲.۳ مدل های Meerkat

مدل های Meerkat [۴۲] یکی دیگر از تلاش های برجسته در حوزه توسعه مدل های زبانی پزشکی است. این پروژه با استخراج زنجیره های تفکر^۴ از کتاب های درسی پزشکی و تنظیم دقیق یک مدل زبانی پایه با استفاده از این داده ها، همراه با مجموعه داده های مکمل دیگر، به وجود است. همانند فاز دوم پایان نامه حاضر هدف

^۲ fine-tuning

^۳ retrieval augmented generation

^۴ chain of thought

اصلی Meerkat تمرکز بر فرآیندهای استدلالی است که در تصمیم‌گیری‌های پزشکی نقش دارند. این مدل تلاش کرده است تا نه تنها اطلاعات پزشکی دقیق ارائه دهد، بلکه فرآیندهای شناختی و تصمیم‌گیری متخصصان حوزه سلامت را شبیه‌سازی کند. به همین دلیل، Meerkat به عنوان مدلی برای تعاملات پیچیده‌تر و آگاهانه‌تر در حوزه پزشکی معرفی شده است.

۴.۲.۳ مدل MedMobile

MedMobile [۴۳] تلاشی دیگر در حوزه مدل‌های زبانی کوچک پزشکی است. برای توسعه این مدل زبانی کوچک، مدل Phi-3-mini [۴۴] به عنوان مدل پایه^۵ استفاده از ترکیبی از داده‌های مصنوعی و تولیدشده توسط انسان تنظیم دقیق^۶ شده است تا عملکردی بهینه و مناسب برای اجرا روی دستگاه‌های همراه مانند موبایل ارائه دهد. با تمرکز بر نیازهای خاص کاربران دستگاه‌های همراه، MedMobile تلاش کرده است مدلی کارآمد و مؤثر فراهم کند که دسترسی به اطلاعات پزشکی باکیفیت را در هر زمان و مکان به صورت محلی^۷ ممکن می‌سازد.

۳.۳ کارهای پیشین در حوزه زبان فارسی

همان‌طور که پیش‌تر اشاره شد، تحقیقات محدودی بر روی مدل‌های زبانی پزشکی فارسی تمرکز داشته‌اند که این امر نشان‌دهنده شکاف قابل توجهی در منابع موجود برای جامعه پزشکی فارسی‌زبان است. علاوه بر این، پژوهش‌های بسیار اندک موجود در این زمینه، به طور کامل در مورد مجموعه داده‌ها، مدل‌ها و کدهای خود متن بسته^۸ هستند.

از سوی دیگر، تمامی این تلاش‌ها عمدتاً بر روی راهکارهای استخراجی^۹ متمرکز بوده‌اند که هدفشان بازیابی اطلاعات مرتبط از منابع از پیش تعریف شده است، به جای استفاده از رویکردهای تولیدی^{۱۰} که قادر به تولید پاسخ‌های آگاه از زمینه باشند.

baseline model^۵

fine tune^۶

local^۷

closed-source^۸

extractive^۹

generative^{۱۰}

۱.۳.۳ مدل Sina-bert

شاید اولین و برجسته ترین مدل زبانی پزشکی فارسی، Sina-BERT [۴۵] باشد که شامل آموزش یک مدل BERT [۴۶] با استفاده از یک پیکره خزش شده^{۱۱} همراه با مجموعه داده پرسش و پاسخ پزشکی فارسی است که به طور خاص برای کاربردهای مختلف از جمله پاسخ به سوالات پزشکی، تحلیل احساسات پزشکی و بازیابی سوالات پزشکی توسعه یافته اند.

Sina-BERT در میان تلاش های متمرکز بر زبان فارسی، بیشترین شباهت را به فاز نخست پایان نامه حاضر دارد؛ با این تفاوت که از مدل برت^{۱۲} یک مدل زبانی مبتنی بر رمزگذار^{۱۳} به عنوان مدل پایه استفاده می کند. این انتخاب تولید پاسخ توسط این مدل را عملاً ناممکن می سازد، چرا که برت عمدتاً برای درک و استخراج اطلاعات طراحی شده است نه برای تولید پاسخ.

۲.۳.۳ سیستم پرسش و پاسخ پزشکی دکتر ویسی و همکاران

یکی از آثار برجسته در حوزه پردازش زبان طبیعی، سیستم پرسش و پاسخ پزشکی فارسی است که توسط دکتر ویسی و همکارانش [۴۷] طراحی و توسعه داده شده است. این سیستم به طور کلی شامل سه ماژول اصلی است: پردازش پرسش، بازیابی سند و استخراج پاسخ. ماژول پردازش پرسش وظیفه تحلیل و اصلاح پرسش های کاربران را برعهده دارد تا پرسش ها به شکل بهینه برای مراحل بعدی آماده شوند. سپس، ماژول بازیابی سند با استفاده از الگوریتم های پیشرفته، اسناد پزشکی مرتبط را از میان داده های از پیش تعیین شده پیدا می کند. در نهایت، ماژول استخراج پاسخ با شناسایی دقیق اطلاعات موجود در اسناد بازیابی شده، مناسب ترین پاسخ ها را استخراج کرده و به کاربران ارائه می دهد. این سیستم نه تنها به طور مؤثر به پرسش های پزشکی پاسخ می دهد، بلکه ساختار ماژولار آن امکان بهبود و توسعه در آینده را نیز فراهم می سازد.

۳.۳.۳ پایان نامه کارشناسی ارشد خانم لیلا دارابی

مشابه به این دو اثر، پیشین لیلا دارابی در پایان نامه ارشد خود [۴۸] از مدل هایی مانند Pars-BERT [۴۹] برای بازیابی پاسخ های مرتبط استفاده کرده است. رویکرد او شامل یافتن سوالات مشابه برای مدیریت پرسش های تکراری و به کارگیری استراتژی های ارزیابی دقیق و سهل گیرانه برای پاسخ های دقیق یا تقریبی می شود. علاوه بر

^{۱۱} crawled
^{۱۲} BERT
^{۱۳} encoder-based

این، روش‌های طبقه‌بندی و شناسایی موجودیت‌های نامدار^{۱۴} برای بهبود ارتباط پاسخ‌ها از طریق دسته‌بندی سوالات و شناسایی موجودیت‌های پزشکی مانند نام داروها و بیماری‌ها به کار گرفته می‌شوند.

۴.۳ بهبود قابلیت دلیل آوری در حوزه پزشکی

۱.۴.۳ مدل MedSSS

یکی از تلاش‌های برجسته در این حوزه، مدل زبانی MedSSS است. [۳۲] هدف اصلی این چارچوب، ارتقای توانایی استدلال مدل‌های پزشکی از طریق دقت‌بخشی و ریزسازی مراحل میانی استدلال بین پرسش و پاسخ نهایی است. همانطوری که در تصویر ۱.۳ برای دستیابی به این هدف، پژوهشگران از الگوریتم جست‌وجوی درختی مونت‌کارلو^{۱۵} [۵۰] استفاده کردند. این الگوریتم بر روی مجموعه داده‌هایی از پرسش‌های چندگزینه‌ای پزشکی به کار گرفته شد تا مسیرهای استدلالی ساختارمند و مرحله به مرحله تولید شود؛ مسیرهایی که نشان می‌دهند مدل چگونه از پرسش به پاسخ درست می‌رسد. بر اساس این رویکرد، نویسندگان به صورت مصنوعی سه مجموعه داده مجزا ساختند که هر یک در مرحله‌ای خاص از آموزش مدل نقش دارد:

۱. مجموعه داده تنظیم دقیق نظارت شده: برای آموزش مدل سیاستی^{۱۶} از طریق نمونه‌های استدلال با کیفیت.
۲. مجموعه داده پاسخ‌های ترجیح داده شده و رد شده: برای آموزش مبتنی بر بهینه‌سازی مستقیم ترجیحات^{۱۷} تا مدل بتواند میان پاسخ‌های بهتر و ضعیف‌تر تمایز قائل شود.
۳. مجموعه داده برچسب‌های نرم دوسویه: جهت تنظیم دقیق مدل پاداش فرآیند^{۱۸} که به جای تمرکز صرف بر پاسخ نهایی، کیفیت فرآیند استدلال مدل را ارزیابی می‌کند.

در نهایت، مدل سیاستی آموزش دیده به عنوان موتور اصلی استدلال در فرآیند تولید پاسخ عمل می‌کند، در حالی که مدل پاداش فرآیند آموزش دیده نقش راهنما و ارزیاب را در هنگام تولید ایفا می‌نماید. این مدل دوم کمک می‌کند تا فرآیند استدلال مدل به صورت پیوسته اصلاح شده و از نظر منطق، انسجام و درستی پزشکی ارزیابی گردد.


^{۱۴} named entity recognition

^{۱۵} monte carlo tree search

^{۱۶} policy model

^{۱۷} direct preference optimization

^{۱۸} process reward model



شکل ۱.۳: بلوک دیگرام مدل medsss [۳۲]

۲.۴.۳ مدل MedReason

یکی دیگر از دستاوردهای مهم در زمینه توسعه مدل‌های زبانی استدلال‌محور در حوزه پزشکی، مدل زبانی MedReason است. [۵۱] در این پژوهش، نویسندگان از یک گراف دانش ساختاریافته پزشکی^{۱۹} بهره گرفتند تا جفت‌های متداول پرسش و پاسخ را به مسیرهای استدلالی دقیق و گام‌به‌گام تبدیل کنند. هر مسیر استدلالی، زنجیره‌ای منطقی از گام‌های مرتبط را نشان می‌داد که یک پرسش بالینی را به پاسخ صحیح آن متصل می‌کرد و این ارتباط بر پایه روابط دانش پزشکی مانند علائم، تشخیص‌ها، درمان‌ها و سازوکارهای فیزیولوژیکی بنا شده بود. پژوهشگران با ساخت چنین مجموعه داده‌ای غنی شده از استدلال، توانستند یک مدل زبانی پایه را بر اساس این نمونه‌های ساختاریافته تنظیم دقیق کنند. این رویکرد سبب شد تا توانایی مدل در انجام وظایف پیچیده و استدلال‌محور در حوزه پزشکی به طور قابل توجهی بهبود یابد. نتایج حاصل نشان داد که نظارت مبتنی بر استدلال استخراج شده از گراف‌های دانش، می‌تواند نقش مؤثری در ارتقای دقت و قابلیت تحلیل مدل‌های زبانی پزشکی ایفا کند.

یافته‌های حاصل از پژوهش MedReason همچنین بر اهمیت نمایش‌های ساختاریافته استدلال در بهبود تفسیرپذیری^{۲۰} و عمق تحلیلی مدل‌های زبانی پزشکی تأکید می‌کنند. این چارچوب نشان می‌دهد که ترکیب دانش ساختاریافته با فرآیند یادگیری زبانی، می‌تواند پلی میان درک داده‌محور و استدلال مبتنی بر دانش در سامانه‌های

^{۱۹} medical knowledge graph
^{۲۰} interpretability

هوش مصنوعی پزشکی ایجاد کند.

۳.۴.۳ مدل HuatuoGPT-o1

یکی از پیشرفت‌های مهم دیگر در توسعه مدل‌های زبانی استدلال‌محور پزشکی، چارچوبی با نام HuatuoGPT-o1 است. [۵۲] در این پژوهش، نویسندگان یک چارچوب استدلال با هدایت اعتبارسنجی^{۲۱} را معرفی کردند که هدف آن بهبود انسجام منطقی و دقت مسیرهای استدلالی تولیدشده توسط مدل است. در این رویکرد، یک مدل اعتبارسنج^{۲۲} به عنوان جز کنترلی و ارزیاب به کار گرفته شد تا در حین فرآیند تولید استدلال، عملکرد مدل سیاستی را ارزیابی و هدایت کند. این مکانیزم اطمینان حاصل می‌کند که هر مسیر استدلالی تولیدشده با واقعیت‌های علمی و اصول پذیرفته‌شده پزشکی سازگار باشد. با استفاده از فرآیند فیلترسازی و پالایش مسیرهای استدلال از طریق این مدل اعتبارسنج، پژوهشگران موفق به تولید یک مجموعه داده با کیفیت متشکل از دنباله‌های استدلالی تأییدشده شدند.

در گام بعد، نویسندگان از ترکیب دورویکرد آموزش، شامل تنظیم دقیق نظارت‌شده و یادگیری تقویتی، برای آموزش مدل زبانی پایه با استفاده از داده‌های اعتبارسنجی‌شده بهره بردند. این رویکرد دوگانه باعث شد مدل نه تنها رفتارهای استدلالی صحیح را تقلید کند، بلکه اصول استدلال منطقی را از طریق بهینه‌سازی مبتنی بر پاداش درونی‌سازی نماید. نتایج حاصل از این پژوهش نشان داد که مدل HuatuoGPT-o1 در طیف وسیعی از وظایف پزشکی، از جمله پاسخ‌گویی به پرسش‌های بالینی و استدلال تشخیصی، بهبود چشمگیری در دقت و قابلیت اعتماد از خود نشان می‌دهد. این دستاورد اهمیت چارچوب‌های یادگیری هدایت‌شده با اعتبارسنج را در ارتقای مدل‌های زبانی استدلالی در حوزه پزشکی برجسته می‌سازد و مسیر توسعه سامانه‌های هوش مصنوعی با استدلال قابل اعتماد را هموار می‌کند.

۵.۳ بهبود قابلیت دلیل آوری در حوزه‌های دیگر

۱.۵.۳ مدل دیپ سیک

یکی از تاثیرگذارترین پژوهش‌های اخیر در حوزه گسترده استدلال در هوش مصنوعی، مدل DeepSeek-R است. [۳۶] این مدل بر پایه نسخه پایه DeepSeek-V3-Base توسعه یافته و با هدف ارتقای صریح قابلیت‌های

^{۲۱} verification guided reasoning framework
^{۲۲} verifier model

استدلالی، چارچوبی مبتنی بر یادگیری تقویتی را به کار می‌گیرد. در این چارچوب، نویسندگان از الگوریتم بهینه سازی سیاست بر پایه پاداش گروهی^{۲۳} استفاده کردند تا فرآیند یادگیری تقویتی را به گونه‌ای هدایت کنند که عملکرد استدلالی مدل به صورت هدفمند بهبود یابد.

در این رویکرد، تابع پاداش به طور ویژه طراحی شد تا کیفیت استدلال مدل را ارزیابی کرده و آن را به حداکثر برساند. نتایج نشان داد که مدل DeepSeek-R از طریق این الگوی آموزشی، پیشرفت چشمگیری در منطق استدلالی و دقت حل مسئله در مجموعه‌ای از معیارهای استاندارد^{۲۴} به دست آورده است. با این حال، استفاده از یادگیری تقویتی بدون کنترل کامل، پیامدهایی جانبی نیز به همراه داشت؛ از جمله کاهش روانی زبان، افت انسجام جمله‌ای، و افزایش بروز پدیده اختلاط زبانی^{۲۵} در خروجی مدل.

برای رفع این چالش‌ها، پژوهشگران مرحله‌ای تکمیلی به فرآیند آموزش افزودند. در این مرحله، مقدار اندکی داده نظارت شده اولیه^{۲۶} مورد استفاده قرار گرفت و یک زنجیره آموزشی چندمرحله‌ای^{۲۷} طراحی شد. این فاز تنظیم دقیق کمک کرد تا ضمن حفظ توانمندی‌های استدلالی کسب شده از یادگیری تقویتی، روانی و خوانایی زبان طبیعی نیز بازگردانده شود.

در نتیجه، مدل DeepSeek-R به عنوان گامی اساسی در مسیر توسعه هوش مصنوعی استدلال محور مطرح شد؛ مدلی که نشان می‌دهد یادگیری تقویتی می‌تواند به طور قابل توجهی توانایی استدلال را ارتقا دهد، مشروط بر آنکه با تنظیم دقیق و نظارت زبانی هدفمند ترکیب شود تا تعادل میان کیفیت زبانی و عمق استدلالی حفظ گردد.

۲.۵.۳ چهارچوب بهینه سازی ترجیحات فکری

یکی از دستاوردهای قابل توجه در زمینه بهبود توانایی استدلال در مدل‌های زبانی، روش بهینه سازی ترجیحات فکری^{۲۸} است. [۵۳] در این پژوهش، نویسندگان چارچوبی مبتنی بر ترجیحات را برای ارتقای کیفیت استدلال در مدل‌های زبانی پیشنهاد کردند.

همانطور که در تصویر ۲.۳ می‌بینید در این رویکرد، هنگامی که یک پرسش به مدل ارائه می‌شود، ابتدا مدل چندین مسیر استدلالی متفاوت را به عنوان پاسخ‌های بالقوه تولید می‌کند. سپس این مسیرهای استدلالی توسط یک مدل داور^{۲۹} مورد ارزیابی قرار می‌گیرند. مدل داور با بررسی صحت منطقی، انسجام و کیفیت استدلال،

^{۲۳} group reward policy optimization

^{۲۴} benchmarks

^{۲۵} language mixing

^{۲۶} cold-start supervised data


^{۲۷} multi-stage training pipeline

^{۲۸} thought preference optimization

^{۲۹} judge model

بهترین و ضعیف‌ترین نمونه‌ها را از میان خروجی‌ها شناسایی می‌کند. در گام بعد، جفت‌های انتخاب‌شده از پاسخ‌های «بهتر» و «ضعیف‌تر» برای آموزش مدل پایه با استفاده از روش بهینه‌سازی مستقیم ترجیحات^{۳۰} به کار گرفته می‌شوند. این فرآیند باعث می‌شود مدل به صورت تدریجی مسیرهای استدلالی باکیفیت‌تر را ترجیح دهد و یاد بگیرد که استدلال‌هایی منطقی‌تر، پیوسته‌تر و نزدیک‌تر به شیوه تفکر انسانی تولید کند.

نتایج این پژوهش نشان داد که به کارگیری چارچوب بهینه‌سازی ترجیحات فکری موجب بهبود چشمگیری در کیفیت استدلال مدل‌های زبانی می‌شود. این یافته بیانگر آن است که ارتقای توانایی استدلالی مدل‌ها تنها از طریق افزایش مقیاس یا داده‌های آموزشی نظارت‌شده حاصل نمی‌شود، بلکه می‌توان با بهره‌گیری از سازوکارهای یادگیری مبتنی بر ترجیح و بازخورد ارزیابانه، به بهبودی مؤثرتر و پایدارتر در فرآیند استدلال مدل دست یافت.



شکل ۲.۳: بلوک دیاگرام بهینه‌سازی ترجیحات فکری [۵۳]


۳.۵.۳ آموزش استدلال مدل‌های بزرگ به مدل‌های کوچک

یکی از پژوهش‌های مرتبط در زمینه انتقال توانایی استدلال میان مدل‌های زبانی، توسط آقای هو و همکاران انجام شده است. [۵۴] در این پژوهش، نویسندگان به بررسی چگونگی انتقال قابلیت‌های استدلالی از مدل‌های زبانی بزرگ به مدل‌های کوچک‌تر پرداختند. ایده اصلی این رویکرد بر آن استوار است که مدل‌های کوچک‌تر می‌توانند از داده‌های تولیدشده توسط مدل‌های بزرگ‌تر، که از قدرت استدلالی بالاتری برخوردارند، برای بهبود عملکرد خود بهره ببرند.

همانطور که در تصویر ۳.۳ در این روش، ابتدا یک مدل زبانی بزرگ با عملکرد استدلالی قوی‌تر به تولید مسیرهای استدلالی^{۳۱} و جفت‌های پرسش و پاسخ می‌پردازد. این خروجی‌ها به عنوان داده‌های آموزشی باکیفیت و مبتنی بر استدلال، برای تنظیم دقیق مدل کوچک‌تر مورد استفاده قرار می‌گیرند. بدین ترتیب، مدل کوچک‌تر از این طریق، الگوهای حل مسئله و استراتژی‌های استدلالی را از مدل بزرگ‌تر فرا می‌گیرد.

^{۳۰}direct preference optimization
^{۳۱}reasoning trajectories

نتایج نشان داد که مدل کوچک‌تر پس از این آموزش هدفمند، توانست عملکردی رقابتی در وظایف استدلالی از خود نشان دهد؛ در حالی که هزینه محاسباتی آن به‌طور قابل‌توجهی کمتر از مدل بزرگ‌تر بود. این پژوهش اهمیت استفاده از داده‌های مصنوعی مبتنی بر استدلال و یادگیری انتقالی هدفمند را در بهبود بازده و کارایی مدل‌های زبانی کوچک‌تر برجسته می‌کند. به عبارت دیگر، توانایی استدلال را می‌توان به‌صورت مؤثر میان مدل‌هایی با مقیاس‌های متفاوت منتقل کرد، مشروط بر آنکه فرآیند تنظیم دقیق بر اساس داده‌های تولیدشده از مدل‌های استدلالی پیشرفته انجام گیرد.



شکل ۳.۳: بلوک دیاگرام آموزش دلیل آوری توسط مدل بزرگ‌تر به مدل کوچک‌تر [۵۴]

فصل ۴

جمع آوری دادگان

۱.۴ مقدمه

برای این منظور، اقدام به جمع‌آوری داده‌ها صورت گرفت. داده‌های جمع‌آوری شده شامل یک پیکره پزشکی، یک مجموعه داده پرسش و پاسخ فرم آزاد^۱ و یک مجموعه داده پرسش و پاسخ چهار گزینه‌ای بودند. شیوه‌های جمع‌آوری این داده‌ها شامل خزش^۲، ترجمه انسانی، ترجمه ماشینی و تبدیل عکس به متن بودند که در ادامه به تفصیل به هر یک از این روش‌ها پرداخته خواهد شد؛ در این راستا، تلاش‌هایی برای استفاده از منابع مختلف و بهره‌گیری از تکنیک‌های نوین صورت گرفت تا داده‌هایی با کیفیت بالا و متنوع گردآوری شوند. این داده‌ها امکان انجام تحقیقات دقیق‌تر و دستیابی به نتایج قابل اعتماد را فراهم کردند.

۲.۴ معرفی پیکره پزشکی فارسی

عدم وجود یک پیکره پزشکی اختصاصی به زبان فارسی، چالشی قابل توجه برای پژوهشگران و توسعه‌دهندگان ایجاد می‌کند که هدفشان توسعه مدل‌های پزشکی در زبان فارسی است. بدون داده‌های متنی باکیفیت و تخصصی که برای آموزش مدل‌های هوش مصنوعی ضروری است، این تلاش‌ها ممکن است با موانع روبه‌رو شوند و در نهایت بر توسعه فناوری‌ها و راه‌حل‌های پیشرفته پزشکی مناسب برای جمعیت فارسی‌زبان تاثیر بگذارند. برای

^۱ answering question form free
^۲ crawl

حل این مشکل، ما یک پیکره^۳ جامع شامل تقریباً نود میلیون توکن و حدود صد هزار مقاله گردآوری کرده‌ایم.^۴ گارسیا فررو و همکاران [۵۵] مجموعه‌ای از متون پزشکی را که به چهار زبان (انگلیسی، فرانسوی، اسپانیایی و ایتالیایی) اختصاص داشت، گردآوری کردند که می‌توان آن را همانطور که در جدول ۱.۴ نشان داده شده است با مجموعه ما مقایسه کرد. پیکره ای که ما گردآوری کرده ایم از مجله‌های آنلاین پزشکی خزش شده است که می‌توانید سهم هر مجله در این پیکره را در تصویر ۱.۴ ببینید.

زبان	تعداد توکن‌ها	گردآورنده
انگلیسی	1.1B	I. Garcia Ferrero et al.
اسپانیایی	950M	I. Garcia Ferrero et al.
فرانسوی	675M	I. Garcia Ferrero et al.
ایتالیایی	143M	I. Garcia Ferrero et al.
فارسی	90M	ما

جدول ۱.۴: مقایسه پیکره گردآوری شده با پیکره‌های گردآوری شده توسط گارسیا فررو

۳.۴ معرفی مجموعه داده MF3QA

گردآوری یک مجموعه داده واقعی از پرسش و پاسخ‌های پزشک و بیمار (پرسش و پاسخ فرم آزاد) اهمیت بسیاری در ارتقا توانایی‌های مدل‌های زبانی در حوزه بهداشت و درمان دارد. چنین مجموعه داده‌ای به مدل‌های زبانی امکان می‌دهد تا اطلاعات ارزشمندی را که از تعاملات واقعی میان ارائه‌دهندگان خدمات بهداشتی و بیماران به دست می‌آید، بیاموزند. با تحلیل این تعاملات واقعی، مدل‌های زبانی می‌توانند به درک جزئیات اصطلاحات پزشکی، نگرانی‌های بیماران، و زمینه پیرامون سوالات بهداشتی دست یابند. علاوه بر این، این مجموعه داده مدل‌ها را قادر می‌سازد نه تنها محتوای دقیق پاسخ‌ها، بلکه ساختار و لحن مناسب برای پاسخ‌دهی به سوالات را نیز یاد بگیرند. این فرآیند دوگانه یادگیری از اهمیت بالایی برخوردار است، زیرا به مدل امکان می‌دهد پاسخ‌هایی دقیق، همدلانه و متناسب با زمینه ارائه دهد و در نهایت ارتباط و پشتیبانی از بیماران در محیط‌های پزشکی را بهبود بخشد.

^۳ corpus

^۴ برای بازدید از این پیکره می‌توانید به آدرس huggingface.co/datasets/gaokerena/medical_corpus مراجعه کنید

در این راستا ما مجموعه داده MF3QA که شامل بیست هزار جفت پرسش و پاسخ پزشکی در مجموعه تمرین^۵، دو هزار جفت پرسش و پاسخ پزشکی در مجموعه توسعه^۶ و دو هزار جفت پرسش و پاسخ پزشکی در مجموعه آزمایش^۷ است را معرفی کردیم. همچنین در این زمینه، یانگ لیو در مقاله مروری^۸ خود [۵۶] به چندین مجموعه داده واقعی پرسش و پاسخ پزشک و بیمار اشاره کرده است، مقایسه‌ای میان این مجموعه دادگان و مجموعه داده ما در جدول ۲.۴ ارائه شده است.


نام مجموعه داده	زبان	تعداد پرسش و پاسخ ها	گردآورنده
ChatDoctor	انگلیسی	100K	[۴۰] Yunxiang Li et al.
CMtMedQA	چینی	68K	[۵۷] Songhua Yang et al.
DISC-Med-SFT	چینی	465K	[۵۸] Zhijie Bao et al.
HuatuoGPT-sft-data-v1	چینی	226K	[۵۹] Hongbo Zhang et al.
Huatuo-26M	چینی	26M	[۶۰] Jianquan Li et al.
MedDialog	چینی و انگلیسی	3.66M	[۶۱] Guangtao Zeng et al.
Medical-Meadow	انگلیسی	160k	[۶۲] Tianyu Han et al.
MF3QA	فارسی	20k	ما

جدول ۲.۴: مقایسه مجموعه داده های پرسش و پاسخ آزاد پزشکی با مجموعه داده گردآوری شده

۱.۳.۴ منابع مجموعه داده MF3QA

همان طور که در شکل ۲.۴ نشان داده شده است، برای گردآوری مجموعه داده MF3QA مراحل مختلفی طی شده است. در بخش آموزش، پرسش و پاسخ های بیمار و پزشک موجود در تالارهای گفت و گوی پزشکی فارسی^۹ "دکترهست" و "نی نی بان" را خزش کرده ایم. برای بخش اعتبارسنجی، تنها از داده های موجود در سایت "نی نی بان" استفاده کرده ایم تا انسجام بیشتری در این بخش حاصل شود. در بخش آزمایش نیز، از سایت های

train set^۵
development set^۶
test set^۷
survey^۸
Persian medical forums^۹



شکل ۱.۴: سهم هر مجله در پیکره پزشکی فارسی گردآوری شده

”دکتر یاب” و ”ایزوویزیت” بهره برده ایم و به منظور اطمینان از تنوع داده ها، مجموعه داده پرسش و پاسخ K-QA [۱۶] را ترجمه کرده و به این بخش اضافه کرده ایم.^{۱۰}



شکل ۲.۴: سهم هر تالار گفتگو در مجموعه داده MF3QA

^{۱۰} مجموعه پرسش و پاسخ های مجموعه آزمایش به طور کامل از منابع متفاوتی نسبت به مجموعه تمرین و توسعه انتخاب شده اند.

۲.۳.۴ فیلتر کردن رکورد های مجموعه داده MF3QA

در پایان نامه حاضر، بیش از صد و هشتاد هزار جفت پرسش و پاسخ از تالارهای گفت و گوی پزشکی فارسی گردآوری شده است. این جفت های پرسش و پاسخ، چه به صورت دستی^{۱۱} و چه به صورت خودکار، مورد بررسی قرار گرفته و جفت هایی که حاوی اطلاعات مفید نبودند، حذف شده اند.^{۱۲}

این رویکرد مشابه کاری است که یونشیانگ لی و همکارانش برای توسعه مدل زبانی Chat Doctor انجام داده اند. [۴۰] آنها نیز داده ها را از تالارهای گفت و گوی پزشکی انگلیسی استخراج کرده و نیمی از جفت های پرسش و پاسخ را بر اساس طول پاسخ ها کنار گذاشته اند^{۱۳}، چراکه پاسخ های کوتاه تر معمولاً حاوی اطلاعات مفیدی نیستند. با این حال، ما با چالش بزرگ تری مواجه بودیم؛ پزشکان فارسی زبان معمولاً پاسخ های بسیار کوتاه تری نسبت به هم تاییان انگلیسی خود ارائه می دهند. این امر ما را مجبور کرد تا بیش از هشتاد درصد از رکوردهای پرسش و پاسخ خود را برای تضمین کیفیت کنار بگذاریم.

۱.۲.۳.۴ خزش از تالار گفتگو دکترهست

خزش از تالار گفتگوی “دکترهست”، که اصلی ترین منبع مجموعه داده MF3QA است، با چالش خاصی همراه بود. این تالار گفتگو تمام رکوردهای تعامل پزشک و بیمار خود را به صورت مستقیم در سایت ارائه نمی دهد و فقط به دو هزار رکورد آخر دسترسی می دهد. علاوه بر این، هر رکورد به صد رکورد مرتبط دیگر پیوند داده شده است.

برای حل این چالش، از الگوریتم ۱.۴ استفاده شد. در این روش، داده های تالار گفتگو به صورت یک گراف در نظر گرفته شده و با استفاده از جستجوی عرض-اول^{۱۴} توانستیم حدود صد و بیست هزار رکورد از مجموع دویست هزار رکورد موجود در این تالار گفتگو را استخراج کنیم. این فرایند حدود دو هفته طول کشید.

^{۱۱} فرآیند فیلتر کردن دستی توسط خانم زهرا کاظمی و آقای میلاد توکلی، از دانشجویان کارشناسی مهندسی کامپیوتر، انجام شده است.
^{۱۲} برای بازدید از مجموعه داده MF3QA به آدرس huggingface.co/datasets/gaokerena/MF3QA و برای بازدید از صد و هشتاد هزار جفت پرسش و پاسخ خزش شده به آدرس huggingface.co/datasets/gaokerena/MF3QA_uncleaned مراجعه کنید.

^{۱۳} فیلتر کردن آنها صرفاً بر اساس طول پاسخ بوده ولی همانطور که پیشتر اشاره شد ما برای فیلتر کردن از روش های دستی نیز استفاده کرده ایم.

^{۱۴} breadth first search

الگوریتم ۱.۴ الگوریتم جستجو اول عرض برای استخراج رکورد های پرسش و پاسخ پزشکی

ورودی: گره های دارای دسترسی در تالار گفتگو (برگ ها)

خروجی: مجموعه ای از گره های بازدید شده

۱: یک پشته خالی S ایجاد کن

۲: یک مجموعه خالی $Visited$ ایجاد کن

۳: گره مبدأ v را به پشته S اضافه کن

۴: تا زمانی که پشته S خالی نیست انجام بده

۵: یک گره u را از پشته S بردار

۶: اگر گره u بازدید نشده است آنگاه

۷: گره u را به مجموعه $Visited$ اضافه کن

۸: برای هر همسایه n از گره u انجام بده

۹: اگر گره n بازدید نشده است آنگاه

۱۰: گره n را به پشته S اضافه کن

۱۱: پایان شرط اگر

۱۲: پایان حلقه برای

۱۳: پایان شرط اگر

۱۴: پایان حلقه تا زمانی که

۱۵: بازگردان نود های بازدید شده

۴.۴ معرفی مجموعه داده پرسش های چند گزینه ای

جمع آوری مجموعه پرسش های چند گزینه ای نیز مانند مجموعه فرم آزاد دارای اهمیت است. این موضوع از آن جهت حائز اهمیت است که برای تمرین دادن یک مدل زبانی، در برخی شیوه های معرفی شده مانند شیوه تمرین مدل medsss [۳۲] یا شیوه پیشنهادی در همین مقاله که در فصل ششم به آن پرداخته خواهد شد، ما نیازمند پرسش هایی هستیم که وقتی مدل زبانی به آن ها پاسخ می دهد، به سادگی مشخص باشد که پاسخ نهایی صحیح است یا خیر! این ویژگی در پرسش های فرم آزاد وجود ندارد و برای تشخیص میزان درستی آن نیازمند یک داور^{۱۵} هستیم. بنابراین، برای سنجش مدل زبانی نیز از همین نظر دارای اهمیت است! زیرا در پرسش های فرم آزاد برای سنجیدن پاسخ باز نیازمند یک داور هستیم، ولی پرسش های چند گزینه ای دارای یک گزینه مشخص به عنوان پاسخ صحیح هستند.

به همین منظور ما اقدام به گردآوری این پرسش و پاسخ ها از منابع گوناگون کردیم. این منابع شامل ترجمه

^{۱۵}judge

انسانی پرسش‌های انگلیسی، استفاده از کنکور علوم پایه پزشکی ایران و در نهایت استفاده از ترجمه ماشینی پرسش‌های انگلیسی بودند. در مجموع حدود هزار و سیصد پرسش برای تمرین، حدود هزار و هفتصد پرسش برای توسعه و حدود هجده هزار پرسش و پاسخ برای مجموعه تمرین حاصل شد. در نظر داشته باشید که ترجمه ماشینی تنها برای مجموعه تمرین استفاده شده است تا از خطاهای آن در آزمایش و توسعه جلوگیری شود.

۱.۴.۴ ترجمه قسمت پزشکی مجموعه داده MMLU

مجموعه داده MMLU [۱۴] یکی از معتبرترین مجموعه داده‌ها برای ارزیابی توانایی مدل‌های زبانی درک و پاسخ‌دهی به سوالات چندوظیفه‌ای است. این مجموعه شامل سوالاتی در موضوعات مختلف از جمله علوم پزشکی، مهندسی، علوم انسانی و دیگر حوزه‌ها است که به صورت چندگزینه‌ای طراحی شده‌اند. برای ارزیابی دانش پزشکی مدل‌های زبانی توسعه‌یافته، بخش پزشکی این مجموعه داده را به زبان فارسی ترجمه شده است.^{۱۷} هدف از این کار، تطبیق داده‌های ارزیابی با زبان مورد استفاده در مدل و بررسی توانایی مدل در پاسخ‌دهی دقیق به سوالات تخصصی پزشکی در زبان فارسی بوده است.^{۱۸}

۲.۴.۴ گردآوری سوالات کنکور علوم پایه پزشکی ایران

آزمون علوم پایه پزشکی یک آزمون سراسری در ایران است که دانشجویان پزشکی موظف هستند پس از گذراندن دروس علوم پایه معمولاً در پنج ترم در آن شرکت کنند. این آزمون به منظور سنجش میزان آموخته‌های دانشجویان از دروس علوم پایه و آمادگی آنها برای ورود به مراحل بالینی برگزار می‌شود. در صورتی که دانشجو پس از سه مرتبه در این آزمون قبول نشود^{۱۹} از ادامه تحصیل در رشته پزشکی محروم می‌شود. سوالات این آزمون ابتدا از سایت سازمان سنجش به صورت pdf دانلود شده سپس در یک خط لوله^{۲۰} تبدیل تصویر به متن که شامل انسان و ماشین بوده است این سوالات به صورت فایل اکسل در آمده است؛^{۲۱} لازم به ذکر است که از سوالات کنکور علوم پزشکی پایه شهریور ۱۴۰۲ در مجموعه آزمایش و از سوالات بقیه سال‌ها در مجموعه توسعه استفاده شده است.^{۲۲}

^{۱۶} massive multitask language understanding

^{۱۷} ترجمه توسط آقای امیرحسین پورسینا دانشجوی پزشکی انجام شده است.

^{۱۸} برای بازدید از ترجمه این مجموعه داده به آدرس huggingface.co/datasets/gaokerena/FA_MED_MMLU مراجعه کنید.

^{۱۹} نمره قبولی در این آزمون در سالهای مختلف متفاوت است و معمولاً حدود سی و شش درصد میباشد

^{۲۰} pipeline

^{۲۱} برای این کار از کتابخانه fitz پایتون استفاده شده است.

^{۲۲} برای بازدید از این مجموعه داده به آدرس huggingface.co/datasets/gaokerena/KOPP مراجعه کنید.

۳.۴.۴ ترجمه ماشینی مجموعه داده MedMCQA

برای پیاده‌سازی روش پیشنهادی خود در فاز دوم که در فصل ششم به آن به طور مفصل پرداخته خواهد شد، نیاز به تعداد بالایی پرسش و پاسخ پزشکی چند گزینه ای داشتیم؛ از آنجایی که سوال های کنکور علوم پزشکی پایه کفاف تعداد بالای پرسش های مورد نیاز برای تمرین را نمیدهد و از آنجا که در زمان انجام پژوهش، چنین مجموعه داده ای در دسترس نبود، تصمیم گرفتیم از مدل زبانی بزرگ DeepSeek-V3 [۶۳] که از نظر هزینه و کارایی مقرون به صرفه است، برای ترجمه ی بخشی از مجموعه داده ی MedMCQA [۶۴] از زبان انگلیسی به فارسی استفاده کنیم.^{۲۳}

به منظور حفظ تنوع موضوعی، پرسش ها به صورت تصادفی از مجموعه داده ی MedMCQA انتخاب شدند تا دامنه ی وسیعی از مباحث علوم پزشکی (از جمله فیزیولوژی، داروشناسی، پاتولوژی، و سایر حوزه ها) در مجموعه ی نهایی پوشش داده شود.^{۲۴}

برای اطمینان از کیفیت ترجمه ها، از دو داور زبانی مستقل به نام های grok-3-mini [۶۵] و gpt-4.1-mini [۶۶] استفاده کردیم. هر یک از این داوران موظف بودند که ترجمه ی هر پرسش و گزینه های آن را از نظر دقت معنایی، روانی زبانی و حفظ اصطلاحات تخصصی ارزیابی کنند. ترجمه تنها در صورتی به عنوان «تایید شده» در نظر گرفته می شد که هر دو داور به آن امتیاز کامل پنج از پنج اختصاص دهند. در پایان این فرآیند چند مرحله ای، موفق شدیم حدود هجده هزار پرسش چندگزینه ای پزشکی به زبان فارسی را که از نظر کیفیت ترجمه تایید شده بودند، گردآوری کنیم.

۵.۴ مجموعه دادگان معرفی شده پس از گردآوری

پس از اتمام فاز جمع آوری داده ها و انتشار آن ها به صورت عمومی، چند مقاله مهم در حوزه جمع آوری مجموعه داده های پزشکی منتشر شد. در این قسمت به معرفی این مجموعه داده ها خواهیم پرداخت هر چند که از این دادگان در این پایان نامه استفاده نشده است.

^{۲۳} ما تنها برای مجموعه تمرین از پرسش هایی که توسط ترجمه ماشینی تولید شده اند استفاده کرده ایم زیرا مجموعه تمرین حساسیت کمتری نسبت به مجموعه های آزمایش و توسعه در صحت و درستی پرسش ها دارد.

^{۲۴} برای بازدید از این مجموعه داده به آدرس github.com/Mehrdadghassabi/Gaokerena-R/tree/main/dataset/medmcqa_translation_filtered مراجعه کنید.

۱.۵.۴ مجموعه داده PerMedCQA

مجموعه داده PerMedCQA [۶۷] از نظر ساختار و نوع پرسش ها شباهت زیادی به مجموعه داده MF3QA دارد. مانند MF3QA، این مجموعه داده نیز یک مجموعه پرسش و پاسخ فرم آزاد پزشکی است که از وبسایت های مختلف جمع آوری شده و سپس توسط انسان و ماشین فیلتر شده است.^{۲۵} نویسنده مقاله PerMedCQA ادعا کرده که این مجموعه داده نخستین در نوع خود است، اما این ادعا نادرست است، زیرا مجموعه داده MF3QA پیش از PerMedCQA معرفی شده بود.^{۲۶}

۲.۵.۴ مجموعه داده PersianMedQA

مجموعه داده PersianMedQA [۶۸] شامل پرسش های چهارگزینه ای پزشکی به زبان فارسی است. این مجموعه می تواند منبع بسیار مناسبی برای پژوهش حاضر باشد؛ با این حال، تا زمان نگارش این مقاله (بهمن ۱۴۰۴)، داده های آن به صورت عمومی در دسترس قرار نگرفته بود. از این رو، ناچار به استفاده از ترجمه ماشینی مجموعه داده MedMCQA شدیم که پیشتر در مورد آن صحبت شد.^{۲۷}

۳.۵.۴ مجموعه داده PerMed-MM

PerMed-MM یک مجموعه داده پرسش و پاسخ پزشکی چندرسانه ای^{۲۸} است که به منظور ارزیابی دانش مدل های زبانی تصویری^{۲۹} طراحی شده است. [۶۹] منبع این مجموعه شامل سوالات امتحانات مورد تخصصی پزشکی ملی ایران می باشد.^{۳۰}

^{۲۵} برای بازدید از این مجموعه داده به آدرس huggingface.co/datasets/NaghmehAI/PerMedCQA مراجعه کنید.
^{۲۶} آیدی آرکایو دو مقاله نیز گواه برا این موضوع است، آیدی مقاله ای که در آن MF3QA معرفی شده است 2505.16000 میباشد و آیدی مقاله ای که در آن PerMedCQA معرفی شده 2505.18331 است.
^{۲۷} برای بازدید از این مجموعه داده به آدرس huggingface.co/datasets/MohammadJRanjbar/PersianMedQA مراجعه کنید.

^{۲۸}multimodal

^{۲۹}vision language models

^{۳۰} برای بازدید از این مجموعه داده به آدرس huggingface.co/datasets/universitytehran/PerMed-MM مراجعه کنید.

فصل ۵

معرفی مدل زبانی گائوکرنا وی

۱.۵ مقدمه

در این فصل با استفاده از دادگانی که گردآوری کرده ایم یک مدل پایه^۱ را تمرین می‌دهیم تا مدل جدید را که گائوکرنا وی نام دارد معرفی کنیم؛ همانطور که در فصل نخست درباره آن صحبت شد دارای توانایی استدلال نیست. در ادامه با استفاده از ترجمه قسمت پزشکی مجموعه داده MMLU به مقایسه مدل جدید خود با مدل پایه و بقیه جایگزین‌ها خواهیم پرداخت.

۲.۵ مدل پایه

به دلیل عدم وجود یک مدل زبانی پزشکی فارسی متن باز^۲ ما مجبور به انتخاب یک مدل زبانی همه منظوره^۳ به عنوان مدل پایه بودیم. گزینه‌های متعددی مانند [۷۰] qwen2.5 ، [۷۱] aya-expanse ، [۷۲] gemma2 و پرشین مایند^۴ [۷۳] برای انتخاب در دسترس بودند، که به دو دلیل زیر مدل هشت میلیارد پارامتری^۵ «آیا اکسپنس» انتخاب شده است.

^۱baseline model

^۲open source

^۳general purpose

^۴PersianMind

^۵یک مدل سی و دو میلیارد پارامتری از «آیا اکسپنس» نیز موجود است ولی ما به علت محدودیت سخت افزار از مدل هشت میلیاردی استفاده کردیم.

• دلیل نخست این است که داده‌های آموزشی سایر مدل‌ها عمدتاً شامل زبان‌های غیر فارسی هستند، که این امر می‌تواند منجر به ایجاد سوگیری‌هایی در مدل شود که حتی در صورت دستور صریح به استفاده از زبان فارسی، باعث تولید کاراکترهای غیر فارسی می‌شود. در مقابل، «آیا اکسپنس» درک قوی‌ای از دستور زبان فارسی نشان می‌دهد و متنی غنی و دستوری صحیح به زبان فارسی تولید می‌کند، که آن را به گزینه‌ای بهتر برای پژوهش ما تبدیل می‌کند.


• علاوه بر این، اگر ما پارامترهای به‌روزرسانی شده خود را به جای «آیا اکسپنس» در مدل دیگری از خانواده آیا، یعنی «آیا ویژن» [۷۴] ادغام کنیم، این امکان را به دست می‌آوریم که تصاویر پزشکی مانند MRI و CT scan را به عنوان ورودی بپذیریم. این امر باعث افزایش قابلیت کاربرد مدل ما در حوزه پزشکی خواهد شد.

۱.۲.۵ ویژگی‌های مدل آیا اکسپنس

همانطور که پیشتر از آن یاد شد مدل زبانی آیا اکسپنس قابلیت تولید متن‌های فارسی غنی با دستور زبانی صحیح را داراست^۶ و ویژگی که بقیه مدل‌های زبانی تنها برای برخی از زبان‌های دارای منابع غنی^۷ مانند انگلیسی و چینی دارا هستند.

این ویژگی زمانی قابل دسترس است که علاوه بر در دسترس بودن منابع غنی برای تمرین منابع به صورت مساوی بین زبان‌هایی که مدل زبانی پشتیبانی می‌کند تقسیم شده باشد؛ آیا اکسپنس با تولید دادگان مصنوعی^۸ بر مشکل نبود دادگان فائق آمده است، البته تمرین دادن یک مدل زبانی با دادگان مصنوعی تولید شده توسط یک مدل زبانی دیگر باعث فروپاشی مدل^۹ [۷۵] می‌شود که آیا اکسپنس با معرفی مکانیسم آربیتراژ داده [۷۶] که در شکل ۱.۵ می‌بینید از رخ دادن این اتفاق جلوگیری کرده است.

^۶ به جز زبان فارسی این مدل از بیست و دو زبان دیگر نیز پشتیبانی می‌کند.
^۷ resource-rich languages
^۸ synthetic data
^۹ model collapse



شکل ۱.۵: مکانیسم آربیتراژ داده

۳.۵ تنظیم دقیق روی پیکره پزشکی

برای دستیابی به مدل گائوکرنا وی همان‌طور که در نمودار کاهش خطا در تصویر ۲.۵ میبینید ابتدا مدل پایه روی شصت درصد از پیکره پزشکی گردآوری شده تنظیم دقیق^{۱۰} شده است^{۱۱}، برای این کار از اندازه دسته^{۱۲} برابر با دو استفاده کردیم تا نیاز به حافظه در طول آموزش کاهش یابد. علاوه بر این، از تجمع گرادیان^{۱۳} با شانزده مرحله استفاده کردیم که به طور مؤثر اندازه‌ی کلی دسته را به سی و دو افزایش داد و دینامیک پایدار آموزش را فراهم کرد.

برای کاهش بیشتر مصرف حافظه در فرآیند تنظیم دقیق، از روش LoRA [۷۷]^{۱۴} بهره بردیم تا تعداد پارامترهای قابل آموزش به‌طور چشمگیری کاهش یابد. برای این کار از رتبه^{۱۵} برابر با هشت، مقدار آلفا برابر با شانزده، نرخ حذف^{۱۶} برابر با پنج درصد و نرخ پوسیدگی وزن^{۱۷} ده درصد استفاده کرده و وزن‌های LoRA را به تمام پارامترهای قابل آموزش در هر لایه ترنسفورمر اختصاص دادیم.

برای بهینه‌سازی بیشتر این فرآیند، از تکنیک‌های کارآمد توکن‌سازی^{۱۸} و تکنیک‌های آموزش مبتنی بر مدیریت حافظه^{۱۹} بهره بردیم. فرآیند توکن‌سازی متن ورودی را به دنباله‌های قابل مدیریت توکن تقسیم کرد، و با

^{۱۰} fine tune

^{۱۱} برای دسترسی به کد تنظیم دقیق مدل پایه روی پیکره پزشکی گردآوری شده میتوانید به آدرس <https://github.com/Mehrdadghassabi/Gaokerena-V/blob/main/fine-tuning/Pretraining.ipynb> مراجعه کنید

^{۱۲} batch size

^{۱۳} gradient accumulation

^{۱۴} low rank adaptation

^{۱۵} rank

^{۱۶} drop out


^{۱۷} weight decay

^{۱۸} efficient tokenization

^{۱۹} memory-aware training techniques

کوتاه کردن، پر کردن، و مدیریت توکن‌های اضافی، ساختار ورودی و برچسب‌ها را ثابت نگه داشت تا یکپارچگی مفهومی در طول ثابت زمینه حفظ شود. این آماده‌سازی ساده‌شده، همراه با تنظیم دقیق مبتنی بر LoRA، و استفاده از Flash Attention 2 [۷۸] بهبود یافت.

Flash Attention 2 با کاهش سربار حافظه، امکان مدیریت طول‌های زمینه بلندتر و اندازه‌های دسته بزرگ‌تر را به صورت کارآمد فراهم می‌کند، که به تنظیم دقیق موثر کمک کرده و تعادل بین کارایی محاسباتی و عملکرد مدل را برقرار می‌سازد.



شکل ۲.۵: نمودار کاهش خطا تنظیم دقیق روی پیکره پزشکی

۴.۵ تنظیم دستورالعملی روی مجموعه داده MF3QA

پس از تنظیم دقیق روی پیکره پزشکی، بایستی فرآیند تنظیم دستورالعملی^{۲۰} را با استفاده از مجموعه داده MF3QA که فصل پیشین معرفی شد انجام دهیم.^{۲۱} همان‌طور که در نمودار کاهش خطا در تصویر ۳.۵ می‌بینید برای این کار به طور مشخص، باز هم از روش LoRA استفاده کرده ایم ولی این بار با رتبه^{۲۲} برابر با دو، آلفا برابر با دو، نرخ حذف برابر با چهل درصد و نرخ پوسیدگی وزن^{۲۳} پنجاه درصد استفاده کرده ایم. فرآیند

^{۲۰}instruction tuning


^{۲۱} برای دسترسی به کد تنظیم دستورالعملی روی مجموعه داده MF3QA می‌توانید به آدرس <https://github.com/Mehrdadghassabi/Gaokerena-V/blob/main/fine-tuning/InstructionTuning.ipynb>

مراجعه کنید

^{۲۲}rank

^{۲۳}weight decay

تنظیم دستورالعمل تنها برای یک دوره ^{۲۴} انجام شد تا مدل شیوه پاسخگویی درست را بهتر درک کند.



شکل ۳.۵: نمودار کاهش خطا تنظیم دقیق روی مجموعه داده MF3QA

۵.۵ رد پای کربن مدل گائوکرنا وی


اثر کربنی حاصل از بهینه‌سازی مدل گائوکرنا وی که شامل مراحل تنظیم دقیق و تنظیم دستورالعملی می‌شود، بر اساس مشخصات سخت‌افزاری و مدت زمان اجرا تخمین زده شده است. فرآیند تمرین به مدت نوزده ساعت بر روی کارت گرافیک NVIDIA A100 PCIe 40GB که در منطقه شرق آسیا ^{۲۵} پلتفرم ابری گوگل میزبانی می‌شدند، اجرا شده است.

با توجه به مصرف برق معمولی هر پردازنده گرافیکی که برابر با دویست و پنجاه وات است، کل انرژی مصرف‌شده در این مدت برابر 4.750 کیلووات‌ساعت است. با در نظر گرفتن ضریب شدت کربن شبکه شرق آسیا که برابر با 560 گرم کربن دی اکسید معادل به ازای هر کیلووات‌ساعت است، میزان انتشار کربن در طول این فرآیند به 2660 گرم می‌رسد. [۷۹]

۶.۵ نتایج

در نبود مدل های پزشکی فارسی برای مقایسه ما مدل گائوکرنا وی را با مدل های زبانی فارسی همه منظوره^{۲۶} و جایگزین های خط لوله ای^{۲۷} مقایسه کرده ایم.

همانطور که در شکل ۴.۵ میبینید جایگزین های خط لوله ای شامل یک سری مراحل است ابتدا، یک مترجم پرسش کاربر را از فارسی به انگلیسی تبدیل می کند، سپس این پرسش انگلیسی به یک مدل زبانی پزشکی انگلیسی داده می شود، و در نهایت، پاسخ تولید شده توسط مدل انگلیسی دوباره از انگلیسی به فارسی ترجمه می شود.



شکل ۴.۵: مکانیسم جایگزین خط لوله ای

۱.۶.۵ مقایسه با مدل های زبانی فارسی همه منظوره

همان طور که در جدول ۱.۵ مشاهده می کنید، مدل گائوکرنا وی توانست با موفقیت کنکور علوم پایه پزشکی شهریور ۱۴۰۲، را پشت سر بگذارد^{۲۸} و به اولین مدل زبان فارسی با کمتر از هشت میلیارد پارامتر تبدیل شد که این آزمون را با موفقیت پشت سر گذاشته است. علاوه بر این، مدل ما در قسمت پزشکی مجموعه داده^{۲۹} نیز بهبودهایی را نشان داد و نه تنها میانگین نمرات بالاتری کسب کرد، بلکه در اکثر زیرشاخه ها عملکرد برجسته ای داشت و توانایی خود را در درک و تولید دانش پزشکی به زبان فارسی به نمایش گذاشت.


قابل توجه است که دلیل سرعت بالای پاسخگویی PersianMind، همان طور که در جدول ۱.۵ نشان داده شده، این است که این مدل تمایل دارد پاسخ های بسیار کوتاه تری نسبت به مدل های دیگر تولید کند و توکن پایان پاسخ را زودتر ایجاد نماید. علاوه بر ارزیابی پرسش و پاسخ چندگزینه ای، ما از GPT-4o [۸۰] به عنوان داور برای پرسش و پاسخ آزاد نیز استفاده کردیم. قسمت تست مجموعه داده MF3QA به مدل زبان رقیب و مدل ما ارائه شد. همان طور که در شکل ۵.۵ نشان داده شده است، GPT-4o به طور عمده پاسخ های تولید شده توسط مدل ما را نسبت به سه مدل زبان دیگر ترجیح داده است.

^{۲۶} general purpose language models

^{۲۷} pipeline alternatives

^{۲۸} نمره قبولی در این امتحان سی و شش درصد بدون نمره منفی بوده است.

^{۲۹} MMLU



شکل ۵.۵: نرخ پیروزی گائوکرنا وی در رقابت با بقیه مدل های زبانی فارسی همه منظوره

۲.۶.۵ مقایسه با جایگزین های خط لوله ای


همان طور که قبلاً اشاره شد، یکی از گزینه های جایگزین برای توسعه یک مدل زبانی پزشکی فارسی، استفاده از جایگزین های خط لوله ای^{۳۰} است. با این حال، یکی از مشکلات عمده این سیستم ها سرعت پایین آن ها است. این سیستم ها زمان استنتاج بالایی دارند، زیرا خروجی یک مدل باید به مدل دوم منتقل شود و سپس خروجی مدل دوم دوباره توسط مدل اول پردازش شود. این فرآیند تکراری به طور قابل توجهی کارایی سیستم را کاهش می دهد. برای رفع مشکل سرعت پایین سیستم های مرحله ای، ما تمام پارامترها شامل پارامترهای مربوط به مترجم ها و مدل زبانی پزشکی را به طور همزمان بارگذاری کرده ایم. آزمایش های ما با مدل هایی مانند Medmobile همراه با gemma-2b-it به عنوان مترجم، و Medmobile همراه با مدل های parsinlu [۸۱] [۸۲] به عنوان مترجم انجام گرفته است؛ همان طور که در جدول ۲.۵ مشاهده میکنید جایگزین های خط لوله ای دقت و سرعت بسیار پایینی از خود نشان دادند.

یکی دیگر از مشکلات مهم جایگزین های خط لوله ای، عملکرد ضعیف آن ها در شناسایی و ترجمه دقیق اصطلاحات پزشکی است. این محدودیت چالشی جدی ایجاد می کند، زیرا دقت در استفاده از اصطلاحات تخصصی برای ارتباط موثر در محیط های مراقبت های بهداشتی حیاتی است. علت اصلی این ضعف احتمالاً به این دلیل است که مترجم های استفاده شده در این سیستم ها به طور خاص برای ترجمه پزشکی توسعه نیافته اند. برخلاف مدل های ترجمه عمومی، ترجمه پزشکی نیازمند درک دقیق واژگان تخصصی، زمینه و پیچیدگی های زبان پزشکی است.

در حال حاضر، هیچ مدلی برای ترجمه پزشکی به زبان فارسی طراحی نشده است، که این امر باعث می شود سیستم های موجود توانایی کافی برای مدیریت پیچیدگی های اصطلاحات پزشکی نداشته باشند. همان طور که در شکل ۶.۵ نشان داده شده است، این محدودیت ها منجر به نرخ پیروزی بسیار پایین جایگزین های خط لوله ای

^{۳۰} pipeline alternatives

در رقابت با مدل گائوکرنا وی شده است.



شکل ۶.۵: نرخ پیروزی گائوکرنا وی در رقابت با جایگزین های خط لوله ای

PersianMind	Qwen2.5	aya-expanse-8b (baseline)	Gaokerena-V (ours)	
25.18	41.48	40.74	48.14	MMLU-anatomy(fa)
34.0	52.0	49.0	53.0	MMLU-medical-genetics(fa)
20.23	43.35	44.51	43.93	MMLU-college-medicine(fa)
25.28	47.92	52.07	55.47	MMLU-clinical-knowledge(fa)
23.89	43.01	45.58	47.05	MMLU-professional-medicine(fa)
32.63	44.85	45.14	47.22	MMLU-college-biology(fa)
25.89	45.17	46.64	49.31	MMLU(avg)
19.64	33.33	34.52	38.69	IBMSEE Sept 2023
6.8b	7.6b	8b	8b	Number of parameters
حدود 2s	حدود 15s	حدود 8s	حدود 10s	inference time

جدول ۱.۵: مقایسه مدل گائوکرنا وی با بقیه مدل های زبانی فارسی همه منظوره

MedMobile + parsinlu	MedMobile + gemma2-2b-it	Gaokerena-V (ours)	
25.18	14.07	48.14	MMLU- anatomy(fa)
35.0	20.0	53.0	MMLU- medical-genetics(fa)
27.17	19.08	43.93	MMLU- college-medicine(fa)
31.70	27.54	55.47	MMLU- clinical-knowledge(fa)
33.82	17.27	47.05	MMLU- professional-medicine(fa)
31.25	18.75	47.22	MMLU- college-biology(fa)
30.99	20.11	49.31	MMLU(avg)
32.73	24.40	38.69	IBMSEE Sept2023
3.8b+1.2b+1.2b	3.8b+2b	8b	Number of parameters
حدود 30s	حدود 20s	حدود 10s	inference time

جدول ۲.۵: مقایسه مدل گائوکرنا وی با جایگزین های خط لوله ای

فصل ۶

معرفی مدل زبانی گائوکرنا آر

۱.۶ مقدمه

در این فصل، ما به معرفی گائوکرنا آر می‌پردازیم. در ابتدا، دوروش نوین ارائه می‌شود که با استفاده از مقدار کمی داده می‌توانند توانایی‌های استدلالی مدل پایه را به‌صورت قابل‌توجهی بهبود بخشند. نتایج نشان می‌دهد که این رویکرد جدید عملکردی بهتر از گائوکرنا وی دارد؛ مدلی که با حجم زیادی از داده‌ها آموزش دیده است. در ادامه، این فرضیه مطرح می‌شود که ارتقای مهارت‌های استدلالی در مدل‌های زبانی کوچک و کم‌منبع حوزه پزشکی، تاثیرگذارتر و سودمندتر از صرفاً افزایش مقیاس داده‌ها است.

۲.۶ مدل پایه

بنا بر همان دلایلی که برای مدل گائوکرنا وی، مدل هشت میلیارد پارامتری آیا اکسپنس [۷۱] را به‌عنوان مدل پایه^۱ انتخاب کردیم، برای مدل گائوکرنا آر نیز از همان مدل پایه استفاده می‌کنیم. به بیان دیگر هدف از این انتخاب، امکان مقایسه‌ی عادلانه میان آموزش مدل بر حجم عظیمی از داده‌ها و روش پیشنهادی ما برای بهبود مهارت‌های استدلالی است. با این کار، می‌توان به‌روشنی تاثیر واقعی افزایش توانایی استدلال در برابر صرفاً گسترش داده‌های آموزشی را بررسی کرد و نشان داد که چگونه تقویت استدلال می‌تواند حتی در شرایط داده‌های محدود، موجب ارتقای عملکرد مدل شود.

^۱baseline model

۳.۶ چارچوب های معرفی شده

همان طور که پیش تر اشاره شد، برای تقویت مهارت های استدلالی در حوزه پزشکی، دو چارچوب نوین معرفی شده اند؛ هر دوی این چارچوب ها که در ادامه به توضیح جزئیات آنها خواهیم پرداخت نیازمند یک مجموعه داده پرسش و پاسخ چند گزینه ای هستند که ما از ترجمه ماشینی مجموعه MedMCQA که در فصل چهار در مورد آن صحبت شد استفاده کرده ایم.

لازم به ذکر است که چارچوب نخست سریع تر از روش دوم عمل می کند، اما چارچوب دوم داده های باکیفیت تری برای آموزش تولید می نماید. به دلیل محدودیت های سخت افزاری ما و سرعت بسیار بیشتر چارچوب اول نسبت به چارچوب دوم، مدل پایه آیا اکسپنس با نرخ نوزده به یک بین این دو چارچوب آموزش داده شده است بدین معنا که به ازای هر دوره ^۲ آموزش در چارچوب دوم نوزده دوره این مدل در چارچوب اول آموزش دیده است.

با استفاده از بهینه سازی مستقیم ترجیحات ^۳ و رویکرد یاد شده، مدل پایه روی حدود 11000 جفت پاسخ ترجیحی-رد شده ^۴ با حدود 2 میلیون توکن در پاسخ های ترجیحی و 2.5 میلیون توکن در پاسخ های رد شده آموزش داده شده است تا مدل گائوکرنا آر معرفی شود.

۱.۳.۶ روش نخست

روش نخست، که در شکل ۱.۶ و الگوریتم ۲.۶ نمایش داده شده است، از یک مدل معلم (در این پژوهش از مدل زبانی DeepSeek-R استفاده شده است) بهره می گیرد. این مدل معلم، خود یک مدل زبانی با قابلیت استدلال پیشرفته است که وظیفه دارد خطاهای استدلالی مدل دانش آموز را در پاسخ به پرسش های چندگزینه ای حوزه پزشکی شناسایی و اصلاح کند. در این فرآیند، اگر مدل دانش آموز گزینه ی صحیح را انتخاب کند، بدون نیاز به مداخله ی بیشتر، به سؤال بعدی در مجموعه داده منتقل می شویم. اما در صورتی که مدل دانش آموز پاسخ نادرست دهد، مدل معلم با در نظر گرفتن پاسخ درست، یک توضیح گام به گام و دقیق در قالب زنجیره استدلال ^۵ تولید می کند که منطق، شواهد و روند تفکر پشت پاسخ صحیح را آشکار می سازد. این توضیحات نه تنها اشتباه مدل دانش آموز را مشخص می کنند، بلکه نحوه ی استدلال صحیح در مسائل پزشکی را نیز آموزش می دهند. در این سازوکار، خروجی مدل معلم به عنوان پاسخ برگزیده ^۶ تلقی می شود و پاسخ اولیه ی مدل دانش آموز به عنوان

^۲ cycle


^۳ direct preference optimization

^۴ rejected preference pairs

^۵ chain-of-thought

^۶ preferred answer

پاسخ مردود^۷ برای فرآیند بهینه سازی مستقیم ترجیحات^۸ [۲۲] مورد استفاده قرار می گیرد. این چارچوب آموزشی به مدل دانش آموز امکان می دهد تا از طریق بازخورد مستقیم مدل معلم، به شکلی هدفمند مهارت های استدلالی خود را تقویت کرده و درک عمیق تری از منطق پزشکی در پرسش های چندگزینه ای به دست آورد.



شکل ۱.۶: بلوک دیاگرام چارچوب نخست

۲.۳.۶ روش دوم

روش دوم، که در شکل ۲.۶ و الگوریتم ۲.۶ نشان داده شده است، از مدل معلم استفاده می کند تا بازخورد دقیق تری ارائه دهد. این روش با شناسایی خطاهای خاص در پاسخ مدل دانش آموز به یک پرسش چندگزینه ای عمل می کند. پس از دریافت این بازخورد، مدل دانش آموز تشویق می شود تا پاسخ خود را دقیقاً از نقطه ای که خطا رخ داده است، اصلاح کند. از طریق این فرآیند تکراری، مدل دانش آموز به تدریج مسیر استدلالی^۹ [۸۳] خود را بهبود می بخشد و به پاسخ صحیح همگرا می شود. این بازخورد سازنده به مدل دانش آموز امکان می دهد تا استقلال استدلالی خود را تقویت کند، زیرا یاد می گیرد خطاهای خود را به جای تقلید صرف از پاسخ های مدل معلم، اصلاح نماید. در این چارچوب، پاسخ نهایی تولید شده توسط مدل دانش آموز به عنوان پاسخ ترجیحی در

^۷rejected answer
^۸direct preference optimization
^۹reasoning trajectories


الگوریتم ۱.۶ چارچوب دوم پیشنهاد شده برای بهبود دلیل آوری

- ورودی:** پرسش و پاسخ های چند گزینه پزشکی
- ۱: برای به ازای تمامی پرسش ها انجام بده
 - ۲: یکی از پرسش های پزشکی را از مدل دانشجو پرس
 - ۳: اگر اگر پاسخ دانشجو درست بود آنگاه
 - ۴: این پرسش را کنار بگذار و به سراغ پرسش بعدی برو
 - ۵: پایان شرط اگر
 - ۶: پاسخ نادرست دانشجو را ذخیره کن
 - ۷: پاسخ نادرست دانشجو را به همراه کلید پاسخ معلم بده و از او بخواه که استدلال نادرست دانشجو را اصلاح کند
 - ۸: پاسخ معلم را به عنوان پاسخ صحیح ذخیره کن
 - ۹: پاسخ درست و نادرست را به عنوان جفت ذخیره کن
 - ۱۰: اگر در صورت جمع شدن تعداد کافی جفت پاسخ درست و نادرست آنگاه
 - ۱۱: مدل دانشجو را با استفاده از بهینه سازی مستقیم ترجیحات تمرین بده
 - ۱۲: پایان شرط اگر
 - ۱۳: پایان حلقه برای

نظر گرفته می شود، در حالی که تلاش اولیه آن به عنوان پاسخ رد شده برای آموزش بهینه سازی مستقیم ترجیحات استفاده می شود. اگرچه این چارچوب دوم به دلیل فرآیند بازخورد تکراری زمان برتر است، اما آموزش بهینه سازی مستقیم ترجیحات را ساده تر می کند، زیرا هر دو پاسخ رد شده و ترجیحی به طور کامل توسط خود مدل دانش آموز و به صورت توالی هایی از توکن های خودش تولید می شوند. این رویکرد نه تنها به مدل دانش آموز کمک می کند تا مهارت های استدلالی خود را به صورت مستقل توسعه دهد، بلکه با تولید داده های آموزشی باکیفیت تر، کارایی فرآیند یادگیری را نیز افزایش می دهد.

۴.۶ ردپای کربن

در فرآیند تمرین گائوکرنا آر با بهره گیری از مجموعه داده ی ترجمه شده ی ماشینی MedMCQA [۶۴] و به کارگیری دو روش پیشنهادی همراه با بهینه سازی مستقیم ترجیحات مدل مورد نظر به مدت تقریبی یک ساعت^{۱۰} بر روی یک کارت گرافیک NVIDIA H100 PCIe با حافظه ی 80 گیگابایت آموزش داده شد. در طول این^{۱۰} این یک ساعت تنها مربوط به زمان تمرین است و گرته هر دور از چارچوب اول حدود یک دقیقه و هر دور از چارچوب دوم پنج دقیقه زمان برای تولید دادگان زمان میبرد یعنی مجموعاً تولید دادگان بالغ بر نه روز زمان برده است.



شکل ۲.۶: بلوک دیاگرام چارچوب دوم

فرآیند، حدود 43 گیگابایت از حافظه‌ی گرافیکی^{۱۱} مورد استفاده قرار گرفت. نمودار تغییرات تابع خطا در طول آموزش در شکل ۳.۶ نمایش داده شده است.

با در نظر گرفتن میانگین توان مصرفی حدود 350 وات برای هر GPU، میزان کل انرژی مصرفی در این فرآیند تقریباً 0.35 کیلووات-ساعت برآورد می‌شود. با توجه به شدت متوسط کربن شبکه‌ی برق کانادا، جایی که سرور ما در آن قرار داشت (هشتاد و شش گرم دی‌اکسید کربن معادل برای هر کیلووات-ساعت)، میزان انتشار کربن حاصل از این فرآیند در حدود سی گرم دی‌اکسید کربن تخمین زده می‌شود. در مقایسه با مدل قبلی، گائوکرنا وی، که انتشار تقریبی 2.66 کیلوگرم دی‌اکسید کربن داشت، مدل جدید میزان بسیار کمتری کربن دی‌اکسید منتشر کرده است. [۷۹]

۵.۶ نتایج

در این بخش، مدل تازه توسعه‌یافته گائوکرنا آر را با مدل پیشین، گائوکرنا وی، مقایسه می‌کنیم. در حالی که گائوکرنا وی روی مجموعه داده‌های پزشکی بزرگی آموزش دیده و دانش پزشکی قوی و قابلیت‌های بازیابی خوبی را نشان می‌دهد، گائوکرنا آر به‌طور خاص برای تقویت استدلال پزشکی^{۱۲} طراحی شده است. به دلیل خط‌مشی آموزشی متمرکز بر استدلال، گائوکرنا آر روی مجموعه داده‌ای به‌مراتب کوچک‌تر آموزش دیده که منجر به پوشش

^{۱۱}VRAM
^{۱۲}medical reasoning


الگوریتم ۲.۶ چارچوب دوم پیشنهاد شده برای بهبود دلیل آوری

- ورودی:** پرسش و پاسخ های چند گزینه پزشکی
- ۱: برای به ازای تمامی پرسش ها انجام بده
 - ۲: یکی از پرسش های پزشکی را از مدل دانشجو پرس
 - ۳: اگر اگر پاسخ دانشجو درست بود آنگاه
 - ۴: این پرسش را کنار بگذار و به سراغ پرسش بعدی برو
 - ۵: پایان شرط اگر
 - ۶: پاسخ نادرست دانشجو را ذخیره کن
 - ۷: تا زمانی که تا زمانی که دانشجو پاسخ نادرست را نیافته است انجام بده
 - ۸: پاسخ نادرست دانشجو را به معلم بده و از او بخواه که استدلال نادرست را گزارش کند
 - ۹: گزارش معلم را به دانشجو بده و از او بخواه به پرسش دوباره پاسخ دهد
 - ۱۰: پایان حلقه تا زمانی که
 - ۱۱: پاسخ درست دانشجو را ذخیره کن
 - ۱۲: پاسخ درست و نادرست را به عنوان جفت ذخیره کن
 - ۱۳: اگر در صورت جمع شدن تعداد کافی جفت پاسخ درست و نادرست آنگاه
 - ۱۴: مدل دانشجو را با استفاده از بهینه سازی مستقیم ترجیحات تمرین بده
 - ۱۵: پایان شرط اگر
 - ۱۶: پایان حلقه برای

کمی محدودتر دانش پزشکی عمومی شده است. با این حال، مدل گائوکرنا آر توانسته شایستگی استدلالی عمیق تری نشان داده و در وظایفی که نیاز به استنتاج چندمرحله ای و انسجام منطقی دارند، عملکرد بهتری داشته باشد. در ارزیابی نهایی، عملکرد گائوکرنا وی با استفاده از درخواست های^{۱۳} مستقیم با عملکرد گائوکرنا آر هنگام استفاده از درخواست های زنجیره ای فکری^{۱۴} مقایسه میشود.^{۱۵}

نتایج نشان می دهد که گائوکرنا آر، با وجود مقیاس کوچک تر و داده های آموزشی محدود، از طریق هدایت استدلال ساختاریافته، عملکرد برتری را نشان داده و این موضوع اثربخشی بهینه سازی متمرکز بر استدلال را در مقایسه با افزایش صرف مقیاس داده ها نشان می دهد.

^{۱۳} prompt^{۱۴} chain of thought^{۱۵} پیش فرض ما این بوده که عملکرد بهینه به هنگام درخواست مستقیم به معنای دانش پزشکی بیشتر و عملکرد بهینه به هنگام درخواست زنجیره افکار به معنای توانایی استدلال پزشکی برتر در مدل است.



شکل ۳.۶: نمودار کاهش خطا بهینه سازی مستقیم ترجیحات

۱.۵.۶ سنجش استدلال پزشکی

برای ارزیابی قابلیت‌های استدلال پزشکی مدل‌ها، از آن‌ها خواستیم تا مسیرهای استدلال زنجیره‌ای فکری را با تنظیم دمای 1.0 تولید کنند. از آنجا که همه مدل‌ها ممکن است پاسخ‌های متفاوتی برای یک پرسش یکسان ارائه دهند، عملکرد آن‌ها را با استفاده از دو معیار دقت و $\text{pass}@k$ [۸۴] روی مجموعه داده‌های ترجمه فارسی MMLU [۱۴] و کنکور علوم پایه پزشکی شهریور 1401 ارزیابی شده است.

۱.۱.۵.۶ دقت

معیار اول، دقت برای هر پرسش در مجموعه داده‌ها است. برای هر پرسش، پنج نمونه مستقل تولید شد و مکانیزم رای‌گیری اکثریت اعمال گردید: اگر سه یا بیشتر از پنج پاسخ تولیدشده گزینه یکسانی را انتخاب کردند، آن گزینه به عنوان پیش‌بینی نهایی انتخاب شد؛ در غیر این صورت، پرسش بدون پاسخ باقی ماند تا عدم قطعیت مدل را نشان دهد. این چارچوب، برآورد قوی‌ای از سازگاری استدلالی در مسیرهای مختلف ارائه می‌دهد. نتایج در جدول ۱.۶ (بدون نمره منفی) و جدول ۲.۶ (با نمره منفی) ارائه شده‌اند، جایی که در تنظیم نمره منفی، هر سؤال پاسخ داده‌شده به صورت نادرست، امتیاز منفی 0.33 دریافت می‌کند.

Pass@k ۲.۱.۵.۶


معیار Pass@k که ابتدا توسط براون و همکاران معرفی شد، یک معیار قوی برای ارزیابی مدل‌های زبانی ارائه می‌دهد که برای یک ورودی یکسان، در نمونه‌گیری‌های متعدد، خروجی‌های متفاوتی تولید می‌کنند. این معیار، احتمال اینکه مدل حداقل یک پاسخ درست را در k تلاش مستقل تولید کند، محاسبه می‌کند و بدین ترتیب ارزیابی جامع‌تری از قابلیت اطمینان استدلال و تنوع نمونه‌ها ارائه می‌دهد. تعریف رسمی این معیار در فرمول ۱.۶ آمده است، که در آن N نشان‌دهنده تعداد کل نمونه‌های تولیدشده و C_i نشان‌دهنده تعداد نمونه‌های درست برای مسئله i است.

$$\text{pass@k} = \frac{1}{\# \text{ of problems}} \sum_{i=1}^{\# \text{ of problems}} \left(1 - \frac{\binom{N-C_i}{k}}{\binom{N}{k}} \right) \quad (1.6)$$

با پیروی از همان تنظیمات آزمایشی که پیش‌تر توضیح داده شد، امتیازهای Pass@k را با $k = 1, 2, 3$ روی دو مجموعه داده ترجمه قسمت پزشکی MMLU و کنکور علوم پایه پزشکی شهریور ۱۴۰۱ محاسبه کردیم. ارزیابی شامل سه مدل گائوکرنا آر، گائوکرنا وی و آیا اکسپنس بود. نتایج مربوط به مجموعه داده ترجمه قسمت پزشکی MMLU در شکل ۴.۶ و نتایج کنکور علوم پایه پزشکی شهریور ۱۴۰۱ در شکل ۵.۶ نشان داده شده‌اند. همان‌طور که در شکل‌های ۴.۶ و ۵.۶ مشاهده می‌شود، مدل گائوکرنا آر به‌طور مداوم در تقریباً تمام مقادیر k و دسته‌های ارزیابی، عملکرد برتری از خود نشان داد. این بهبود حاکی از آن است که گائوکرنا آر از قابلیت‌های استدلالی پایدارتر و منسجم‌تری برخوردار است و حتی با تعداد نمونه‌های محدود، پاسخ‌های درست را با اطمینان بیشتری تولید می‌کند. در مقابل، مدل گائوکرنا وی در مقادیر کوچک k عملکرد نسبتاً ضعیفی داشت، اما با افزایش k نتایج آن بهبود یافت. این الگو نشان می‌دهد که گائوکرنا وی هنگام تولید مسیرهای استدلالی زنجیره‌ای افکار به‌طور قابل توجهی نامطمئن‌تر عمل می‌کند و اغلب در نمونه‌های مختلف، پاسخ‌های متنوع یا ناسازگاری تولید می‌نماید. بنابراین نتایج، برتری چشمگیر در ثبات و قابلیت اطمینان استدلال را که از طریق رویکرد آموزشی هدفمند و متمرکز بر استدلال در مدل گائوکرنا آر به‌دست آمده است، به‌خوبی برجسته می‌کنند.

سنجش دانش پزشکی ۲.۵.۶

همان‌طور که پیش‌تر اشاره شد، مدل گائوکرنا وی دارای پایه دانش پزشکی گسترده‌تری نسبت به مدل جدیدتر گائوکرنا آر است؛ عمدتاً به این دلیل که بر روی مجموعه داده‌های پزشکی به‌مراتب بزرگ‌تر و متنوع‌تری آموزش دیده




شکل ۴.۶: نتایج Pass@k روی مجموعه داده ترجمه قسمت پزشکی MMLU

است. این تفاوت به ویژه زمانی آشکار می شود که هر دو مدل با درخواست های مستقیم ارزیابی شوند، نه زمانی که از آن ها درخواست زنجیره افکار می شود؛ زیرا در حالت دوم، توانایی استدلال مدل نیز بر عملکرد نهایی تاثیر قابل توجهی می گذارد. همان طور که در جدول ۳.۶ نشان داده شده، در شرایط درخواست مستقیم، گائوکرنا وی عملکرد برتری از خود نشان می دهد که این امر بیانگر توانایی قوی تر آن در به خاطر سپردن و بازیابی حقایق پزشکی ناشی از پیش آموزش گسترده است. نکته جالب توجه اینکه عملکرد گائوکرنا آر و مدل پایه آن آیا اکسپنس در شرایط درخواست مستقیم تقریباً برابر است. این مشاهدت حاکی از آن است که برتری گائوکرنا آر در سناریوهای زنجیره افکار، عمدتاً ناشی از مهارت های استدلالی پیشرفته تر آن نسبت به مدل پایه است، نه افزایش قابل توجه دانش پزشکی.

۳.۵.۶ سنجش پایانی

همان طور که پیش تر بحث شد، مدل گائوکرنا وی در حالت درخواست مستقیم^{۱۶} عملکرد بهتری از خود نشان می دهد، در حالی که گائوکرنا آر زمانی برتر است که از آن درخواست زنجیره افکار^{۱۷} شود؛ یعنی از مدل

^{۱۶} straight prompt
^{۱۷} chain of thought prompt



شکل ۵.۶: نتایج Pass@k روی مجموعه داده کنکور علوم پایه پزشکی شهریور ۱۴۰۱

خواسته شود پیش از ارائه پاسخ نهایی، گام به گام استدلال کند. همانطور که در جدول ۴.۶ میبینید در این بخش دو مدل مدل گائوکرنا وی و گائوکرنا آر با یکدیگر مقایسه شده اند در حالتی که هر مدل درخواستی را دریافت کند که در آن عملکرد بهتری دارد.

مدل های ساخته شده بر پایه مدل آیا اکسپنس (شامل مدل گائوکرنا وی و گائوکرنا آر) به علت ماهیت توسعه شان هنگامی که درخواست زنجیره افکار دریافت میکنند با هر بار اجرا ممکن است نتیجه ای متفاوت تولید کنند؛ برای سنجیدن این مدل هنگامی که با هر بار اجرا نتیجه متفاوتی تولید میکند ما از ترکیب نمونه برداری چندگانه^{۱۸} و رای گیری اکثریت^{۱۹} استفاده کرده ایم به گونه ای که اگر در پنج مرتبه اجرا سه مرتبه گزینه ای توسط مدل زبانی انتخاب شود، آن گزینه به عنوان پاسخ مورد نظر مدل زبانی در نظر گرفته میشود؛ همچنین در مواردی که گائوکرنا آر عدم اطمینان نشان می دهد (یعنی در پنج مرتبه اجرا حداقل سه مرتبه یک گزینه مشخص را به عنوان جواب نهایی تعیین نمیکند)، از مدل پایه یعنی آیا اکسپنس به عنوان یک تاییدکننده کمکی^{۲۰} استفاده می کنیم. پاسخ های تولید شده توسط گائوکرنا آر به آیا اکسپنس ارائه می شود و این مدل مامور می شود پاسخی را انتخاب کند که کمترین اطلاعات نادرست یا ناسازگار را داشته باشد.

^{۱۸} multiple sampling

^{۱۹} majority voting

^{۲۰} auxiliary verifier

aya-expanse-8b (baseline)	gaokerena-V	gaokerena-R	
40.74	39.25	42.22	MMLU- anatomy(fa)
45.0	41.0	50.0	MMLU- medical-genetics(fa)
48.55	37.57	47.97	MMLU- college-medicine(fa)
54.71	46.79	55.84	MMLU- clinical-knowledge(fa)
43.75	37.13	44.85	MMLU- professional- medicine(fa)
43.75	36.80	48.61	MMLU- college-biology(fa)
47.10	40.40	48.76	MMLU(avg)
35.71	29.76	38.69	IBMSEE Sept2023
8b	8b	8b	Number of parameters
حدود 5*35s	حدود 5*35s	حدود 5*35s	inference time

جدول ۱.۶: دقت با درخواست زنجیره افکار بدون نمره منفی

aya-expanse-8b (baseline)	gaokerena-V	gaokerena-R	
24.93	27.65	29.13	MMLU- anatomy(fa)
33.0	32.0	40.0	MMLU- medical-genetics(fa)
34.48	25.24	34.68	MMLU- college-medicine(fa)
42.51	35.59	44.65	MMLU- clinical-knowledge(fa)
30.39	25.0	30.39	MMLU- professional- medicine(fa)
30.09	25.0	36.80	MMLU- college-biology(fa)
33.55	28.57	36.14	MMLU(avg)
19.84	15.87	24.60	IBMSEE Sept2023
8b	8b	8b	Number of parameters
حدود 5*35s	حدود 5*35s	حدود 5*35s	inference time

جدول ۲.۶: دقت با درخواست زنجیره افکار با نمره منفی

aya-expanse-8b (baseline)	gaokerena-V	gaokerena-R	
40.74	48.14	41.48	MMLU- anatomy(fa)
49.0	53.0	49.0	MMLU- medical-genetics(fa)
44.51	43.93	46.24	MMLU- college-medicine(fa)
52.07	55.47	52.45	MMLU- clinical-knowledge(fa)
45.58	47.05	41.91	MMLU- professional- medicine(fa)
45.14	47.22	44.44	MMLU- college-biology(fa)
46.64	49.31	46.28	MMLU(avg)
34.52	38.69	35.11	IBMSEE Sept2023
8b	8b	8b	Number of parameters
حدود 10s	حدود 10s	حدود 10s	inference time

جدول ۳.۶: دقت با درخواست مستقیم

gaokerena-V	gaokerena-R + aya-expanse-8b (verifier)	
48.14	47.40	MMLU- anatomy(fa)
53.0	56.0	MMLU- medical-genetics(fa)
43.93	50.28	MMLU- college-medicine(fa)
55.47	58.86	MMLU- clinical-knowledge(fa)
47.05	48.89	MMLU- professional- medicine(fa)
47.22	54.86	MMLU- college-biology(fa)
49.31	52.98	MMLU(avg)
38.69	46.42	IBMSEE Sept2023
Straight	COT for the main model Straight for the verifier	prompt
حدود 10s	حدود 5*35+10+8s	inference time

جدول ۴.۶: ارزیابی دو پیکربندی

فصل ۷

نتیجه گیری

در این پایان نامه، علاوه بر جمع آوری و معرفی مجموعه داده پزشکی فارسی، دو مدل زبانی کوچک تخصصی پزشکی نیز آموزش داده و ارائه شدند. هر چند تا به کارگیری این مدل های کوچک در محیط واقعی فاصله بسیاری داریم ولی نتایج به دست آمده نشان دهنده عملکرد نسبتاً مطلوب این مدل ها است و می توانند به عنوان گام های اولیه در مسیر توسعه مدل های زبانی کوچک و کارآمد پزشکی به زبان فارسی محسوب شوند.

در نظر داشته باشید که طبق درس تلخ ساتون^۱ هر اندازه یک مدل یادگیری ماشین بزرگتر باشد و با حجم داده بیشتری تمرین داده شده باشد عملکرد بهتری خواهد داشت بنابراین منطقی است که برای کاربرد های پزشکی که در آن تنها عملکرد مد نظر است بایستی مدل های زبانی با اندازه بسیار بزرگتری تمرین داده شوند که نیاز به سخت افزار بیشتری دارند؛ سخت افزاری که اجاره آن هزاران دلار هزینه در پی خواهد داشت و تهیه آن برای یک دانشجو مقدور نیست.

۱.۷ نوآوری ها

به طور خلاصه نوآوری های این پایان نامه به شرح زیر است:

- معرفی اولین مدل های زبانی پزشکی فارسی منبع باز که در مقایسه با سایر مدل های قابل اجرا روی دستگاه های خانگی (مانند لپ تاپ و کامپیوتر شخصی) به نتایج امیدوارکننده دست یافته است.

^۱sutton's bitter lesson

- معرفی یک پیکره پزشکی فارسی که از طریق خزش^۲ وبسایت‌های مختلف پزشکی جمع‌آوری شده است.
- معرفی اولین مجموعه داده پرسش و پاسخ پزشکی فارسی فرم آزاد^۳ که از طریق خزش سایت‌های پرسش و پاسخ پزشکی جمع‌آوری شده است.
- ترجمه بخش پزشکی مجموعه داده MMLU به زبان فارسی که می‌تواند به عنوان یک معیار استاندارد و قابل اعتماد برای ارزیابی هر مدل زبانی پزشکی فارسی مورد استفاده قرار گیرد.
- معرفی چارچوب‌های کارآمد که با استفاده از یک حلقه آموزش-شاگرد باعث بهبود توانایی دلیل‌آوری مدل زبانی شاگرد میشوند.

۲.۷ تحقیقات آینده

۱.۲.۷ توسعه یک مدل زبانی دیداری

در پژوهش‌های انجام‌شده در این پایان‌نامه، تمرکز تنها بر دریافت متن به عنوان ورودی بوده است، در حالی که کاربردهای واقعی پزشکی در بسیاری موارد به دریافت تصویر نیز نیاز دارند. اگر پارامترهای به‌روزشده خود را به جای مدل آیا اکسپنس [۷۱]، با مدل آیا ویژن [۷۴] که یک مدل زبانی دیداری^۴ است ادغام کنیم^۵، مدل‌های گائوکرنا وی و گائوکرنا آر نیز قادر خواهند بود ورودی‌های چندوجهی^۶ از جمله تصاویر پزشکی را دریافت و پردازش کنند. با این حال، توانایی این مدل‌ها در پاسخ‌گویی به پرسش‌های چندوجهی هنوز به طور جامع ارزیابی نشده است؛ بنابراین سنجش این قابلیت می‌تواند در اولویت تحقیقات آینده قرار گیرد.

^۲crawling

^۳free form

^۴vision language model

^۵ توجه داشته باشید که مدل‌های معرفی شده در این پایان‌نامه با استفاده از LoRA آموزش داده شده‌اند؛ به این معنا که تنها بخش بسیار کوچکی از پارامترها به‌روزرسانی شده است. این مجموعه‌ی محدود از پارامترهای به‌روزشده، علاوه بر امکان ترکیب با مدل پایه یعنی آیا اکسپنس، قابلیت ادغام در مدل آیا ویژن را نیز دارند.

^۶multimodal

۲.۲.۷ بهبود مدل از طریق یادگیری تقویتی مبتنی بر بازخورد انسانی

یکی دیگر از تحقیقات آینده می تواند شامل همکاری سازمان یافته و مستمر با پزشکان متخصص در حوزه های مرتبط باشد تا از تجربه های بالینی واقعی آنان برای بهبود عملکرد مدل بهره گرفته شود. این همکاری به ویژه در چارچوب یادگیری تقویتی مبتنی بر بازخورد انسانی^۷ اهمیت می یابد؛ زیرا بازخورد مستقیم متخصصان می تواند مدل را در جهت ارائه پاسخ های دقیق تر، قابل اعتمادتر و سازگار با نیازهای عملی بالین هدایت کند.

۳.۲.۷ توسعه یک مدل مستقل از نوع درخواست

همانطور که در فصل ششم اشاره شد مدل گائوکرنا وی در مواجهه با درخواست های^۸ مستقیم عملکرد بهتری دارد، در حالی که مدل گائوکرنا آر در در مواجهه با درخواست های زنجیره استدلال^۹ عملکرد برتری ارائه می کند. این موضوع بیانگر آن است که هر دو مدل به شدت وابسته به نوع پرامپت هستند و پژوهش های آینده باید این محدودیت مهم را برطرف کنند.

۴.۲.۷ بررسی عدم اطمینان در مدل آیا اکسپنس

همان طور که در فصل پنجم بررسی شد، مدل زبانی آیا اکسپنس پیشرفت قابل توجهی در حوزه زبان های کم منبع^{۱۰} محسوب می شود. این مدل با تمرین بر روی داده های مصنوعی، توانسته است درک و تولید متن در زبان های با منابع کم را به طور موثری بهبود ببخشد. آیا اکسپنس از داده های تولید شده توسط مدل های زبانی بزرگ دیگر به عنوان داده های تمرین استفاده میکند، این رویکرد نوآورانه به آیا اکسپنس اجازه می دهد تا از منابع داده مصنوعی متنوعی استفاده کند، اما در عین حال مشکلاتی را درباره قابلیت اطمینان مدل و عدم قطعیت ذاتی در خروجی های مدل آیا اکسپنس و مدل هایی که بر اساس آن به وجود آمده اند (مانند مدل های گائوکرنا) به وجود می آورد.

یک آزمایش ساده برای نمایش عدم قطعیت موجود در هر دو مدل آیا اکسپنس و مدل گائوکرنا انجام شده است. در این آزمایش، مدل های آیا اکسپنس، گائوکرنا وی و Med-Gemma برای پاسخگویی به سوالات کنکور علوم پزشکی پایه ایران که در شهریور ۱۴۰۲ برگزار شد، به کار گرفته شدند. هر مدل پنج بار بر روی این مجموعه

^۷reinforcement learning with human feedback

^۸prompt

^۹chain of thought

^{۱۰}low resource languages

از سوالات اجرا شد. نتایج نشان داد که تنها Med-Gemma به طور مداوم یک گزینه را برای پرسش مورد نظر در هر پنج اجرا انتخاب میکند، در حالی که مدل‌های دیگر تنوع بسیار بالایی در پاسخ از خود نشان دادند و تنها برای برخی سوالات گزینه یکسانی را در هر پنج اجرا برگزیدند. این یافته‌ها در جدول ۱۰۷ خلاصه شده‌اند. این آزمایش، سطح عدم قطعیت مرتبط با مدل آیا اکسپنس را برجسته می‌کند و چالش‌هایی را که این مدل در ارائه خروجی‌های قابل اعتماد و سازگار با آن مواجه است را آشکار می‌سازد. بنابراین پرداختن به این موضوع نیز میتواند موضوع یکی از تحقیقات آینده باشد.

medgemma	aya-expanse	gaokerena-V	
37.5	34.52	38.69	Accuracy
168	44	10	Number of Single Option Taken
0	7	10	Number of All Option Taken
0	1.21	1.62	Entropy
COT	COT	COT	Prompt
4 billion	8 billion	8 billion	Number of Parameters

جدول ۱۰۷: مقایسه اطمینان مدل‌ها روی مجموعه داده سوالات کنکور علوم پایه پزشکی شهرپور 1402

کتاب نامه

- [۱] Momani, Ahmad. "Implications of Artificial Intelligence on Health Data Privacy and Confidentiality." arXiv preprint arXiv:2501.01639. (2025)
- [۲] Liu, Fenglin, et al. "Application of large language models in medicine." Nature Reviews Bioengineering 3.6 (2025): 445-464
- [۳] Bean, Andrew M., et al. "Reliability of LLMs as medical assistants for the general public: a randomized preregistered study." Nature Medicine (2026): 1-7
- [۴] Wang, Wenxuan, et al. "Medical reasoning in the era of LLMs: a systematic review of enhancement techniques and applications." arXiv preprint arXiv:2508.00669. (2025)
- [۵] Brown, Peter F., et al. "A statistical approach to machine translation." (1990): 79-85.
- [۶] Williams, Ronald J., and David Zipser. "A learning algorithm for continually running fully recurrent neural networks." Neural computation 1.2 (1989): 270-280.
- [۷] Hochreiter, Sepp, and Jürgen Schmidhuber. "Long short-term memory." Neural computation 9.8 (1997): 1735-1780.
- [۸] Vaswani, Ashish, et al. "Attention is all you need." Advances in neural information processing systems 30 (2017).
- [۹] Koroteev, Mikhail V. "BERT: a review of applications in natural language processing and understanding." arXiv preprint arXiv:2103.11943 (2021).

- Devlin, Jacob, et al. "Bert: Pre-training of deep bidirectional transformers for language understanding." Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019. [۱۰]
- Yenduri, Gokul, et al. "Generative pre-trained transformer: A comprehensive review on enabling technologies, potential applications, emerging challenges, and future directions." arXiv preprint arXiv:2305.10435 (2023). [۱۱]
- Raffel, Colin, et al. "Exploring the limits of transfer learning with a unified text-to-text transformer." Journal of machine learning research 21.140 (2020): 1-67. [۱۲]
- Luo, Man, et al. "Choose your QA model wisely: A systematic study of generative and extractive readers for question answering." arXiv preprint arXiv:2203.07522 (2022). [۱۳]
- Hendrycks, Dan, et al. "Measuring massive multitask language understanding." arXiv preprint arXiv:2009.03300 (2020). [۱۴]
- Liu, Yang, et al. "G-eval: NLG evaluation using gpt-4 with better human alignment." arXiv preprint arXiv:2303.16634 (2023). [۱۵]
- Manes, Itay, et al. "K-qa: A real-world medical q&a benchmark." arXiv preprint arXiv:2401.14493 (2024). [۱۶]
- Zhang, Tianyi, et al. "Bertscore: Evaluating text generation with bert." arXiv preprint arXiv:1904.09675 (2019). [۱۷]
- Christiano, Paul F., et al. "Deep reinforcement learning from human preferences." Advances in neural information processing systems 30 (2017). [۱۸]
- Lee, Harrison, et al. "Rlaif vs. rlhf: Scaling reinforcement learning from human feedback with ai feedback." arXiv preprint arXiv:2309.00267 (2023). [۱۹]

- Schulman, John, et al. "Proximal policy optimization algorithms." arXiv preprint [۲۰] arXiv:1707.06347. (2017)
- Shao, Zhihong, et al. "Deepseekmath: Pushing the limits of mathematical reasoning [۲۱] in open language models." arXiv preprint arXiv:2402.03300. (2024)
- Rafailov, Rafael, et al. "Direct preference optimization: Your language model is [۲۲] secretly a reward model." Advances in neural information processing systems 36 (2023): 53728-53741
- Ji, Kaixuan, et al. "Enhancing multi-step reasoning abilities of language models [۲۳] through direct q-function optimization." arXiv preprint arXiv:2410.09302. (2024)
- Haarnoja, Tuomas, et al. "Soft actor-critic: Off-policy maximum entropy deep re- [۲۴] inforcement learning with a stochastic actor." International conference on machine learning. Pmlr, 2018
- Bengio, Yoshua. "From system 1 deep learning to system 2 deep learning." Neural [۲۵] Information Processing Systems. 2019
- Kahneman, Daniel. "Thinking, fast and slow." Farrar, Straus and Giroux. (2011) [۲۶]
- Goyal, Anirudh, et al. "Recurrent independent mechanisms." arXiv preprint [۲۷] arXiv:1909.10893. (2019)
- Wang, Guan, et al. "Hierarchical Reasoning Model." arXiv preprint [۲۸] arXiv:2506.21734. (2025)
- Pan, Liangming, et al. "Automatically correcting large language models: Surveying [۲۹] the landscape of diverse self-correction strategies." arXiv preprint arXiv:2308.03188. (2023)
- Liang, Baoyu, Yuchen Wang, and Chao Tong. "AI Reasoning in Deep Learning Era: [۳۰] From Symbolic AI to Neural-Symbolic AI." Mathematics 13.11 (2025): 1707

- Lightman, Hunter, et al. "Let's verify step by step." The Twelfth International Conference on Learning Representations. 2023. [۳۸]
- Jiang, Shuyang, et al. "MedS³: Towards Medical Slow Thinking with Self-Evolved Soft Dual-sided Process Supervision." arXiv preprint arXiv:2501.12051. (2025) [۳۹]
- Huang, Jie, and Kevin Chen-Chuan Chang. "Towards reasoning in large language models: A survey." Findings of the association for computational linguistics: ACL 2023. 2023. [۴۰]
- Shojaee, Parshin, et al. "The illusion of thinking: Understanding the strengths and limitations of reasoning models via the lens of problem complexity." arXiv preprint arXiv:2506.06941. (2025) [۴۱]
- Wei, Jason, et al. "Emergent abilities of large language models." arXiv preprint arXiv:2206.07682. (2022) [۴۲]
- Guo, Daya, et al. "Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning." arXiv preprint arXiv:2501.12948. (2025) [۴۳]
- Singhal, Karan, et al. "Toward expert-level medical question answering with large language models." Nature Medicine (2025): 1-8. [۴۴]
- Singhal, Karan, et al. "Large language models encode clinical knowledge." Nature 620.7972 (2023): 172-180. [۴۵]
- Saab, Khaled, et al. "Capabilities of gemini models in medicine." arXiv preprint arXiv:2404.18416 (2024). [۴۶]
- Li, Yunxiang, et al. "Chatdoctor: A medical chat model fine-tuned on a large language model meta-ai (llama) using medical domain knowledge." Cureus 15.6 (2023). [۴۷]
- Touvron, Hugo, et al. "Llama: Open and efficient foundation language models." arXiv preprint arXiv:2302.13971 (2023). [۴۸]

- Kim, Hyunjae, et al. "Small language models learn enhanced reasoning skills from [۴۲] medical textbooks." arXiv preprint arXiv:2404.00376 (2024).
- Vishwanath, Krithik, et al. "MedMobile: A mobile-sized language model with [۴۳] expert-level clinical capabilities." arXiv preprint arXiv:2410.09019 (2024).
- Abdin, Marah, et al. "Phi-3 technical report: A highly capable language model lo- [۴۴] cally on your phone." arXiv preprint arXiv:2404.14219 (2024).
- Taghizadeh, Nasrin, et al. "SINA-BERT: a pre-trained language model for analysis [۴۵] of medical texts in Persian." arXiv preprint arXiv:2104.07613 (2021).
- Koroteev, Mikhail V. "BERT: a review of applications in natural language processing [۴۶] and understanding." arXiv preprint arXiv:2103.11943 (2021).
- Veisi, Hadi, and Hamed Fakour Shandi. "A Persian medical question answering sys- [۴۷] tem." International Journal on Artificial Intelligence Tools 29.06 (2020): 2050019.
- Darabi, Leila. Medical Question Answering for Persian. Master's thesis, LIACS, [۴۸] Leiden University, 2024.
- Farahani, Mehrdad, et al. "Parsbert: Transformer-based model for persian language [۴۹] understanding." Neural Processing Letters 53 (2021): 3831-3847.
- Coulom, Rémi. "Efficient selectivity and backup operators in Monte-Carlo tree [۵۰] search." International conference on computers and games. Berlin, Heidelberg: Springer Berlin Heidelberg, .2006
- Wu, Juncheng, et al. "Medreason: Eliciting factual medical reasoning steps in llms [۵۱] via knowledge graphs." arXiv preprint arXiv:2504.00993 .(2025)
- Chen, Junying, et al. "Huatuogpt-o1, towards medical complex reasoning with [۵۲] llms." arXiv preprint arXiv:2412.18925 .(2024)

- Wu, Tianhao, et al. "Thinking llms: General instruction following with thought generation." arXiv preprint arXiv:2410.10630. (2024) [۵۳]
- Ho, Namgyu, Laura Schmid, and Se-Young Yun. "Large language models are reasoning teachers." Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). 2023. [۵۴]
- García-Ferrero, Iker, et al. "Medical mT5: an open-source multilingual text-to-text LLM for the medical domain." arXiv preprint arXiv:2404.07613 (2024). [۵۵]
- Liu, Yang, et al. "Datasets for large language models: A comprehensive survey." arXiv preprint arXiv:2402.18041 (2024). [۵۶]
- Yang, Songhua, et al. "Zhongjing: Enhancing the chinese medical capabilities of large language model through expert feedback and real-world multi-turn dialogue." Proceedings of the AAAI conference on artificial intelligence. Vol. 38. No. 17. 2024. [۵۷]
- Bao, Zhijie, et al. "Disc-medllm: Bridging general large language models and real-world medical consultation." arXiv preprint arXiv:2308.14346 (2023). [۵۸]
- Zhang, Hongbo, et al. "Huatuogpt, towards taming language model to be a doctor." arXiv preprint arXiv:2305.15075 (2023). [۵۹]
- Wang, Xidong, et al. "Huatuo-26M, a Large-scale Chinese Medical QA Dataset." Findings of the Association for Computational Linguistics: NAACL 2025. 2025. [۶۰]
- Zeng, Guangtao, et al. "MedDialog: Large-scale medical dialogue datasets." Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP). 2020. [۶۱]
- Han, Tianyu, et al. "MedAlpaca—an open-source collection of medical conversational AI models and training data." arXiv preprint arXiv:2304.08247 (2023). [۶۲]
- Bi, Xiao, et al. "Deepseek llm: Scaling open-source language models with longtermism." arXiv preprint arXiv:2401.02954. (2024) [۶۳]

- Pal, Ankit, Logesh Kumar Umapathi, and Malaikannan Sankarasubbu. "Medmcqa: [۶۴]
A large-scale multi-subject multi-choice dataset for medical domain question answer-
ing." Conference on health, inference, and learning. PMLR, .2022
- C-LARA-Instance, Manny Rayner ChatGPT. "How Woke is Grok? Empirical Evi- [۶۵]
dence that xAI's Grok Aligns Closely with Other Frontier Models." (2025)
- Achiam, Josh, et al. "Gpt-4 technical report." arXiv preprint arXiv:2303.08774 [۶۶]
(2023).
- Jamali, Naghmeh, et al. "PerMedCQA: Benchmarking Large Language Models [۶۷]
on Medical Consumer Question Answering in Persian Language." arXiv preprint
arXiv:2505.18331 (2025)
- Kalahroodi, Mohammad Javad Ranjbar, et al. "PersianMedQA: Language- [۶۸]
Centric Evaluation of LLMs in the Persian Medical Domain." arXiv preprint
arXiv:2506.00250 (2025)
- Khoramfar, Ali, Mohammad Javad Dousti, and Hesham Faili. "PerMed-MM: A [۶۹]
Multimodal, Multi-Specialty Persian Medical Benchmark for Evaluating Vision Lan-
guage Models." Proceedings of the 14th International Joint Conference on Natural
Language Processing and the 4th Conference of the Asia-Pacific Chapter of the As-
sociation for Computational Linguistics. .2025
- Yang, An, et al. "Qwen2 Technical Report." arXiv Preprint arXiv:2407.10671, 2024. [۷۰]
- Dang, John, et al. "Aya expanse: Combining research breakthroughs for a new mul- [۷۱]
tilingual frontier." arXiv preprint arXiv:2412.04261 (2024).
- Team, Gemma, et al. "Gemma 2: Improving open language models at a practical [۷۲]
size, 2024." URL <https://arxiv.org/abs/2408.00118> 1.3 (2024).

- Rostami, Pedram, Ali Salemi, and Mohammad Javad Dousti. "Persian- [۷۳]
mind: A cross-lingual persian-english large language model." arXiv preprint
arXiv:2401.06466 (2024).
- Dash, Saurabh, et al. "Aya Vision: Advancing the Frontier of Multilingual Multi- [۷۴]
modality." arXiv preprint arXiv:2505.08751 (2025).
- Shumailov, Ilia, et al. "AI models collapse when trained on recursively generated [۷۵]
data." Nature 631.8022 (2024): 755-759.
- Odumakinde, Ayomide, et al. "Multilingual arbitrage: Optimizing data pools to ac- [۷۶]
celerate multilingual progress, 2024." URL <https://arxiv.org/abs/2408.14960>.
- Hu, Edward J., et al. "Lora: Low-rank adaptation of large language models." ICLR [۷۷]
1.2 (2022): 3.
- Dao, Tri. "Flashattention-2: Faster attention with better parallelism and work parti- [۷۸]
tioning." arXiv preprint arXiv:2307.08691 (2023).
- Lacoste, Alexandre, et al. "Quantifying the carbon emissions of machine learning." [۷۹]
arXiv preprint arXiv:1910.09700 (2019).
- Hurst, Aaron, et al. "Gpt-4o system card." arXiv preprint arXiv:2410.21276 (2024). [۸۰]
- Khashabi, Daniel, et al. "Parsinlu: a suite of language understanding challenges for [۸۱]
persian." Transactions of the Association for Computational Linguistics 9 (2021):
1147-1162.
- Kashefi, Omid. "MIZAN: a large persian-english parallel corpus." arXiv preprint [۸۲]
arXiv:1801.02107 (2018).
- Wei, Jason, et al. "Chain-of-thought prompting elicits reasoning in large language [۸۳]
models." Advances in neural information processing systems 35 (2022): 24824-
.24837

Brown, Bradley, et al. "Large language monkeys: Scaling inference compute with [۸۴] repeated sampling." arXiv preprint arXiv:2407.21787. (2024)

Zhang, Mozhi, et al. "Calibrating the confidence of large language models by elic- [۸۵] iting fidelity." arXiv preprint arXiv:2404.02655. (2024)

پیوست آ

اجرای مدل های زبانی

آ.۱ اجرای مدل ها

وزن های مدل های معرفی شده به صورت عمومی منتشر شده است برای دریافت آن میتوانید به مخزن هاگینگ فیس گائوکرنا^۱ مراجعه کنید؛ برای اجرای این مدل ها میتوانید از برنامه آ.۱ برای دادن تنها متن به ورودی و از برنامه آ.۲ برای دادن متن و تصویر به ورودی استفاده کنید.

کیفیت پاسخدهی مدل در حالت چندوجهی (ورودی همزمان متن و تصویر) در چارچوب این پایان نامه به صورت جامع ارزیابی نشده است و نتایج ممکن است بسته به کیفیت تصویر، رزولوشن و نوع پرسش متفاوت باشد. بنابراین توصیه می شود در کاربردهای حساس ابتدا ارزیابی های اضافی انجام دهید.

^۱huggingface.co/gaokerena

```

import torch 1
from transformers import AutoModelForCausalLM, 2
    AutoTokenizer, pipeline 3
from peft.peft_model import PeftModel 4

device = "cuda" if torch.cuda.is_available() else "cpu" 5
dtype = torch.bfloat16 6

base_model_id = "CohereForAI/aya-expanse-8b" 7
our_model_id = "gaokerena/gaokerena-v1.0" 8
# our_model_id = "gaokerena/gaokerena-r1.0" 9

model = AutoModelForCausalLM.from_pretrained( 10
    base_model_id, 11
    torch_dtype=dtype, 12
    device_map=device 13
) 14
tokenizer = AutoTokenizer.from_pretrained(base_model_id) 15

model = PeftModel.from_pretrained(model = model, 16
    model_id = our_model_id) 17
model = model.merge_and_unload() 18

pipe = pipeline("text-generation", model=model, 19
    tokenizer=tokenizer) 20
pipe_output = pipe([{"role": "user", 21
    "content": "your prompt!"}], 22
    max_new_tokens=1024, 23
    eos_token_id=[tokenizer.eos_token_id], 24
    do_sample=False, 25
) 26

output = pipe_output[0]["generated_text"][-1]["content"] 27
print(output) 28

```

برنامه آ.۱: اجرای مدل های زبانی ورودی فقط متن

```

1 from transformers import AutoProcessor,
2   AutoModelForImageTextToText
3 import torch
4 from peft.peft_model import PeftModel
5
6 base_model_id = "CohereForAI/aya-expanse-8b"
7 our_model_id = "gaokerena/gaokerena-v1.0"
8 #our_model_id = "gaokerena/gaokerena-r1.0"
9
10 processor = AutoProcessor.from_pretrained(base_model_id)
11 model = AutoModelForImageTextToText.from_pretrained(
12     base_model_id, device_map="auto",
13     torch_dtype=torch.float16
14 )
15 model = PeftModel.from_pretrained(model=model,
16                                   model_id=our_model_id)
17 model = model.merge_and_unload()
18
19 messages = [
20     {"role": "user",
21      "content": [
22          {"type": "image", "url": "your image!"},
23          {"type": "text", "text": "your prompt!"},
24      ]},
25 ]
26
27 inputs = processor.apply_chat_template(
28     messages, padding=True, add_generation_prompt=True,
29     tokenize=True, return_dict=True, return_tensors="pt"
30 ).to(model.device)
31
32 gen_tokens = model.generate(
33     **inputs,
34     max_new_tokens=1024,
35     do_sample=True,
36     temperature=0.3,
37 )
38 print(processor.tokenizer.decode(
39     gen_tokens[0][inputs.input_ids.shape[1]:],
40     skip_special_tokens=True))

```

برنامه آ.۲: اجرای مدل های زبانی ورودی متن و تصویر

پیوست ب

نمونه های اجرا

در این قسمت یک نمونه پرسش که هم از مدل پایه (آیا اکسپنس) هم از مدل های معرفی شده پرسیده شده آمده است، لازم به ذکر است که تمامی سوالات پرسیده شده از مدل ها به طور کامل در مخازن گیت هاب به صورت فایل اکسل موجود است و اینجا تنها به چند نمونه از آنها اشاره شده است؛ در نظر داشته باشید همانطور که گفته شد اگر از مدل ها درخواست زنجیره افکار شود ممکن است نتایج هر مرتبه متفاوت باشد در نمونه های زیر به نوشتن نتایج یکی از اجراها اکتفا شده است.^۱

ب.۱ نمونه های اجرای گائوکرنا وی در مقایسه با مدل پایه

درخواست^۲:

به پرسش زیر به پاسخ بدهید و تنها از زبان فارسی استفاده کنید!

پرسش

کدام یک از گزینه های زیر در مورد عملکرد انسولین درست است؟

گزینه ها

[A]: گلیکوژنولیز (تجزیه گلیکوژن) در سلول کبدی را افزایش می دهد

[B]: بتا اکسیداسیون اسیدهای چرب را در میتوکندری سلول های کبدی افزایش می دهد

^۱ آدرس مخازن گیت هاب همانطور که پیشتر اشاره شد github.com/mehrdadghassabi/gaokerena-V و github.com/mehrdadghassabi/gaokerena-R-prompt میباشند.

[C]: غلظت پلاسمایی کلسترول و فسفولیپیدها را افزایش می دهد

[D]: آنزیم لیپو پروتئین لیپاز در دیواره مویرگ بافت چربی را فعال می کند

مطرح شده در:

پرسش هفدهم کنکور علوم پایه پزشکی شهریور 1402

گزینه صحیح:

گزینه [D]

پاسخ آیا اکسپنس:

پاسخ صحیح **نیست هیچ کدام از گزینه ها**.

انسولین هورمونی است که توسط لوزالمعده ترشح می شود و نقش اصلی آن در تنظیم متابولیسم گلوکز است. عملکرد اصلی آن **کاهش غلظت گلوکز خون** از طریق دو مکانیسم اصلی است:

1. **افزایش جذب گلوکز توسط سلول ها:** انسولین به سلول ها اجازه می دهد تا گلوکز را از خون به عنوان منبع انرژی جذب کنند.

2. **مهار گلیکوجنولیز:** انسولین تولید گلیکوجن (فرم ذخیره گلوکز) در کبد و عضلات را مهار می کند. گزینه های ارائه شده با عملکرد واقعی انسولین مطابقت ندارند:

[A] * غلظت گلیکوجن را افزایش می دهد، نه کاهش.

[B] * بتا اکسیداسیون اسیدهای چرب را افزایش می دهد، که ارتباط مستقیمی با انسولین ندارد.

[C] * انسولین غلظت کلسترول و فسفولیپید را **کاهش** می دهد، نه افزایش.

[D] * انسولین لیپاز را فعال نمی کند، بلکه متابولیسم چربی را به طور کلی تنظیم می کند.

پاسخ گائوکرنا وی:

پاسخ صحیح گزینه [D] است.

انسولین هورمونی است که توسط لوزالمعده تولید می شود و نقش مهمی در تنظیم قند خون دارد. عملکرد اصلی انسولین، افزایش جذب گلوکز توسط سلول ها است. این هورمون به طور مستقیم بر روی سلول های هدف مانند سلول های کبد، عضلات و بافت چربی تأثیر می گذارد.

گزینه [D] که «آنزیم لیپو پروتئین لیپاز در دیواره مویرگ بافت چربی را فعال می کند» درست است. انسولین باعث افزایش فعالیت آنزیم لیپو پروتئین لیپاز (LPL) در دیواره مویرگ بافت چربی می شود. این آنزیم، چربی های ذخیره شده در بافت چربی را تجزیه کرده و باعث آزاد شدن اسیدهای چرب به جریان خون می شود. این فرآیند به عنوان لیپولیز شناخته می شود و به بدن کمک می کند تا از چربی ها به عنوان منبع انرژی استفاده کند.

گزینه [A] غلط است. انسولین باعث کاهش تجزیه گلوکز (گلیکوجنولیز) در کبد نمی شود.

گزینه [B] غلط است. انسولین باعث افزایش بتا اکسیداسیون اسیدهای چرب در میتوکندری سلول های کبدی

نمی شود.

گزینه [C] غلط است. انسولین باعث افزایش غلظت پلاسمایی کلسترول و فسفولیپیدها نمی شود. بنابراین، گزینه [D] تنها گزینه صحیح در مورد عملکرد انسولین است.

ب. ۲ نمونه های اجرای گائوکرنا آر در مقایسه با مدل پایه

درخواست ۳:

به پرسش زیر قدم به قدم فکر کنید و زنجیره افکار (chain of thought) خود برای رسیدن به پاسخ را به طور کامل شرح دهید و تنها یک گزینه را انتخاب کنید.

پرسش:

بیماری با آسیب وسیع درد و طرف نواحی داخلی قشر پس سری و گیجگاهی کدام علایم را دارد؟
گزینه ها

[A]: هیپوتونی در سمت چپ

[B]: سفتی در انگشتان هر دو دست

[C]: غفلت در نیمه چپ بدن

[D]: عدم تشخیص چهره ها

مطرح شده در:

پرسش ششم کنکور علوم پایه پزشکی شهریور 1402

گزینه صحیح:

گزینه [D]

پاسخ آیا اکسپنس:

زنجیره افکار:

برای پاسخ به این پرسش، ما باید درک کنیم که نواحی قشر پس سری و گیجگاهی کجاست و آسیب به آن چه اثراتی می تواند داشته باشد.

- **قشر پس سری و گیجگاهی:** این نواحی از قشر مغز مسئول عملکردهای مهمی مانند درک حس، کنترل حرکات، ادراک فضایی، حافظه و زبان است.

prompt^۳

- **علائم احتمالی آسیب: ** با توجه به توصیف "آسیب وسیع درد و آسیب در نواحی داخلی قشر پس سری و گیجگاهی"، می توانیم انتظار علائم زیر را داشت:

- **غفلت در نیمکره چپ: ** آسیب به قشر مغز می تواند منجر به اختلال در پردازش اطلاعات حسی و حرکتی در نیمکره چپ شود که علائمی مانند غفلت یا بی توجهی در آن منطقه ایجاد کند.

- **عدم تشخیص چهره ها: ** ناحیه ای از قشر به نام "قلمروی چهره" در ناحیه گیجگاهی واقع شده است. آسیب به این ناحیه می تواند منجر به مشکلات در شناسایی چهره ها شود.

**انتخاب گزینه: **

بنابراین، با توجه به زنجیره افکار فوق، پاسخ صحیح [C] ** غفلت در نیمکره چپ بدن ** است.

** دلیل رد گزینه های دیگر: **

[A] ** هیپوتونی در سمت چپ: ** هیپوتونی ضعف عضلانی است که بیشتر با آسیب به سیستم عصبی حرکتی مرتبط است، نه به طور مستقیم نواحی قشر پس سری و گیجگاهی.

[B] ** سفتی در انگشتان هر دو دست: ** این علامت معمولاً با اختلالات سیستم عصبی مرتبط است، نه به طور خاص آسیب قشر پس سری و گیجگاهی.

[D] ** عدم تشخیص چهره ها: ** این علائم مستقیماً با منطقه آسیب دیده مطابقت دارد.

پاسخ گائوکرنا آر:

برای پاسخ به این پرسش، باید به ارتباط بین نواحی آسیب دیده در قشر مغز و علائمی که هر گزینه توصیف می کند، توجه کنیم. بیماری با آسیب درد وسیع در نواحی داخلی قشر پس سری و گیجگاهی، احتمالاً با علائمی مرتبط با عملکرد این نواحی همراه است.

** قشر پس سری (Posterior Parietal Cortex): **

- مسئولیت پردازش اطلاعات حسی، به ویژه از طریق بینایی و فاصله را بر عهده دارد.

- آسیب به این ناحیه می تواند منجر به مشکلاتی در تشخیص اشکال، جهت یابی، و درک فضا شود.

** قشر گیجگاهی (Temporal Lobes): **

- در پردازش زبان، حافظه، و تشخیص چهره نقش دارد.

- آسیب های این ناحیه می تواند منجر به اختلالات زبانی، مشکلات حافظه ای و شناختی، و حتی ناتوانی در تشخیص چهره ها شود.

با توجه به این اطلاعات، گزینه های را یکی پس از دیگری بررسی می کنیم:

[A] ** هیپوتونی در سمت چپ: ** هیپوتونی به معنای ضعف عضلانی است و معمولاً با آسیب های موتوریک مرتبط است. این علائم با نواحی آسیب دیده در پرسش مرتبط نیست.

[B] ** سفتی در انگشتان هر دو دست: ** این علائم ممکن است با آسیب های موتوریک مرتبط باشد، اما با

نواحی ذکر شده در پرسش مطابقت ندارد.

[C] **غفلت در نیم چپ بدن: ** غفلت (Neglect) یک حالت حسی یا حرکتی است که معمولاً در اثر آسیب به نیمکره چپ مغز رخ می دهد. این پدیده شامل بی توجهی به محیط، اشیاء، یا قسمت های بدن در یک طرف است. با توجه به اینکه پرسش از آسیب به نواحی داخلی قشر پس سری و گیجگاهی سخن می گوید، این گزینه ممکن است مرتبط باشد، به ویژه اگر آسیب به سمت چپ مغز محدود باشد.

[D] **عدم تشخیص چهره ها: ** این علائم مستقیماً با نواحی آسیب دیده در پرسش ارتباط دارد. قشر گیجگاهی در تشخیص چهره ها نقش دارد، بنابراین آسیب به این ناحیه می تواند منجر به ناتوانی در تشخیص چهره ها شود.

بنابراین، با توجه به زنجیره افکار فوق، **گزینه [D] عدم تشخیص چهره ها** پاسخ صحیح است.

Abstract

The use of artificial intelligence in answering medical questions has attracted significant attention in recent years as an emerging and important area in technology and healthcare. While extensive research in this field has been published in English, at the time this thesis began, the Persian language domain was lacking in research. In the first phase of this study, a medical corpus consisting of ninety million tokens and a dataset comprising twenty thousand medical questions and answers provided by physicians was collected from journals and online QA forums. Using part of this data, the base model "Aya-Expanse" was trained, and a new model named "Gaokerena-V" was introduced, which achieved 2.67% better performance compared to its base model on the MMLU medical dataset translated into Persian; in the second phase, considering that medicine is heavily reliant on reasoning and logical analysis, a new model based on a chain of thoughts and logical reasoning was designed to significantly enhance its accuracy and efficiency. For this purpose, two new frameworks based on reinforcement learning with AI feedback were introduced to improve the reasoning capabilities of the base model, Aya-Expanse, through direct optimization of preferences. The result of this improvement was the "Gaokerena-R" model, which, despite being trained on a significantly smaller number of tokens compared to Gaokerena-V, achieved 6.34% better performance than its base model on the same MMLU medical dataset translated into Persian. This level of improvement highlights the importance of reasoning in the field of medicine.

Keywords Artificial Intelligence in medicine, Persian language models, Medical language models, Natural language processing, Artificial Intelligence reasoning



University of Isfahan
Faculty of Computer Engineering

Developing a medical language model based on reasoning in Persian language

A Thesis submitted to the Graduate Studies Office
In partial fulfillment of the requirements for
The degree of Master of Science
in Computer Engineering - Artificial Intelligence and Robotics

By:

Mehrdad Ghassabi

Supervisor:

Dr. Hamidreza Baradaran Kashani

Feb 2026